


**PERANCANGAN DAN EVALUASI METODE INFORMATION
RETRIEVAL UNTUK PEMETAAN STATEMENT OF
APPLICABILITY ISO/IEC 27001:2022 ANNEX A.5–A.8**

SKRIPSI



***THE SUSTAINABLE DEVELOPMENT GOALS
Industry, Innovation and Infrastructure
Peace, Justice and Strong Institutions
Quality Education***

Disusun oleh:

**Muhammad Hilmi Dzaki Wismadi
22/497591/TK/54539**

**PROGRAM SARJANA PROGRAM STUDI TEKNOLOGI INFORMASI
DEPARTEMEN TEKNIK ELEKTRO DAN TEKNOLOGI INFORMASI
FAKULTAS TEKNIK UNIVERSITAS GADJAH MADA
YOGYAKARTA
2026**

DAFTAR ISI

DAFTAR TABEL

DAFTAR GAMBAR

BAB I

PENDAHULUAN

1.1 Latar Belakang

Perkembangan transformasi digital yang pesat telah meningkatkan ketergantungan organisasi terhadap sistem informasi dan infrastruktur teknologi. Konsekuensinya, permukaan serangan (*attack surface*) juga semakin luas, sehingga risiko keamanan siber menjadi semakin kompleks dan sulit dikendalikan. Laporan Check Point Global Cyber Attack Report 2026 menunjukkan bahwa sektor pendidikan merupakan salah satu sektor dengan tingkat serangan siber tertinggi, dengan rata-rata 4.749 serangan per organisasi per minggu, meningkat sebesar 7% dibandingkan tahun sebelumnya. Di kawasan Asia-Pasifik, rata-rata serangan mencapai 3.040 per organisasi per minggu dengan peningkatan 3% secara tahunan [?]. Data ini menunjukkan bahwa institusi pendidikan menghadapi eksposur risiko yang signifikan dan membutuhkan pendekatan pengelolaan keamanan informasi yang sistematis.

Sebagai respons terhadap tantangan tersebut, organisasi mengadopsi standar manajemen keamanan informasi seperti ISO/IEC 27001 yang menyediakan kerangka kerja *Information Security Management System* (ISMS) berbasis risiko [?]. Standar ini mengatur proses penetapan, implementasi, pemeliharaan, dan peningkatan berkelanjutan sistem keamanan informasi [?]. Pembaruan ISO/IEC 27001:2022 mengkonsolidasikan kontrol Annex A dari 114 menjadi 93 kontrol yang diklasifikasikan ke dalam empat kategori utama: organisasional, manusia, fisik, dan teknologi [?]. Selain itu, peningkatan jumlah sertifikasi secara global menunjukkan adopsi yang semakin luas, mengindikasikan relevansi standar ini dalam praktik tata kelola keamanan informasi modern [?].

Namun demikian, implementasi dan audit kepatuhan terhadap ISO 27001 bukan hanya permasalahan adopsi standar, tetapi juga menyangkut kompleksitas operasional dalam proses evaluasi kontrol. Studi empiris menunjukkan bahwa proses sertifikasi dapat berlangsung selama 6 hingga 12 bulan dengan biaya signifikan [?]. Durasi tersebut mencerminkan tahapan yang panjang, mulai dari perencanaan ruang lingkup audit, implementasi kontrol, hingga proses audit eksternal. Dalam konteks ini, beban utama tidak hanya terletak pada durasi, tetapi pada aktivitas analitis seperti pemetaan kontrol terhadap dokumen organisasi, evaluasi bukti implementasi, serta penyusunan *Statement of Applicability* (SoA) yang memerlukan justifikasi eksplisit untuk setiap kontrol yang diterapkan atau dikecualikan.

Secara khusus, proses analisis SoA menjadi salah satu komponen yang paling kritis dalam audit ISO 27001 karena berfungsi sebagai penghubung antara hasil *risk*

assessment dan implementasi kontrol. Auditor harus memastikan bahwa setiap kontrol dalam Annex A telah dievaluasi secara konsisten dan didukung oleh bukti yang relevan. Aktivitas ini umumnya dilakukan secara manual melalui analisis dokumen kebijakan, prosedur, dan artefak pendukung yang berpotensi menimbulkan inkonsistensi, redundansi, serta keterbatasan skalabilitas [?]. Kompleksitas ini semakin meningkat pada organisasi dengan ruang lingkup sistem informasi yang luas, sebagaimana ditunjukkan oleh studi pada institusi pendidikan tinggi yang melibatkan ratusan kontrol dan sub-kontrol dalam proses audit [5].

Perkembangan teknologi *Large Language Model* (LLM) dan arsitektur *Retrieval-Augmented Generation* (RAG) menawarkan pendekatan baru untuk mendukung aktivitas analisis berbasis dokumen. Pendekatan ini menggabungkan kemampuan pemahaman bahasa alami dengan mekanisme *retrieval* terhadap basis pengetahuan eksternal, sehingga memungkinkan sistem untuk mengakses informasi yang relevan. Sejumlah penelitian menunjukkan bahwa performa sistem RAG sangat dipengaruhi oleh kualitas proses *retrieval*, termasuk bagaimana *query* direpresentasikan, bagaimana dokumen dicari, serta bagaimana hasil pencarian diurutkan berdasarkan relevansi sebelum digunakan dalam proses analisis [?, ?, ?, ?]. Dalam konteks ini, strategi *retrieval* menjadi komponen krusial yang menentukan relevansi informasi yang diperoleh.

Dalam domain audit, regulasi, dan *compliance checking*, beberapa studi menunjukkan bahwa kualitas RAG tidak hanya ditentukan oleh model generatif, tetapi juga oleh rancangan *retrieval* dan pengurutan kandidat dokumen. Liu et al. membandingkan BM25, *dense retrieval*, serta kombinasi pembobotan beberapa jalur pencarian untuk memetakan temuan audit ke dasar hukum yang relevan [?]. Studi pada kepatuhan GDPR/CCPA juga menunjukkan bahwa kombinasi DPR dan *cross-encoder reranking* mampu meningkatkan keseimbangan presisi dan recall dibanding pendekatan tunggal [?]. Pada domain keuangan, Ravishankar dan Varalakshmi menerapkan kombinasi *hybrid retrieval*, *reranking*, dan *score fusion* untuk meningkatkan kualitas bukti pada sistem tanya jawab berbasis dokumen [?]. Pada domain hukum pajak, Rustamov et al. membandingkan model *sparse retrieval*, *dense retrieval*, serta *reranker* untuk meningkatkan kualitas pengambilan pasal yang relevan [?]. Selain itu, studi empiris oleh Elkiran dan Rasheed menegaskan bahwa pilihan *retriever*, ukuran kandidat, metrik kemiripan, dan *reranker* memiliki pengaruh signifikan terhadap performa sistem RAG [?]. Meskipun demikian, penelitian-penelitian tersebut umumnya masih berada pada domain regulasi umum, audit pemerintahan, keuangan, atau hukum, sehingga belum secara khusus mengevaluasi perbandingan *hybrid retrieval*, *reranking*, dan kombinasi pembobotan keduanya untuk pemetaan kontrol ISO/IEC 27001:2022 dalam analisis *Statement of Applicability*.

Pada konteks ISO/IEC 27001:2022, terdapat proses yang membutuhkan kemampuan untuk mengidentifikasi kontrol yang paling sesuai berdasarkan konteks tertentu, melibatkan baik kesamaan semantik maupun kecocokan kata kunci secara eksplisit. Oleh karena itu, kualitas *retrieval* menjadi faktor yang sangat menentukan dalam mendukung proses analisis SoA. Meskipun demikian, masih terdapat kesenjangan penelitian dalam hal pemahaman mengenai strategi *retrieval* yang paling efektif untuk konteks ini, khususnya dalam membandingkan pendekatan seperti *hybrid retrieval* serta mekanisme *reranking* secara sistematis.

Berdasarkan permasalahan tersebut, penelitian ini berfokus pada pengembangan dan evaluasi beberapa variasi strategi *retrieval* dalam sistem RAG untuk mendukung proses pemetaan kontrol pada SoA ISO/IEC 27001:2022. Variasi yang diusulkan meliputi pendekatan *hybrid retrieval* yang menggabungkan aspek semantik dan leksikal serta integrasi metode *reranking* untuk meningkatkan kualitas pengurutan hasil pencarian berdasarkan tingkat relevansi terhadap *query*. Sistem yang dikembangkan berperan untuk membantu mengidentifikasi kontrol yang relevan berdasarkan input audit dengan memanfaatkan basis pengetahuan yang terstruktur. Evaluasi difokuskan pada kualitas *retrieval*, seperti ketepatan pemilihan kontrol yang relevan, serta efisiensi proses dalam hal waktu respons, sehingga diharapkan dapat memberikan kontribusi yang bersifat praktis dan terukur dalam penerapan RAG untuk audit keamanan informasi.

1.2 Rumusan Masalah

Berdasarkan latar belakang yang telah dijelaskan, diketahui bahwa pendekatan *Retrieval-Augmented Generation* (RAG) telah digunakan untuk mendukung analisis berbasis dokumen, termasuk dalam konteks audit dan *compliance checking*. Meskipun demikian, masih terdapat keterbatasan dalam evaluasi sistematis terhadap rancangan strategi *retrieval* dalam satu kerangka eksperimen yang konsisten, khususnya pada konteks pemetaan kontrol *Statement of Applicability* (SoA) ISO/IEC 27001:2022.

Penelitian ini berfokus pada analisis kombinasi *hybrid retrieval* antara *dense retrieval* dan *sparse retrieval* melalui variasi proporsi pembobotan skor, analisis performa *reranking* berdasarkan variasi jumlah *candidate pool*, serta analisis kombinasi *hybrid retrieval* dan *reranker* melalui variasi proporsi pembobotan skor akhir. Setiap konfigurasi dievaluasi menggunakan uji signifikansi statistik non-parametrik untuk memastikan bahwa perbedaan performa yang ditemukan bersifat signifikan dan bukan disebabkan oleh variasi acak. Oleh karena itu, rumusan masalah dalam penelitian ini adalah sebagai berikut:

1. Bagaimana pengaruh variasi proporsi pembobotan skor *dense retrieval* dan *sparse retrieval* pada metode *hybrid retrieval* terhadap performa pemetaan kontrol SoA

ISO/IEC 27001:2022, dan apakah perbedaan antar konfigurasi tersebut signifikan secara statistik?

2. Bagaimana pengaruh variasi jumlah *candidate pool* pada proses *reranking* terhadap kualitas pemeringkatan kontrol SoA ISO/IEC 27001:2022, dan apakah perbedaan antar ukuran *candidate pool* tersebut signifikan secara statistik?
3. Bagaimana pengaruh variasi proporsi pembobotan skor antara *hybrid retrieval* dan *reranker* terhadap performa pemetaan kontrol SoA ISO/IEC 27001:2022, dan konfigurasi mana yang paling optimal secara deskriptif maupun statistik?

1.3 Tujuan Penelitian

Berdasarkan rumusan masalah di atas, tujuan penelitian ini adalah sebagai berikut.

1. Mengidentifikasi proporsi pembobotan skor antara *dense retrieval* dan *sparse retrieval* yang paling efektif pada metode *hybrid retrieval* untuk pemetaan kontrol SoA ISO/IEC 27001:2022.
2. Mengidentifikasi ukuran *candidate pool* yang paling efektif pada proses *reranking* untuk meningkatkan kualitas pemeringkatan kontrol SoA ISO/IEC 27001:2022.
3. Mengidentifikasi proporsi pembobotan skor antara *hybrid retrieval* dan *reranker* yang paling efektif untuk meningkatkan performa pemetaan kontrol SoA ISO/IEC 27001:2022, serta mengevaluasi apakah penambahan *reranker* memberikan peningkatan performa yang signifikan dibandingkan pendekatan *hybrid retrieval* saja.

1.4 Batasan Penelitian

1. Ruang lingkup analisis dibatasi pada Annex A.5 (Kontrol Organisasional), A.6 (Kontrol Manusia), A.7 (Kontrol Fisik), dan A.8 (Kontrol Teknologi) dari ISO/IEC 27001:2022.
2. Sistem dirancang untuk menghasilkan rekomendasi kepatuhan dan justifikasi teknis, bukan keputusan audit final yang tetap memerlukan validasi oleh auditor bersertifikat. Selain itu, proses pemetaan manual kontrol Annex ISO/IEC 27001 dalam penelitian ini dilakukan berdasarkan analisis peneliti dengan mengacu pada literatur dan standar terkait, perlu proses validasi langsung oleh praktisi profesional bersertifikat di bidang audit keamanan informasi untuk penelitian lanjutan.
3. Penggunaan dokumen yang berasal dari lingkungan Direktorat Teknologi Informasi Universitas Gadjah Mada sebagai sumber utama pengujian berpotensi menyebabkan hasil penelitian memiliki kecenderungan yang spesifik terhadap karakteristik, struktur dokumentasi, terminologi, serta ruang lingkup pengelolaan

keamanan informasi pada instansi tersebut. Oleh karena itu, tingkat generalisasi hasil penelitian terhadap organisasi atau instansi lain dengan konteks, kebutuhan, dan praktik tata kelola yang berbeda masih memerlukan validasi serta pengujian lebih lanjut.

4. Penelitian ini berfokus pada aspek teknis arsitektur RAG terkhususnya pada tahap *Information retrieval* dan evaluasi akurasi sistem, tidak mencakup aspek regulasi, legal, atau implikasi kebijakan dari otomatisasi audit.
5. Pengukuran performa sistem, khususnya terkait waktu respons dan latensi komputasi dilakukan menggunakan perangkat komputasi milik peneliti. Oleh karena itu, hasil performa yang diperoleh dapat dipengaruhi oleh spesifikasi perangkat keras dan lingkungan komputasi yang digunakan selama proses pengujian.
6. Bahasa dokumen input yang didukung terbatas pada bahasa Indonesia untuk *proof-of-concept*, meskipun arsitektur dirancang untuk dapat diperluas ke bahasa lain.
7. Penelitian ini dibatasi pada analisis dan evaluasi komponen *retrieval* dalam *pipeline Retrieval-Augmented Generation* (RAG), khususnya pada pendekatan *hybrid retrieval* dan metode *reranking*.
8. Penelitian tidak mencakup evaluasi pada tahap *generation* oleh *Large Language Model* (LLM), serta tidak membahas secara khusus pengaruh teknik *document chunking* maupun strategi pemrosesan dokumen lainnya terhadap performa sistem.

1.5 Manfaat Penelitian

Manfaat Akademis

1. Memberikan kontribusi literatur tentang penerapan arsitektur *Retrieval-Augmented Generation* (RAG) terutama pada fokus metode *Information Retrieval* dalam domain audit keamanan informasi, khususnya untuk standar ISO/IEC 27001:2022.
2. Menyediakan metodologi evaluasi komparatif terhadap variasi arsitektur RAG (*Hybrid Retrieval*, *Reranking*, dan kombinasi keduanya) menggunakan metrik akurasi dan latensi untuk menilai peningkatan kinerja sistem secara terukur.
3. Menjadi referensi bagi penelitian lanjutan terkait otomatisasi proses audit dan kepatuhan regulasi domain sistem manajemen keamanan informasi menggunakan arsitektur *Retrieval-Augmented Generation* (RAG).

Manfaat Praktis

1. Menyediakan solusi praktis berupa sistem pendukung keputusan yang dapat digunakan oleh organisasi untuk mempercepat proses analisis *Statement of Applicability* dan mengurangi beban kerja auditor.

2. Meningkatkan konsistensi evaluasi kepatuhan ISO 27001 melalui otomatisasi analisis kontrol dan penyediaan rekomendasi yang dapat ditelusuri.
3. Mengurangi waktu yang diperlukan dalam proses sertifikasi ISO 27001, khususnya pada tahap persiapan dokumentasi dan audit internal.

1.6 Sistematika Penulisan

Sistematika penulisan dalam penelitian ini disusun sebagai berikut:

Bab I Pendahuluan memaparkan latar belakang masalah yang mengidentifikasi tantangan audit ISO 27001 dan peluang otomatisasi menggunakan RAG, rumusan masalah penelitian, tujuan yang ingin dicapai, batasan penelitian, manfaat akademis dan praktis, serta sistematika penulisan.

Bab II Tinjauan Pustaka dan Dasar Teori menyajikan tinjauan literatur terhadap penelitian terdahulu tentang penerapan *hybrid retrieval* dan *reranking* dalam sistem RAG pada domain regulasi dan audit, diikuti dengan dasar teori yang mencakup ISO/IEC 27001, ISMS, SoA, PDCA, Annex A, audit keamanan informasi, NLP, Transformer, LLM, *Information Retrieval*, RAG, dan metrik evaluasi.

Bab III Metodologi Penelitian menjelaskan kerangka penelitian, tahapan pembangunan basis pengetahuan dan penyusunan *dataset* variasi *query*, perancangan arsitektur *Information Retrieval* mencakup metode *hybrid retrieval* dan integrasi *cross-encoder reranking*, serta metodologi evaluasi menggunakan metrik performa *retrieval* seperti Hit@3, Recall@3, MAP@3, dan NDCG@3 untuk menganalisis kualitas hasil pencarian pada dokumen ISO/IEC 27001:2022.

Bab IV Hasil dan Pembahasan menyajikan hasil implementasi sistem serta analisis performa komponen *retrieval* dan *reranking*. Pembahasan mencakup pencarian proporsi *hybrid retrieval* yang optimal, pemilihan *candidate pool* untuk proses *reranking*, evaluasi performa pendekatan *retrieval* dan *reranking* secara independen, serta analisis pengaruh proporsi *weighted score fusion* terhadap kualitas hasil *retrieval* dan efisiensi sistem.

Bab V Kesimpulan dan Saran merangkum temuan utama penelitian, menjawab rumusan masalah, menyajikan kesimpulan tentang efektivitas sistem, serta memberikan saran untuk penelitian lanjutan dan pengembangan sistem di masa depan.

BAB II

TINJAUAN PUSTAKA DAN DASAR TEORI

2.1 Tinjauan Pustaka

Berbagai penelitian telah mengadopsi pendekatan *Retrieval-Augmented Generation* (RAG) untuk meningkatkan kualitas keluaran pada tugas yang membutuhkan *grounded reasoning*, khususnya pada domain yang bersifat regulatif seperti audit, hukum, dan *compliance*. Pada domain ini, keluaran sistem tidak hanya dituntut relevan secara semantik, tetapi juga harus memiliki keterkaitan eksplisit dengan dokumen sumber seperti pasal, klausul, atau regulasi tertentu.

Salah satu penelitian yang secara langsung mengangkat konteks audit adalah penelitian oleh (Liu et al., 2025) yang memodelkan proses pemetaan temuan audit terhadap dasar hukum yang relevan. Penelitian ini menggunakan pendekatan *multi-path retrieval* yang menggabungkan metode *sparse retrieval* (BM25) dan *dense retrieval* berbasis *embedding* BGE. Hasil dari beberapa jalur *retrieval* kemudian digabungkan menggunakan *weighted Reciprocal Rank Fusion* (RRF). Hasil evaluasi menunjukkan bahwa pendekatan ini mampu mengungguli *baseline single-path* dengan Recall@5 sebesar 0,5210 dan MRR@5 sebesar 0,3869. Hal ini menunjukkan bahwa kombinasi multi-representasi *query* dan gabungan skor dapat meningkatkan kualitas pemetaan antara teks audit dan regulasi.

Pada domain *compliance* yang lebih terstruktur, (Gupta et al., 2025) mengembangkan sistem RAG untuk pengecekan kepatuhan terhadap regulasi *General Data Protection Regulation* (GDPR) dan *California Consumer Privacy Act* (CCPA). Berbeda dengan pendekatan sebelumnya, penelitian ini menggunakan *retrieval* berbasis *Dense Passage Retrieval* (DPR) yang diikuti dengan tahap *reranking* menggunakan *cross-encoder*. Output sistem tidak hanya berupa referensi pasal, tetapi juga tingkat kepatuhan (*compliant*, *partially compliant*, *non-compliant*). Hasil eksperimen menunjukkan performa yang sangat tinggi dengan Recall@10 dan Precision@10 mencapai 98,2%, meskipun dengan konsekuensi peningkatan latensi sebesar 3,4 detik per *query*. Penelitian ini menegaskan pentingnya *reranking* dalam meningkatkan presisi hasil *retrieval*, terutama dalam konteks pengambilan keputusan berbasis regulasi.

Sementara itu, (Ravishankar-Varalakshmi, 2025) mengeksplorasi pendekatan serupa pada domain finansial dengan mengintegrasikan *query expansion*, *dense retrieval*, serta *cross-encoder reranking* yang dikombinasikan melalui pembobotan *score fusion*. Hasil evaluasi menunjukkan bahwa pendekatan *hybrid* secara signifikan mengungguli *baseline*, di mana kombinasi terbaik mencapai MAP 0,861 dan Recall@10 0,923 dibandingkan DPR-only dengan MAP 0,712 dan Recall@10 0,784. Studi

ablation juga memperlihatkan bahwa penambahan *reranking* dan pengaturan parameter *score fusion* memberikan peningkatan konsisten pada kualitas *retrieval*. Secara umum, penelitian ini menegaskan bahwa integrasi *reranking* dan *score fusion* merupakan faktor kunci dalam meningkatkan presisi dan relevansi hasil *retrieval*, meskipun diikuti dengan peningkatan kompleksitas sistem.

Pada domain hukum, (Rustamov et al., 2025) melakukan studi kasus pada sistem tanya jawab berbasis hukum perpajakan dengan pendekatan *hybrid retrieval* yang menggabungkan BM25/SPLADE dengan *dense embedding*. Penelitian ini menunjukkan bahwa kombinasi *retrieval sparse* dan *dense* mampu meningkatkan Recall@100 dari 0,49 menjadi 0,60. Selain itu, penerapan *cross-encoder reranking* terbukti meningkatkan kualitas *ranking* dengan peningkatan nilai NDCG dari 0,39 menjadi 0,44. Hasil ini mengindikasikan bahwa pada domain regulasi, *coverage (recall)* dan kualitas *ranking* (presisi) sama-sama krusial untuk memastikan relevansi dokumen yang diambil.

Berbeda dengan penelitian yang berfokus pada domain tertentu, (Elkiran-Rasheed., 2026) melakukan evaluasi empiris secara komprehensif terhadap berbagai komponen dalam *pipeline* RAG, termasuk *retriever*, *similarity function*, dan *reranker*. Hasil penelitian menunjukkan bahwa pemilihan *retriever* dan fungsi *similarity* memiliki pengaruh paling signifikan terhadap performa sistem, dengan signifikansi statistik yang tinggi ($p < 10^{-9}$ pada beberapa metrik). Selain itu, *reranking* terbukti mampu meningkatkan kualitas hasil pada metrik seperti MRR dan nDCG, meskipun dengan tambahan biaya komputasi. Penelitian ini memberikan justifikasi empiris bahwa optimasi pada tahap *retrieval* dan *reranking* merupakan faktor kunci dalam peningkatan performa RAG.

Tabel 2.1. Perbandingan Penelitian Terkait

Paper	Domain	Retrieval	Reranking	Parameter	Metrik
(Liu et al., 2025)	Audit Hukum	Hybrid (BM25 + dense BGE)	Weighted RRF	Pembobotan RRF multi-jalur; Ablasi metode <i>retrieval</i>	Recall, MRR, Hit@5
(Gupta et al., 2025)	Kepatuhan Privasi	DPR (dua tahap)	Cross-encoder	Variasi skema: DPR independen, reranker independen, dan hybrid	Recall, Precision@10, FP, Time
(Ravishankar-Varalakshmi, 2025)	Kuangan	Hybrid (QE + DPR)	Cross-encoder + <i>score fusion</i>	Variasi $\alpha \in \{0,3; 0,5; 0,7\}$ komposisi bobot DPR:reranker	MAP, NDCG, Recall, Precision@10
(Rustamov et al., 2025)	Hukum pajak	Hybrid (BM25/SPLADE + dense)	Cross-encoder (BGE, MiniLM, BERT)	Variasi $\alpha \in \{0,3; 0,5; 0,7\}$ bobot sparse:dense; Variasi $k \in \{10; 50; 100\}$ ukuran kandidat; Perbandingan sebelum dan sesudah reranking	Recall, NDCG, MRR
(Elkiran-Rasheed, 2026)	RAG umum	DPR + variasi strategi retrieval	Cross-encoder (MiniLM, BGE)	Perbandingan kontribusi relatif reranker vs <i>retriever</i> terhadap performa	MAP, NDCG, MRR, Cost

Berdasarkan berbagai penelitian tersebut, dapat disintesis beberapa pola utama. Pertama, pendekatan *hybrid retrieval* yang menggabungkan metode *sparse* dan *dense* mampu memberikan keseimbangan antara *coverage* dan *semantic matching*, dengan

variasi bobot α dense:sparse yang dievaluasi pada penelitian Rustamov et al. Kedua, *reranking* berbasis *cross-encoder* secara konsisten meningkatkan presisi dan kualitas peringkat pada hasil *top-k*, dengan ukuran *candidate pool* yang bervariasi ($k \in \{10; 50; 100\}$) sebagaimana diteliti oleh Rustamov et al. dan Ravishankar-Varalakshmi ($k = 20$). Ketiga, pendekatan *score fusion* melalui pengaturan bobot α hybrid:reranker menunjukkan peran penting dalam mengoptimalkan performa sistem, yang dievaluasi secara eksplisit oleh Ravishankar-Varalakshmi ($\alpha \in \{0,3; 0,5; 0,7\}$). Namun demikian, peningkatan kualitas tersebut umumnya diikuti oleh bertambahnya kompleksitas sistem serta latensi komputasi.

Meskipun berbagai pendekatan tersebut telah banyak diusulkan, sebagian besar penelitian berfokus pada domain umum seperti hukum perpajakan, keuangan, atau regulasi privasi, serta cenderung mengembangkan arsitektur yang semakin kompleks tanpa mengevaluasi secara sistematis kontribusi masing-masing komponen. Berdasarkan Tabel ??, tiga parameter kunci yang masih memerlukan eksplorasi lebih lanjut adalah: (1) bobot α dense:sparse pada tahap *hybrid retrieval*, yang hanya dievaluasi oleh Rustamov et al. dengan variasi terbatas pada domain hukum pajak; (2) ukuran *candidate pool* (k) yang menentukan jumlah kandidat sebelum *reranking*, yang hanya diteliti oleh Rustamov et al. dan Ravishankar-Varalakshmi; serta (3) bobot α hybrid:reranker pada tahap fusi skor akhir, yang hanya dievaluasi oleh Ravishankar-Varalakshmi pada domain keuangan. Ketiga parameter tersebut belum pernah dievaluasi secara sekuensial maupun pada domain keamanan informasi. Oleh karena itu, penelitian ini mengusulkan analisis komparatif terhadap ketiga parameter tersebut secara sekuensial pada domain ISO/IEC 27001:2022, untuk mengidentifikasi *trade-off* antara peningkatan performa dan kompleksitas, serta menentukan konfigurasi yang paling optimal.

2.2 Dasar Teori

2.2.1 Information Security Management System

Information Security Management System (ISMS) merupakan suatu pendekatan sistematis dalam pengelolaan keamanan informasi yang mencakup pemilihan, implementasi, konfigurasi, operasional, serta pemantauan kontrol keamanan untuk melindungi kerahasiaan, integritas, dan ketersediaan informasi serta sistem yang mendukungnya. Dalam konteks ini, istilah “sistem” tidak merujuk pada solusi teknologi semata, melainkan pada sekumpulan proses dan aktivitas yang terstandarisasi, eksplisit, dan dapat diulang dalam pengelolaan keamanan informasi. Oleh karena itu, ISMS tidak hanya berfokus pada aspek teknis, tetapi juga mencakup tata kelola organisasi, manajemen risiko, serta proses bisnis yang berkaitan dengan perlindungan aset informasi.

Sebagai fondasi utama dalam ISMS, keamanan informasi didasarkan pada tiga

prinsip dasar yang dikenal sebagai *CIA triad*, yaitu *confidentiality*, *integrity*, dan *availability*, yang merupakan tujuan fundamental dalam perlindungan data dan layanan informasi [?, ?]:

1. ***Confidentiality*** (Kerahasiaan): memastikan bahwa informasi hanya dapat diakses oleh pihak yang memiliki otorisasi, sehingga mencegah kebocoran atau akses tidak sah.
2. ***Integrity*** (Integritas): menjamin bahwa informasi tetap akurat, utuh, dan tidak mengalami perubahan yang tidak sah selama proses penyimpanan maupun transmisi.
3. ***Availability*** (Ketersediaan): memastikan bahwa informasi dan sistem pendukungnya dapat diakses secara tepat waktu oleh pihak yang berwenang ketika dibutuhkan.

Dalam implementasinya, ISMS dibangun melalui serangkaian proses yang terstruktur dan bersifat siklikal atau berulang, sebagaimana ditetapkan dalam standar internasional seperti ISO/IEC 27001 [?]. Proses ini mencakup identifikasi dan evaluasi risiko keamanan informasi, penerapan kontrol keamanan yang sesuai, serta kegiatan pemantauan dan peningkatan berkelanjutan terhadap efektivitas sistem. Selain itu, ISO/IEC 27001 juga menekankan pentingnya audit internal secara formal untuk mengevaluasi tujuan kontrol keamanan, efektivitas kontrol yang diterapkan, serta proses operasional dalam menjaga dan meningkatkan ISMS [?].

2.2.2 ISO/IEC 27001:2022

ISO/IEC 27001 merupakan standar internasional yang menetapkan persyaratan untuk membangun, mengimplementasikan, memelihara, serta meningkatkan secara berkelanjutan suatu *Information Security Management System* (ISMS). Standar ini menyediakan kerangka kerja formal bagi organisasi dalam mengelola keamanan informasi secara sistematis melalui pendekatan berbasis proses dan risiko. Dalam penerapannya, ISO/IEC 27001 berfokus pada pengelolaan kontrol keamanan serta proses yang mendukung operasional, pemeliharaan, dan peningkatan ISMS secara berkelanjutan.

Pendekatan dalam ISO/IEC 27001 berbasis pada risiko, keputusan terkait keamanan informasi didasarkan pada keseimbangan antara tingkat risiko yang dihadapi organisasi dan biaya atau upaya dalam penerapan kontrol keamanan [?]. Dengan demikian, standar ini memungkinkan organisasi untuk menyesuaikan kontrol keamanan sesuai dengan kebutuhan bisnis dan konteks operasionalnya. Selain itu, tujuan utama implementasi ISO/IEC 27001 adalah untuk melindungi aset informasi melalui penerapan prinsip dasar keamanan informasi, yaitu kerahasiaan (*confidentiality*), integritas (*integrity*), dan ketersediaan (*availability*), yang menjadi fondasi dalam

pengelolaan keamanan informasi [?, ?].

Secara struktural, ISO/IEC 27001:2022 terdiri dari klausul utama (Clause 4–10) yang merepresentasikan kerangka *management system*. Klausul tersebut meliputi:

1. **Clause 4 (Context of the Organization):** Menentukan ruang lingkup ISMS dengan mempertimbangkan isu internal/eksternal, kebutuhan pihak berkepentingan, serta dependensi, yang harus didokumentasikan [?].
2. **Clause 5 (Leadership):** Menekankan komitmen manajemen puncak dalam menetapkan kebijakan, tujuan, integrasi ke proses organisasi, serta mendorong perbaikan berkelanjutan.
3. **Clause 6 (Planning):** Mengatur perencanaan berbasis risiko untuk menangani risiko dan peluang, termasuk penyusunan *Statement of Applicability* (SoA) yang memuat kontrol, justifikasi, dan status implementasi.
4. **Clause 7 (Support):** Mengatur penyediaan sumber daya yang diperlukan untuk implementasi dan peningkatan ISMS.
5. **Clause 8 (Operation):** Mencakup pelaksanaan dan pengendalian proses operasional untuk memenuhi persyaratan ISMS.
6. **Clause 9 (Performance Evaluation):** Mengatur pemantauan, evaluasi kinerja, serta audit internal untuk memastikan efektivitas ISMS; serta
7. **Clause 10 (Improvement):** Berfokus pada perbaikan berkelanjutan melalui tindakan korektif terhadap ketidaksesuaian.



Gambar 2.1. Struktur klausul ISO/IEC 27001:2022. Sumber: [?]

2.2.3 Siklus *Plan, Do, Check, Act* dalam ISO 27001

Konsep *Plan–Do–Check–Act* (PDCA) merupakan suatu siklus manajemen yang digunakan untuk mendukung perbaikan berkelanjutan dalam berbagai domain, termasuk tata kelola TI, manajemen risiko, audit, dan keamanan informasi. Model ini secara umum dikaitkan dengan W. Edwards Deming dan dikenal sebagai pendekatan iteratif yang terdiri dari empat tahapan utama untuk mengelola dan meningkatkan proses secara sistematis.

Dalam konteks ISO/IEC 27001, siklus PDCA digunakan sebagai kerangka kerja dalam pengelolaan *Information Security Management System* (ISMS). Standar ini mengadopsi PDCA sebagai *lifecycle* yang mencakup tahap *Plan* (perencanaan), *Do* (pelaksanaan dan pengoperasian), *Check* (pemantauan dan peninjauan), serta *Act* (pemeliharaan dan peningkatan) dalam pengelolaan keamanan informasi [?]. Pendekatan ini menunjukkan bahwa ISMS tidak bersifat statis, melainkan merupakan sistem yang terus berkembang melalui proses evaluasi dan peningkatan berkelanjutan:

1. *Plan*

Organisasi melakukan proses *risk assessment* dan *risk treatment planning* untuk mengidentifikasi ancaman, kerentanan, serta menentukan kontrol yang sesuai. Proses ini mencakup penentuan ruang lingkup ISMS, kebijakan keamanan informasi, serta pemilihan kontrol yang mengacu pada Annex A.

2. *Do*

ISO 27001 mencakup implementasi kontrol keamanan informasi yang telah direncanakan. Implementasi ini dapat berupa penerapan kebijakan akses, pengamanan jaringan, pelatihan kesadaran keamanan (*security awareness*), serta prosedur operasional lainnya yang mendukung perlindungan aset informasi. Keberhasilan tahap ini sangat bergantung pada konsistensi pelaksanaan serta keterlibatan seluruh pemangku kepentingan dalam organisasi.


3. *Check*

Kegiatan *monitoring* dan evaluasi terhadap efektivitas kontrol yang telah diterapkan. Aktivitas ini meliputi *internal audit*, *management review*, serta pengukuran kinerja keamanan informasi berdasarkan indikator yang telah ditentukan. Tujuan utama tahap ini adalah untuk memastikan bahwa implementasi ISMS berjalan sesuai dengan kebijakan dan tujuan yang telah ditetapkan.

4. *Act*

Perbaikan berkelanjutan terhadap sistem manajemen keamanan informasi. Organisasi melakukan tindakan korektif terhadap temuan audit, memperbaiki

kelemahan kontrol, serta menyesuaikan kebijakan dan prosedur berdasarkan perubahan lingkungan bisnis maupun ancaman keamanan yang berkembang. Dengan demikian, siklus PDCA tidak hanya memastikan kepatuhan terhadap standar, tetapi juga meningkatkan ketahanan sistem terhadap risiko keamanan informasi.



Gambar 2.2. Siklus PDCA dalam ISMS. Sumber: [?]

2.2.4 Statement of Applicability (SoA)

Statement of Applicability (SoA) merupakan salah satu dokumen inti dalam penerapan ISO/IEC 27001 yang berfungsi untuk mendefinisikan kontrol keamanan informasi yang relevan bagi organisasi. SoA berisi daftar kontrol yang dipilih dari Annex A, disertai dengan justifikasi apakah kontrol tersebut diterapkan (*applicable*) atau tidak (*not applicable*), serta alasan yang mendasarinya. Dengan demikian, SoA menjadi representasi formal dari keputusan organisasi dalam mengelola risiko keamanan informasi berdasarkan hasil *risk assessment* dan *risk treatment*.

Dalam konteks siklus *Plan–Do–Check–Act* (PDCA), SoA terutama muncul pada tahap *Plan*. Pada fase ini, organisasi melakukan identifikasi risiko serta menentukan strategi penanganannya (*risk treatment plan*). SoA berperan sebagai artefak yang menghubungkan hasil analisis risiko dengan pemilihan kontrol yang sesuai. Selain itu, SoA juga memiliki keterkaitan dengan tahap *Do* (sebagai acuan implementasi kontrol) dan *Check* (sebagai referensi dalam audit), namun fungsi utamanya tetap berada pada fase perencanaan. Oleh karena itu, SoA dapat dipandang sebagai jembatan antara proses analisis risiko dan implementasi kontrol dalam siklus ISMS.

Lebih lanjut, SoA memiliki hubungan erat dengan praktik pengendalian dokumentasi dalam ISMS, khususnya terkait *control of documents* dan *control of records*. Sebagai dokumen formal, SoA harus dikelola secara sistematis, termasuk dalam hal versi, otorisasi, distribusi, serta penyimpanan. Hal ini penting untuk memastikan bahwa setiap perubahan pada kontrol keamanan dapat dilacak (*traceable*) dan diaudit. Selain itu, SoA juga berfungsi sebagai dokumen pemetaan (*mapping document*) yang menghubungkan risiko, kontrol yang dipilih, serta status implementasinya sebelum dituangkan lebih lanjut dalam *risk treatment plan*. Dengan kata lain, SoA menyediakan transparansi dan akuntabilitas dalam proses pengambilan keputusan terkait keamanan informasi.

Secara struktural, SoA umumnya disajikan dalam bentuk tabel yang terdiri dari beberapa kolom utama:

1. **Control ID** yang merujuk pada identifikasi unik setiap kontrol berdasarkan Annex A ISO/IEC 27001. Kolom ini memudahkan proses referensi dan pelacakan kontrol dalam standar.
2. **Control Description** yang berisi penjelasan singkat mengenai tujuan dan ruang lingkup kontrol tersebut. Kolom ini memberikan konteks bagi organisasi dalam memahami fungsi kontrol yang dipilih.
3. **Applicability** yang menunjukkan apakah suatu kontrol diterapkan atau tidak. Penentuan ini didasarkan pada hasil analisis risiko serta relevansi kontrol terhadap konteks organisasi.
4. **Justification** menjelaskan alasan di balik keputusan tersebut, baik untuk kontrol yang diterapkan maupun yang tidak. Justifikasi ini penting untuk menunjukkan bahwa keputusan yang diambil bersifat rasional dan berbasis risiko, bukan arbitrer.
5. **Implementation Status** yang menggambarkan tingkat implementasi kontrol, misalnya *implemented*, *partially implemented*, atau *not implemented*.
6. **Related Documents** yang mengaitkan kontrol dengan kebijakan, prosedur, atau dokumen pendukung lainnya dalam organisasi.

2.2.5 Annex A ISO/IEC 27001:2022

Annex A dalam ISO/IEC 27001:2022 berfungsi sebagai kumpulan kontrol keamanan (*security controls*) yang digunakan sebagai referensi dalam proses mitigasi risiko pada *Information Security Management System* (ISMS). Kontrol-kontrol ini tidak bersifat wajib untuk seluruhnya diterapkan, melainkan dipilih berdasarkan hasil *risk assessment* dan *risk treatment* yang dilakukan organisasi. Dengan demikian, Annex A menyediakan daftar kontrol yang terstandarisasi untuk membantu organisasi dalam

menentukan langkah perlindungan yang relevan terhadap aset informasi. Pemilihan kontrol dari Annex A kemudian didokumentasikan dalam *Statement of Applicability* (SoA), sehingga Annex A berperan sebagai sumber kontrol, sementara SoA menjadi artefak implementasi yang mencerminkan keputusan organisasi dalam konteks manajemen risiko.

1. A.5 *Organizational Controls*

Annex A.5 berfokus pada kontrol yang berkaitan dengan aspek organisasi dan tata kelola keamanan informasi. Kontrol dalam kategori ini mencakup kebijakan, struktur organisasi, pengelolaan risiko, serta hubungan dengan pihak eksternal. Tujuan utama dari kontrol A.5 adalah memastikan bahwa keamanan informasi dikelola secara strategis dan terintegrasi dalam proses bisnis organisasi.

Tabel 2.2. Kontrol Annex A.5 – *Organizational Controls* [?]

Annex ID	Nama Kontrol	Penjelasan Singkat
A.5.1	<i>Policies for Information Security</i>	Menetapkan kebijakan keamanan sebagai dasar ISMS
A.5.2	<i>Information Security Roles and Responsibilities</i>	Mendefinisikan peran dan tanggung jawab keamanan
A.5.3	<i>Segregation of Duties</i>	Memisahkan fungsi untuk mencegah konflik kepentingan
A.5.4	<i>Management Responsibilities</i>	Menetapkan akuntabilitas manajemen terhadap keamanan informasi
A.5.5	<i>Contact with Authorities</i>	Menjalin koordinasi dengan otoritas keamanan terkait
A.5.6	<i>Contact with Special Interest Groups</i>	Berpartisipasi dalam komunitas dan forum keamanan
A.5.7	<i>Threat Intelligence</i>	Mengelola dan menganalisis informasi ancaman keamanan
A.5.8	<i>Information Security in Project Management</i>	Mengintegrasikan kontrol keamanan dalam manajemen proyek
A.5.9	<i>Inventory of Information and Other Associated Assets</i>	Mengelola inventaris aset informasi secara terstruktur

Tabel 2.3. Kontrol Annex A.5 – *Organizational Controls* (lanjutan 1) [?]

Annex ID	Nama Kontrol	Penjelasan Singkat
A.5.10	<i>Acceptable Use of Information and Assets</i>	Mengatur penggunaan aset sesuai kebijakan organisasi
A.5.11	<i>Return of Assets</i>	Mengelola pengembalian aset setelah masa penggunaan
A.5.12	<i>Classification of Information</i>	Mengklasifikasikan informasi berdasarkan tingkat sensitivitasnya
A.5.13	<i>Labelling of Information</i>	Memberikan label informasi sesuai klasifikasi keamanan
A.5.14	<i>Information Transfer</i>	Mengatur mekanisme transfer informasi secara aman
A.5.15	<i>Access Control</i>	Menetapkan kebijakan dan mekanisme pengendalian akses
A.5.16	<i>Identity Management</i>	Mengelola identitas pengguna dalam sistem organisasi
A.5.17	<i>Authentication Information</i>	Mengelola kredensial dan informasi autentikasi pengguna
A.5.18	<i>Access Rights</i>	Mengatur dan memonitor hak akses pengguna
A.5.19	<i>Information Security in Supplier Relationships</i>	Mengelola risiko keamanan dalam hubungan pemasok
A.5.22	<i>Monitoring, Review and Change Management of Supplier Services</i>	Memantau dan mengevaluasi layanan yang diberikan <i>supplier</i>
A.5.23	<i>Information Security for Use of Cloud Services</i>	Mengatur kontrol keamanan dalam penggunaan layanan <i>cloud</i>
A.5.24	<i>Information Security Incident Management Planning and Preparation</i>	Menyusun rencana penanganan insiden keamanan informasi

Tabel 2.4. Kontrol Annex A.5 – *Organizational Controls* (lanjutan 2) [?]

Annex ID	Nama Kontrol	Penjelasan Singkat
A.5.25	<i>Assessment and Decision on Information Security Events</i>	Melakukan evaluasi terhadap kejadian keamanan informasi
A.5.26	<i>Response to Information Security Incidents</i>	Menangani insiden keamanan secara efektif dan terstruktur
A.5.27	<i>Learning from Information Security Incidents</i>	Mengambil pembelajaran dari insiden keamanan sebelumnya
A.5.28	<i>Collection of Evidence</i>	Mengumpulkan dan mengelola bukti insiden keamanan
A.5.29	<i>Information Security During Disruption</i>	Menjaga keamanan informasi selama kondisi gangguan
A.5.30	<i>ICT Readiness for Business Continuity</i>	Menjamin kesiapan ICT untuk kelangsungan bisnis
A.5.31	<i>Legal, Statutory, Regulatory and Contractual Requirements</i>	Memastikan kepatuhan terhadap regulasi dan hukum
A.5.32	<i>Intellectual Property Rights</i>	Melindungi hak kekayaan intelektual organisasi
A.5.33	<i>Protection of Records</i>	Menjaga keamanan dan integritas catatan organisasi
A.5.34	<i>Privacy and Protection of PII</i>	Melindungi data pribadi dan informasi sensitif
A.5.35	<i>Independent Review of Information Security</i>	Melakukan audit independen terhadap keamanan informasi
A.5.36	<i>Compliance with Policies and Standards for Information Security</i>	Memastikan kepatuhan terhadap kebijakan dan standar
A.5.37	<i>Documented Operating Procedures</i>	Menyusun prosedur operasional yang terdokumentasi dengan baik

2. A.6 People Controls

Annex A.6 berfokus pada aspek sumber daya manusia dalam keamanan informasi. Kontrol ini mencakup pengelolaan keamanan sebelum, selama, dan setelah masa kerja karyawan, dengan tujuan meminimalkan risiko yang berasal dari faktor manusia.

Tabel 2.5. Kontrol Annex A.6 – *People Controls* [?]

Annex ID	Nama Kontrol	Penjelasan Singkat
A.6.1	<i>Screening</i>	Melakukan verifikasi latar belakang calon karyawan
A.6.2	<i>Terms and Conditions of Employment</i>	Menetapkan ketentuan kerja terkait keamanan informasi
A.6.3	<i>Information Security Awareness, Education and Training</i>	Menyelenggarakan pelatihan dan kesadaran keamanan informasi
A.6.4	<i>Disciplinary Process</i>	Menerapkan mekanisme disiplin terhadap pelanggaran keamanan
A.6.5	<i>Responsibilities After Termination</i>	Menetapkan tanggung jawab pasca pemutusan hubungan kerja
A.6.6	<i>Confidentiality or Non-disclosure Agreements</i>	Mengatur perjanjian kerahasiaan untuk perlindungan informasi
A.6.7	<i>Remote Working</i>	Mengamankan aktivitas kerja jarak jauh karyawan
A.6.8	<i>Information Security Event Reporting</i>	Mendorong pelaporan insiden keamanan oleh karyawan

3. A.7 *Physical Controls*

Annex A.7 mencakup kontrol yang berfokus pada perlindungan fisik terhadap aset informasi dan fasilitas organisasi. Tujuannya adalah mencegah akses fisik yang tidak sah, kerusakan, atau gangguan terhadap infrastruktur.

Tabel 2.6. Kontrol Annex A.7 – *Physical Controls* [?]

Annex ID	Nama Kontrol	Penjelasan Singkat
A.7.1	<i>Physical Security Perimeters</i>	Menetapkan batas dan perimeter keamanan fisik
A.7.2	<i>Physical Entry Controls</i>	Mengendalikan akses masuk ke area fisik terbatas

Tabel 2.7. Kontrol Annex A.7 – *Physical Controls* (lanjutan) [?]

Annex ID	Nama Kontrol	Penjelasan Singkat
A.7.3	<i>Securing Offices, Rooms and Facilities</i>	Mengamankan ruang kerja dan fasilitas operasional
A.7.4	<i>Physical Security Monitoring</i>	Melakukan pemantauan aktivitas pada area fisik
A.7.5	<i>Protecting Against Physical and Environmental Threats</i>	Melindungi aset dari ancaman fisik dan lingkungan
A.7.6	<i>Working in Secure Areas</i>	Mengatur prosedur kerja di area dengan keamanan tinggi
A.7.7	<i>Clear Desk and Clear Screen</i>	Menerapkan kebijakan meja bersih dan layar bersih
A.7.8	<i>Equipment Siting and Protection</i>	Menentukan penempatan perangkat secara aman dan terkendali
A.7.9	<i>Security of Assets Off-premises</i>	Menjaga keamanan aset saat digunakan di luar lokasi
A.7.10	<i>Storage Media</i>	Mengelola media penyimpanan secara aman dan terkendali
A.7.11	<i>Supporting Utilities</i>	Menjamin keamanan utilitas pendukung sistem informasi
A.7.12	<i>Cabling Security</i>	Melindungi infrastruktur kabel dari gangguan dan kerusakan
A.7.13	<i>Equipment Maintenance</i>	Melakukan pemeliharaan perangkat secara berkala dan aman
A.7.14	<i>Secure Disposal or Reuse of Equipment</i>	Mengelola penghapusan atau penggunaan ulang perangkat dengan aman

4. A.8 Technological Controls

Annex A.8 berfokus pada kontrol teknis yang diterapkan pada sistem informasi, jaringan, dan aplikasi. Kontrol ini bertujuan untuk melindungi sistem dari ancaman siber serta memastikan keamanan operasional teknologi.

Tabel 2.8. Kontrol Annex A.8 – *Technological Controls* [?]

Annex ID	Nama Kontrol	Penjelasan Singkat
A.8.1	<i>User Endpoint Devices</i>	Mengamankan perangkat <i>endpoint</i> pengguna dari ancaman
A.8.2	<i>Privileged Access Rights</i>	Mengelola hak akses istimewa secara ketat
A.8.3	<i>Information Access Restriction</i>	Membatasi akses informasi sesuai kebutuhan pengguna
A.8.4	<i>Access to Source Code</i>	Melindungi akses terhadap kode sumber aplikasi
A.8.5	<i>Secure Authentication</i>	Menerapkan mekanisme autentikasi yang aman
A.8.6	<i>Capacity Management</i>	Mengelola kapasitas sistem untuk menjaga kinerja
A.8.7	<i>Protection Against Malware</i>	Melindungi sistem dari serangan perangkat lunak berbahaya
A.8.8	<i>Management of Technical Vulnerabilities</i>	Mengidentifikasi dan menangani kerentanan teknis sistem
A.8.9	<i>Configuration Management</i>	Mengelola konfigurasi sistem secara konsisten dan aman
A.8.10	<i>Information Deletion</i>	Menghapus informasi secara aman dan permanen
A.8.11	<i>Data Masking</i>	Melindungi data sensitif melalui teknik <i>masking</i>
A.8.12	<i>Data Leakage Prevention</i>	Mencegah kebocoran data melalui kontrol keamanan
A.8.13	<i>Information Backup</i>	Melakukan pencadangan data secara berkala dan aman
A.8.14	<i>Redundancy of Information Processing Facilities</i>	Menyediakan redundansi untuk menjaga ketersediaan sistem
A.8.15	<i>Logging</i>	Mencatat aktivitas sistem untuk keperluan audit

Tabel 2.9. Kontrol Annex A.8 – *Technological Controls* (lanjutan 1) [?]

Annex ID	Nama Kontrol	Penjelasan Singkat
A.8.16	<i>Monitoring Activities</i>	Memantau aktivitas sistem secara berkelanjutan
A.8.17	<i>Clock Synchronisation</i>	Menyelaraskan waktu sistem untuk konsistensi <i>log</i>
A.8.18	<i>Use of Privileged Utility Programs</i>	Mengontrol penggunaan program utilitas khusus
A.8.19	<i>Installation of Software on Operational Systems</i>	Mengatur instalasi perangkat lunak pada sistem operasional
A.8.20	<i>Network Security</i>	Mengamankan jaringan dari ancaman dan serangan
A.8.21	<i>Security of Network Services</i>	Melindungi layanan jaringan yang digunakan organisasi
A.8.22	<i>Segregation of Networks</i>	Memisahkan jaringan untuk mengurangi risiko akses
A.8.23	<i>Web Filtering</i>	Menyaring akses <i>web</i> untuk mencegah konten berbahaya
A.8.24	<i>Use of Cryptography</i>	Menggunakan kriptografi untuk melindungi informasi sensitif
A.8.25	<i>Secure Development Life Cycle</i>	Menerapkan siklus pengembangan sistem yang aman
A.8.26	<i>Application Security Requirements</i>	Menetapkan kebutuhan keamanan pada aplikasi
A.8.27	<i>Secure System Architecture</i>	Merancang arsitektur sistem yang aman dan andal
A.8.28	<i>Secure Coding</i>	Menerapkan praktik pengkodean yang aman
A.8.29	<i>Security Testing in Development</i>	Melakukan pengujian keamanan selama pengembangan
A.8.30	<i>Outsourced Development</i>	Mengelola keamanan dalam pengembangan oleh pihak ketiga

Tabel 2.10. Kontrol Annex A.8 – *Technological Controls* (lanjutan 2) [?]

Annex ID	Nama Kontrol	Penjelasan Singkat
A.8.31	<i>Separation of Development, Test and Production Environments</i>	Memisahkan lingkungan pengembangan, uji, dan produksi
A.8.32	<i>Change Management</i>	Mengelola perubahan sistem secara terkontrol
A.8.33	<i>Test Information</i>	Mengelola data uji agar tetap aman
A.8.34	<i>Protection of Information Systems During Audit Testing</i>	Melindungi sistem saat proses audit dan pengujian

2.2.6 Keterbatasan Pendekatan Konvensional dalam Audit Keamanan Informasi

Meskipun kerangka ISO/IEC 27001:2022 dan ISMS telah menyediakan pendekatan sistematis, proses audit masih menghadapi kendala pada analisis dan penelusuran bukti. Auditor umumnya mengaitkan temuan dengan kontrol dan regulasi secara manual, yang bergantung pada pengetahuan individu sehingga membatasi efisiensi dan konsistensi. Di sisi lain, besarnya volume dokumen audit membuat proses menjadi memakan waktu, rentan kesalahan, dan berpotensi menimbulkan inkonsistensi [?].

Perkembangan *Natural Language Processing* melalui *Large Language Models* menawarkan otomatisasi analisis dokumen, namun masih memiliki keterbatasan seperti kurangnya *grounding* terhadap data spesifik. Oleh karena itu, *Retrieval-Augmented Generation* menjadi pendekatan yang lebih andal dengan menggabungkan kemampuan generatif dan *retrieval* berbasis dokumen untuk meningkatkan akurasi dan konsistensi dalam proses audit [?].


2.2.7 *Natural Language Processing*

Pemrosesan bahasa alami (*natural language processing*, NLP) merupakan bagian dari kecerdasan buatan yang memungkinkan komputer untuk memahami dan menghasilkan bahasa manusia. NLP terdiri dari dua komponen utama, yaitu *natural language understanding* (NLU) dan *natural language generation* (NLG). NLU berfokus pada kemampuan sistem dalam memahami makna dari bahasa yang digunakan manusia, termasuk menangani konteks, ambiguitas, serta berbagai bentuk ekspresi bahasa. Sementara itu, NLG bertugas untuk menghasilkan teks yang menyerupai bahasa manusia, melalui proses pemilihan informasi yang relevan, penyusunan isi, serta pengaturan struktur dan gaya bahasa agar mudah dipahami [?].

2.2.8 Transformer

Arsitektur *Transformer* merupakan model yang diperkenalkan oleh Vaswani et al. melalui publikasi berjudul “*Attention Is All You Need*” [?]. Model ini menghadirkan pendekatan baru dalam pemodelan tugas NLP. Sebelum adanya *Transformer*, berbagai tugas sekuensial umumnya mengandalkan arsitektur *Recurrent Neural Network* (RNN) dan *Convolutional Neural Network* (CNN). Kedua arsitektur tersebut memiliki kekurangan yaitu memproses data harus secara berurutan menyebabkan keterbatasan dalam efisiensi pelatihan serta kesulitan dalam menangkap hubungan konteks jangka panjang antar elemen dalam data.

Sebagai solusi, *Transformer* dirancang tanpa bergantung pada mekanisme RNN maupun CNN, melainkan mengandalkan mekanisme *attention*, khususnya *self-attention*. Mekanisme ini memungkinkan model untuk mengevaluasi keterkaitan antar kata dalam suatu urutan secara lebih fleksibel, sehingga mampu memahami konteks secara menyeluruh dan menghasilkan representasi yang lebih baik. Secara teknis, struktur arsitektur *Transformer*, khususnya bagian *encoder* umumnya disajikan dalam bentuk diagram untuk menggambarkan alur pemrosesannya (Gambar ??).



Gambar 2.3. Arsitektur Transformer. Sumber: [?]

Arsitektur ini terdiri dari beberapa komponen utama yang bekerja secara terintegrasi dalam memproses dan menghasilkan teks:

1. **Embedding** dan **Unembedding** berfungsi untuk mengubah token menjadi representasi vektor serta memetakan kembali representasi tersebut ke ruang kosakata untuk menghasilkan prediksi kata berikutnya [?].
2. **Positional Encoding** ditambahkan ke *embedding* untuk mempertahankan informasi

urutan token dalam suatu kalimat.

3. **Layer Normalization** digunakan untuk menstabilkan proses pelatihan dengan menjaga nilai dalam *layer* tetap berada pada rentang yang mendukung optimasi berbasis gradien.
4. **Multi-head Attention** merupakan mekanisme inti yang memungkinkan model menangkap hubungan kontekstual antar token melalui proses *query*, *key*, dan *value* secara paralel.
5. **Feedforward Network** berfungsi sebagai transformasi non-linear yang diterapkan pada setiap token untuk memperkaya representasi fitur.
6. **Softmax** digunakan untuk mengubah *output* model menjadi distribusi probabilitas atas seluruh kosakata, sehingga memungkinkan pemilihan token berikutnya secara probabilistik.

2.2.9 Sentence Embedding

Sentence embedding merupakan teknik representasi teks di mana sebuah kalimat, paragraf, atau dokumen diproyeksikan ke dalam ruang vektor berdimensi tetap (fixed-size vector space), sehingga kemiripan semantik antar teks dapat diukur secara matematis. Konsep ini dilandasi oleh prinsip *distributional semantics*, yang menyatakan bahwa makna suatu kata atau kalimat dapat ditangkap melalui konteks penggunaannya dalam korpus bahasa. Prinsip ini dirumuskan oleh Firth (1957) dengan pernyataan “*you shall know a word by the company it keeps*”, yang menjadi fondasi filosofis bagi pendekatan representasi berbasis vektor. Dalam konteks modern, prinsip tersebut diwujudkan dalam bentuk vektor padat (*dense vector*) berdimensi rendah yang dihasilkan oleh model jaringan saraf berbasis arsitektur *Transformer*, di mana setiap dimensi vektor menyandikan informasi semantik yang dipelajari secara implisit dari data pelatihan [?].

Berbeda dengan representasi kata berbasis *sparse vector* seperti *one-hot encoding* atau matriks ko-okurens yang berdimensi sangat tinggi dan sebagian besar bernilai nol, *dense embedding* memiliki dimensi jauh lebih kecil (umumnya antara 50 hingga 1000) namun setiap elemennya menyimpan informasi semantik secara lebih kompak dan kaya. Terdapat dua kelompok utama model *embedding*: (1) model *static embedding* seperti Word2Vec dan FastText yang menghasilkan satu vektor tetap per kata tanpa mempertimbangkan konteks kalimat, dan (2) model *contextualized embedding* berbasis *Transformer* seperti BERT dan variannya yang menghasilkan representasi dinamis sesuai konteks kalimat secara keseluruhan. Dalam tugas *information retrieval* dan *semantic similarity*, model *sentence embedding* dari keluarga *Sentence-BERT* (SBERT) lebih diutamakan karena menghasilkan representasi tingkat kalimat yang

efisien untuk perbandingan antar teks dalam skala besar [?].

2.2.10 Cosine Similarity dan Dot Product

Setelah teks direpresentasikan sebagai vektor, kemiripan semantik antar dua teks dapat diukur menggunakan metrik *cosine similarity*. Secara geometris, *cosine similarity* mengukur kosinus sudut (θ) antara dua vektor dalam ruang berdimensi- N , sehingga berfokus pada arah vektor, bukan besaran magnitudonya. Hal ini menguntungkan dalam konteks pemrosesan teks karena kemiripan makna lebih tepat dicerminkan oleh keselarasan arah vektor dibanding panjang vektor yang dapat dipengaruhi oleh frekuensi kata. Rumus *cosine similarity* antara dua vektor $\mathbf{v}$ dan $\mathbf{w}$ dinyatakan sebagai:

$$\text{cosine}(\mathbf{v}, \mathbf{w}) = \frac{\mathbf{v} \cdot \mathbf{w}}{|\mathbf{v}| |\mathbf{w}|} = \frac{\sum_{i=1}^N v_i w_i}{\sqrt{\sum_{i=1}^N v_i^2} \cdot \sqrt{\sum_{i=1}^N w_i^2}} \quad (2-1)$$

dengan $\mathbf{v} \cdot \mathbf{w}$ adalah *dot product* antara kedua vektor, $|\mathbf{v}|$ dan $|\mathbf{w}|$ adalah panjang (norma L2) masing-masing vektor, dan N adalah jumlah dimensi. Nilai *cosine similarity* berada pada rentang $[-1, 1]$; nilai mendekati 1 menunjukkan dua teks yang sangat mirip secara semantik, nilai 0 menunjukkan tidak adanya kemiripan, dan nilai mendekati -1 menunjukkan makna yang berlawanan.

Apabila kedua vektor telah dinormalisasi terlebih dahulu menjadi vektor satuan (*unit vector*) melalui normalisasi L2, maka *cosine similarity* setara dengan operasi *dot product* biasa [?]. Normalisasi L2 dilakukan dengan membagi setiap vektor dengan norma L2-nya:

$$\hat{\mathbf{v}} = \frac{\mathbf{v}}{|\mathbf{v}|} = \frac{\mathbf{v}}{\sqrt{\sum_{i=1}^N v_i^2}} \quad (2-2)$$

Setelah normalisasi, $|\hat{\mathbf{v}}| = |\hat{\mathbf{w}}| = 1$, sehingga penyebut pada Persamaan ?? bernilai 1 dan *cosine similarity* menjadi:

$$\text{cosine}(\hat{\mathbf{v}}, \hat{\mathbf{w}}) = \hat{\mathbf{v}} \cdot \hat{\mathbf{w}} = \sum_{i=1}^N \hat{v}_i \hat{w}_i \quad (2-3)$$

Penyetaraan ini memiliki implikasi penting dari sisi efisiensi komputasi: *dot product* jauh lebih cepat dihitung dibanding *cosine similarity* yang memerlukan operasi pembagian, sehingga pada sistem *retrieval* berskala besar, normalisasi vektor dilakukan sekali di awal dan selanjutnya hanya *dot product* yang digunakan saat pencarian.

2.2.11 *Large Language Model*

Large Language Models (LLM) merupakan model *machine learning* dalam bidang *natural language processing* yang dirancang untuk memahami dan menghasilkan teks dengan mempelajari pola statistik dari data berskala besar. Secara umum, model bahasa bekerja dengan memprediksi kata berikutnya dalam suatu urutan serta menghasilkan distribusi probabilitas atas kemungkinan kata yang dapat muncul. Pendekatan ini memungkinkan model untuk mempelajari struktur linguistik, makna, serta hubungan kontekstual antar kata dari data pelatihan. Perkembangan LLM modern yang berbasis arsitektur *transformer* mampu menangkap konteks secara lebih luas dan kompleks [?].


Dengan kapasitas pengetahuan yang besar serta mekanisme pemrosesan yang kompleks, LLM mampu menjalankan berbagai tugas berbasis bahasa, seperti menghasilkan teks, merangkum dokumen, menjawab pertanyaan, menghasilkan kode program, hingga melakukan penalaran secara bertahap [?, ?]. Kemampuan ini memungkinkan LLM untuk diterapkan pada berbagai domain yang memerlukan pemahaman spesifik. Sebagai contoh, dalam bidang hukum, LLM dimanfaatkan untuk mendukung pekerjaan profesional, seperti penyusunan dokumen, analisis kontrak, serta proses uji tuntas yang umumnya memerlukan waktu dan tenaga yang signifikan [?].

2.2.12 *Prompt Engineering*

Tidak seperti *fine-tuning* yang membutuhkan *training* parameter model, *prompt engineering* berfokus pada penyusunan instruksi berbasis bahasa alami untuk menggunakan pengetahuan yang telah dipelajari oleh model *pre-trained* [?]. Tujuan utama dari teknik ini adalah mengontrol dan memberi arahan respons LLM secara spesifik, mengurangi ambiguitas konteks, serta menjaga relevansi jawaban tanpa perlu mengubah struktur maupun parameter model, sehingga dapat diterapkan pada berbagai kebutuhan domain spesifik [?, ?].

2.2.13 *Information Retrieval*

Information Retrieval (IR) merupakan bidang yang berfokus pada proses pencarian dan pengambilan berbagai jenis informasi berdasarkan kebutuhan pengguna, yang umumnya diimplementasikan dalam bentuk *search engine*. Salah satu tugas utama dalam IR adalah *ad hoc retrieval*, di mana pengguna mengajukan kueri dan sistem mengembalikan sekumpulan dokumen yang telah diurutkan berdasarkan relevansi dari suatu koleksi tertentu. Dalam konteks ini, dokumen merujuk pada unit teks yang diindeks dan diambil (seperti halaman *web*, artikel ilmiah, atau paragraf) serta koleksi adalah himpunan dokumen yang digunakan untuk memenuhi kebutuhan informasi.




Gambar 2.4. Arsitektur umum sistem information retrieval. Sumber: [?]

Arsitektur tingkat tinggi dari sistem *ad hoc retrieval* terdiri dari dua pendekatan utama berdasarkan representasi vektor yang digunakan, yaitu *sparse retrieval* dan *dense retrieval*. Pada *sparse retrieval*, dokumen dan kueri direpresentasikan sebagai vektor berbasis frekuensi kata (*count vectors*) yang umumnya diberi bobot menggunakan metode seperti TF-IDF atau BM25. Sementara itu, pada *dense retrieval*, dokumen dan kueri direpresentasikan dalam bentuk *embedding* yang dihasilkan oleh model bahasa (baik *encoder* maupun *decoder*), sehingga mampu menangkap hubungan semantik yang lebih kompleks [?].

2.2.14 Retrieval-Augmented Generation

Retrieval-Augmented Generation (RAG) merupakan metode yang mengintegrasikan teknik *information retrieval* (IR) ke dalam *language model* untuk meningkatkan kualitas jawaban yang dihasilkan. Dalam skenario dasar RAG, sistem terlebih dahulu mengambil dokumen yang relevan dari suatu basis pengetahuan menggunakan teknik *retrieval*, kemudian memanfaatkan *large language model* (LLM) untuk menghasilkan jawaban berdasarkan dokumen tersebut serta *query* pengguna [?]. Pendekatan ini memiliki beberapa tujuan utama, antara lain mengurangi halusinasi dengan menyediakan sumber informasi yang tepercaya, memungkinkan pemanfaatan data spesifik atau privat (seperti dokumen internal, rekam medis, atau *email*), serta mengatasi keterbatasan pengetahuan model yang bersifat statis dan tidak selalu mutakhir.



Gambar 2.5. Arsitektur Retrieval-Augmented Generation. Sumber: [?]

Secara arsitektural, RAG terdiri dari dua komponen utama, yaitu *retriever* yang bertugas mengindeks dan mengambil data relevan (biasanya dalam bentuk vektor), serta *generator* (LLM) yang memanfaatkan konteks tersebut untuk menghasilkan respons yang koheren dan berbasis fakta, sehingga meningkatkan keandalan dan mengurangi risiko halusinasi [?].

2.2.15 Metrik Evaluasi

Evaluasi performa sistem *Retrieval-Augmented Generation* (RAG) memerlukan metrik yang mampu mengukur kualitas hasil *retrieval* serta efektivitas peringkat dokumen relevan, sekaligus mempertimbangkan efisiensi sistem dari sisi komputasi. Oleh karena itu, digunakan beberapa metrik evaluasi standar yang mencakup aspek keberhasilan *retrieval*, kualitas pemeringkatan dokumen, serta efisiensi waktu respons sistem. Berikut adalah metrik-metrik yang digunakan:

1. Hit@k

Hit@k digunakan untuk mengukur apakah setidaknya satu dokumen relevan muncul dalam top- k hasil *retrieval*. Metrik ini bersifat biner (*hit* atau tidak), sehingga sering digunakan untuk mengevaluasi keberhasilan minimum sistem dalam menemukan jawaban yang benar.

$$\text{Hit@}k = \frac{\text{Jumlah query dengan } \geq 1 \text{ dokumen relevan di top-}k}{\text{Total query}} \quad (2-4)$$

dengan:

- *Query* dengan ≥ 1 dokumen relevan: jumlah *query* yang memiliki minimal satu hasil relevan dalam top- k
- Total *query*: jumlah seluruh *query* yang diuji

2. Recall@k

Recall@k digunakan untuk mengukur kemampuan sistem dalam menemukan dokumen relevan dalam sejumlah top- k hasil *retrieval*. Metrik ini berfokus pada *coverage*, yaitu seberapa banyak dokumen relevan yang berhasil ditemukan dibandingkan dengan seluruh dokumen relevan yang tersedia. Recall@k sangat penting dalam konteks RAG karena menentukan apakah informasi yang dibutuhkan sudah masuk ke dalam kandidat awal sebelum tahap generasi.

$$\text{Recall@}k = \frac{\text{Total dokumen relevan}}{\text{Jumlah dokumen relevan dalam top-}k} \quad (2-5)$$

dengan:

- Total dokumen relevan: seluruh dokumen yang seharusnya relevan dalam *corpus*
- Dokumen relevan dalam top- k : jumlah dokumen relevan yang berhasil ditemukan dalam k teratas

3. Mean Average Precision (MAP@k)

Mean Average Precision (MAP@k) digunakan untuk mengukur kualitas peringkat dengan mempertimbangkan posisi seluruh dokumen relevan yang berhasil ditemukan dalam top- k hasil *retrieval*. MAP@k menghitung rata-rata *precision* pada setiap posisi di mana dokumen relevan ditemukan, kemudian dinormalisasi terhadap jumlah total *ground truth*. Metrik ini bersifat *rank-sensitive* karena memberikan bobot lebih tinggi pada dokumen relevan yang ditemukan di posisi atas. Semakin tinggi nilai MAP@k, maka semakin baik kemampuan sistem dalam menempatkan dokumen relevan pada posisi peringkat yang lebih tinggi.

$$\text{MAP@}k = \frac{1}{|G|} \sum_{i=1}^k P(i) \cdot \text{rel}(i) \quad (2-6)$$

dengan:

- $|G|$ = jumlah total dokumen relevan (*ground truth*)
- $P(i)$ = *precision* pada posisi ke- i , yaitu $\frac{\text{jumlah dokumen relevan dalam top-}i}{i}$
- $\text{rel}(i) = 1$ jika dokumen pada posisi ke- i relevan, 0 jika tidak

4. Normalized Discounted Cumulative Gain (NDCG)

nDCG digunakan untuk mengevaluasi kualitas *ranking* dengan mempertimbangkan posisi dan tingkat relevansi dokumen. Dokumen yang relevan pada posisi lebih atas akan memberikan kontribusi nilai yang lebih tinggi. Metrik ini cocok untuk skenario di mana relevansi tidak bersifat biner.

$$\text{NDCG@}k = \frac{\text{DCG@}k}{\text{IDCG@}k} \quad (2-7)$$

$$\text{DCG@}k = \sum_{i=1}^k \frac{2^{\text{rel}_i} - 1}{\log_2(i + 1)} \quad (2-8)$$

$$\text{IDCG@}k = \sum_{i=1}^k \frac{2^{\text{rel}_{ideal,i}} - 1}{\log_2(i + 1)} \quad (2-9)$$

dengan:

- $\text{DCG@}k$: *Discounted Cumulative Gain*, yaitu akumulasi skor relevansi dengan pembobotan posisi

- $IDCG@k$: nilai DCG ideal (*ranking* terbaik)
- rel_i : skor relevansi bertingkat dari dokumen pada posisi i
- Faktor diskonto logaritmik $\log_2(i + 1)$ digunakan untuk memberi penalti pada dokumen yang berada di peringkat lebih rendah

5. Latensi Waktu

Evaluasi sistem ketepatan *Information Retrieval* pemilihan dokumen pada *Information Retrieval* tidak hanya berfokus pada kualitas hasil (akurasi dan relevansi), tetapi juga pada efisiensi waktu pemrosesan. Oleh karena itu, metrik latensi digunakan untuk mengukur waktu yang dibutuhkan sistem dalam memproses satu *query* hingga menentukan dokumen yang relevan. Latensi menjadi penting terutama pada sistem yang melibatkan beberapa tahapan seperti *hybrid retrieval*, dan *reranking*, karena setiap komponen tambahan berpotensi meningkatkan waktu eksekusi.

$$\text{Latensi}_{\text{Total}} = t_{\text{retrieval}} + t_{\text{rerank}} \quad (2-10)$$

dengan:

- $t_{\text{retrieval}}$ = waktu untuk mengambil kandidat dokumen dari basis pengetahuan
- t_{rerank} = waktu untuk melakukan pengurutan ulang hasil menggunakan *reranker*

2.2.16 Sparse Retrieval Model

Sparse retrieval merupakan pendekatan pencarian dokumen yang merepresentasikan teks sebagai vektor berdimensi tinggi dengan sebagian besar elemen bernilai nol (*sparse vector*). Setiap dimensi pada vektor tersebut berkorespondensi dengan satu *term* atau kata dalam kosakata, sehingga pencocokan dilakukan berdasarkan keberadaan dan frekuensi istilah secara eksplisit. Berikut diuraikan empat metode *sparse retrieval* yang relevan dalam konteks *hybrid retrieval*.

BM25 (*Best Matching 25*). BM25 merupakan fungsi pemeringkatan berbasis model probabilistik yang dikembangkan oleh Robertson dan Zaragoza [?]. BM25 menghitung skor relevansi antara kueri dan dokumen berdasarkan tiga komponen utama: frekuensi istilah (*term frequency*, TF), frekuensi dokumen terbalik (*inverse document frequency*, IDF), serta normalisasi panjang dokumen. Skor BM25 untuk suatu kueri Q yang memuat istilah-istilah $q_1, q_2, \dots, q_n$ terhadap dokumen D dihitung dengan rumus berikut.

$$\text{BM25}(D, Q) = \sum_{i=1}^n \text{IDF}(q_i) \cdot \frac{f(q_i, D) \cdot (k_1 + 1)}{f(q_i, D) + k_1 \cdot (1 - b + b \cdot \frac{|D|}{\text{avgdl}})} \quad (2-11)$$

dengan $f(q_i, D)$ adalah frekuensi istilah q_i pada dokumen D , $|D|$ adalah panjang dokumen, avgdl adalah rata-rata panjang dokumen, k_1 mengatur pengaruh frekuensi istilah, dan b mengontrol derajat normalisasi panjang dokumen ($b = 0$ berarti tanpa normalisasi, $b = 1$ berarti normalisasi penuh). Nilai IDF didefinisikan sebagai $\text{IDF}(q_i) = \ln \left(\frac{N - n(q_i) + 0,5}{n(q_i) + 0,5} \right)$, di mana N adalah jumlah total dokumen dan $n(q_i)$ adalah jumlah dokumen yang mengandung istilah q_i .

SPLADE (Sparse Lexical And Expansion). SPLADE merupakan model *sparse retrieval* berbasis *Transformer* yang menghasilkan representasi vektor *sparse* melalui mekanisme ekspansi kosakata [?]. Berbeda dengan BM25 yang hanya mengandung istilah yang secara eksplisit muncul dalam teks, SPLADE mampu menambahkan istilah-istilah baru yang secara semantik relevan namun tidak muncul secara leksikal dalam dokumen atau kueri. Proses ini dilakukan melalui lapisan *masking* pada *logits* keluaran *Transformer* yang kemudian diaktivasi menggunakan fungsi ReLU atau *soft thresholding*, menghasilkan vektor *sparse* yang lebih informatif namun tetap bersifat *interpretable*.

TF-IDF (Term Frequency–Inverse Document Frequency). TF-IDF merupakan metode pembobotan klasik yang mengalikan frekuensi istilah (TF) dengan nilai IDF [?]. TF mengukur seberapa sering suatu istilah muncul dalam dokumen, sedangkan IDF memberikan bobot lebih tinggi pada istilah yang jarang muncul di seluruh koleksi. TF-IDF tidak memiliki mekanisme normalisasi panjang dokumen bawaan seperti BM25, sehingga umumnya digunakan sebagai *baseline* yang lebih sederhana [?].

BM25L dan BM25+. BM25L dan BM25+ merupakan varian BM25 yang dirancang untuk memperbaiki normalisasi frekuensi istilah [?]. BM25L mengurangi bias terhadap dokumen panjang dengan menambahkan konstanta pada frekuensi istilah ternormalisasi, sementara BM25+ memperbaiki perhitungan IDF dengan menambahkan term δ pada komponen frekuensi istilah sehingga istilah yang muncul pada dokumen panjang tidak mendapat penalti berlebihan. Kedua varian ini lebih jarang digunakan sebagai konfigurasi standar dibanding BM25 dan membutuhkan penyesuaian tambahan terhadap parameter normalisasi.

2.2.17 Dense Embedding Model

Dense retrieval menggunakan model *sentence embedding* untuk memproyeksikan teks ke dalam ruang vektor berdimensi tetap di mana setiap dimensi menyimpan informasi semantik secara padat. Berbeda dengan vektor *sparse* yang

sebagian besar bernilai nol, vektor *dense* berdimensi rendah (umumnya 384–1024) namun seluruh elemennya menyandikan makna kontekstual. Berikut diuraikan model-model *dense embedding* yang relevan.

Paraphrase-multilingual-MiniLM-L12-v2. Model ini merupakan varian *Sentence-BERT* (SBERT) [?] yang menggunakan arsitektur MiniLM [?] dengan 12 lapisan *transformer*. MiniLM merupakan model yang diperoleh melalui proses *knowledge distillation* dari model yang lebih besar, sehingga menghasilkan representasi semantik yang efektif dengan jumlah parameter yang lebih sedikit. Model ini mendukung lebih dari 50 bahasa dan menghasilkan *embedding* berdimensi 384, menjadikannya efisien secara komputasi untuk tugas *retrieval* berskala besar.

Paraphrase-multilingual-mpnet-base-v2. Model ini menggunakan arsitektur MPNet yang menggabungkan kelebihan *Masked Language Model* (MLM) dan *Permutation Language Model* (PLM) untuk menghasilkan representasi semantik yang lebih kaya. Dengan 768 dimensi dan dukungan lebih dari 50 bahasa, model ini memiliki kapasitas representasi yang lebih besar dibanding MiniLM, namun dengan peningkatan biaya komputasi yang signifikan.

BGE-M3. BGE-M3 [?] merupakan model *embedding* multilingual yang mendukung tiga fungsionalitas *retrieval* sekaligus dalam satu arsitektur: *dense retrieval*, *sparse retrieval*, dan *multi-vector retrieval*. Model ini mendukung lebih dari 100 bahasa dan panjang dokumen hingga 8.192 *token*, dengan dimensi keluaran sebesar 1024. Kemampuan *multi-functionality* ini menjadikannya fleksibel, namun dimensi yang besar berdampak pada biaya komputasi yang lebih tinggi.

IndoBERT. IndoBERT merupakan model bahasa yang dilatih khusus pada korpus berbahasa Indonesia. Model ini dirancang untuk menangkap struktur linguistik Bahasa Indonesia secara lebih mendalam dibanding model multilingual umum, dengan dimensi representasi sebesar 768.

2.2.18 *Reranker Model*

Komponen *reranking* berfungsi untuk mengevaluasi ulang kandidat dokumen yang diperoleh dari tahap *retrieval* awal guna meningkatkan kualitas peringkat. Terdapat tiga arsitektur utama yang digunakan dalam model *reranking*.

Cross-Encoder. Model *cross-encoder* menerima pasangan teks (*query* dan dokumen) secara simultan sebagai masukan ke dalam satu arsitektur *Transformer* [?]. Berbeda dengan *bi-encoder* yang menghitung *embedding* secara terpisah, *cross-encoder* memproses interaksi antar kata dari kedua teks melalui mekanisme *self-attention*, sehingga mampu menangkap hubungan kontekstual yang lebih mendalam. Kelebihan utamanya adalah akurasi penilaian relevansi yang lebih tinggi, namun kelemahannya

adalah tidak dapat diindeks secara sebelumnya (*pre-index*) sehingga setiap pasangan kueri–dokumen harus diproses secara individual, yang mengakibatkan biaya komputasi yang tinggi.

Late Interaction (ColBERT). ColBERT [?] menggunakan arsitektur *late interaction* yang menghitung *embedding* kueri dan dokumen secara terpisah, kemudian mengukur kemiripan melalui mekanisme *MaxSim*. Pendekatan ini menawarkan keseimbangan antara kualitas *cross-encoder* dan efisiensi *bi-encoder*, karena representasi dokumen dapat diindeks sebelumnya. Namun, implementasinya membutuhkan setup indeks khusus dan cenderung lebih kompleks.

Varian Cross-Encoder. Dalam keluarga model BAAI BGE, terdapat beberapa varian *cross-encoder* reranker yang dapat digunakan. BAAI/bge-reranker-base merupakan model *cross-encoder* monolingual yang terbukti efektif pada domain regulasi. BAAI/bge-reranker-v2-m3 merupakan pengembangan dari *base* dengan tambahan kemampuan multibahasa yang mendukung lebih dari 100 bahasa. Model *cross-encoder/ms-marco-MiniLM-L-6-v2* menggunakan arsitektur MiniLM yang sangat ringan namun bersifat monolingual Bahasa Inggris. Jina Reranker v2 menawarkan dukungan multilingual dengan *context window* yang lebih panjang.

2.2.19 Uji Signifikansi Statistik

Evaluasi performa sistem *Information Retrieval* tidak hanya memerlukan perbandingan nilai metrik secara deskriptif, tetapi juga memerlukan pembuktian statistik untuk menentukan apakah perbedaan performa antar konfigurasi bersifat signifikan atau hanya terjadi karena variasi acak [?]. Pada penelitian ini, digunakan uji non-parametrik Friedman karena data evaluasi tidak memenuhi asumsi normalitas dan terdiri dari beberapa kelompok perlakuan yang diukur pada subjek atau *query* yang sama. Uji Friedman merupakan metode statistik non-parametrik untuk data berpasangan yang melibatkan lebih dari dua kelompok, sehingga cocok digunakan pada skenario di mana satu set *query* yang identik dievaluasi pada beberapa konfigurasi sistem.

Penggunaan uji signifikansi dalam evaluasi *retrieval* sangat penting karena perbedaan metrik yang terlihat secara deskriptif tidak selalu mengindikasikan adanya perbedaan yang bermakna secara statistik. Tanpa uji signifikansi, kesimpulan yang diambil hanya bersifat observasional dan rentan terhadap bias sampling. Selain itu, uji Friedman memungkinkan penentuan apakah konfigurasi tertentu secara konsisten mengungguli konfigurasi lain pada mayoritas *query*, bukan hanya unggul pada beberapa *query* tertentu. Jika hasil uji Friedman menunjukkan signifikansi, maka dapat disimpulkan bahwa minimal terdapat satu konfigurasi yang berbeda secara signifikan dari konfigurasi lainnya.

Uji Friedman dihitung berdasarkan peringkat (*ranking*) nilai metrik dari setiap

query pada masing-masing kelompok perlakuan, dengan rumus sebagai berikut:

$$\chi_F^2 = \frac{12N}{k(k+1)} \sum_{j=1}^k R_j^2 - 3N(k+1) \quad (2-12)$$

dengan:

- N = jumlah *query* yang dievaluasi (jumlah *block*/subjek)
- k = jumlah kelompok perlakuan atau konfigurasi yang dibandingkan
- R_j = jumlah peringkat (*rank sum*) pada kelompok perlakuan ke- j
- χ_F^2 = statistik uji Friedman yang mendekati distribusi χ^2 dengan derajat kebebasan $df = k - 1$

Statistik uji χ_F^2 dibandingkan dengan nilai kritis distribusi χ^2 pada tingkat signifikansi $\alpha = 0,05$. Jika nilai χ_F^2 lebih besar dari nilai kritis, maka $p\text{-value} < 0,05$ dan hipotesis nol (H_0 : tidak ada perbedaan signifikan antar kelompok) ditolak, sehingga disimpulkan bahwa minimal terdapat satu kelompok yang berbeda secara signifikan. Sebaliknya, jika $p\text{-value} \geq 0,05$, maka H_0 gagal ditolak dan tidak terdapat cukup bukti statistik untuk menyatakan adanya perbedaan antar kelompok.

2.3 Analisis Perbandingan Metode

Bagian ini menyajikan analisis komparatif terhadap metode dan model yang relevan untuk komponen *hybrid retrieval* dan *reranking*. Perbandingan dilakukan berdasarkan bukti empiris dari literatur untuk memberikan justifikasi terhadap pemilihan komponen yang digunakan pada penelitian ini.

2.3.1 Perbandingan Metode *Sparse Retrieval*

Untuk komponen *sparse retrieval*, terdapat beberapa alternatif metode yang dapat digunakan, antara lain BM25, SPLADE, TF-IDF, serta varian BM25 seperti BM25L dan BM25+. Metode yang dipilih disajikan pada Tabel ??, sedangkan alternatif lainnya disajikan pada Tabel ??.

Tabel 2.11. Metode *Sparse Retrieval* yang Dipilih

Metode	Kelebihan	Kekurangan
BM25 (<i>dipilih</i>)	Model leksikal yang kuat untuk pencocokan istilah eksplisit dan menjadi dasar umum dalam <i>ad-hoc retrieval</i> [?]; pada studi hukum pajak, BM25 dipilih karena mengungguli SPLADE [?]; pada studi RAG klinis, BM25 Retriever mengungguli Dense Passage Retriever pada seluruh metrik evaluasi [?]	Tidak menangkap hubungan semantik secara langsung karena berbasis pencocokan istilah; sensitif terhadap variasi kata, sinonim, dan parafrasa
SPLADE	Menghasilkan representasi <i>sparse</i> berbasis Transformer dan ekspansi kosakata sehingga dapat menangkap kecocokan leksikal yang lebih kaya dibanding pencocokan kata kunci murni [?]	Lebih kompleks secara komputasi dibanding BM25 karena membutuhkan model neural untuk menghasilkan representasi <i>sparse</i> ; pada studi hukum pajak, SPLADE tidak mengungguli BM25 [?]

Tabel 2.12. Perbandingan Metode *Sparse Retrieval* Alternatif

Metode	Kelebihan	Kekurangan
TF-IDF	Metode pembobotan leksikal klasik yang sederhana, ringan, dan banyak digunakan sebagai dasar pemeringkatan dokumen [?]	Tidak memiliki normalisasi panjang dokumen dan formulasi probabilistik seperti BM25, sehingga umumnya digunakan sebagai <i>baseline</i> yang lebih sederhana dibanding BM25 [?]
BM25L / BM25+	Varian BM25 yang dirancang untuk memperbaiki normalisasi frekuensi istilah dan mengurangi bias terhadap panjang dokumen [?]	Lebih jarang digunakan sebagai konfigurasi standar dibanding BM25 dan membutuhkan penyesuaian tambahan terhadap parameter normalisasi [?]

Berdasarkan perbandingan pada Tabel ?? dan Tabel ??, BM25 merupakan pilihan yang paling sesuai sebagai komponen *sparse retrieval*. Pada studi sistem tanya jawab hukum perpajakan, Rustamov et al. [?] secara eksplisit menunjukkan bahwa BM25 mengungguli SPLADE sehingga dipilih sebagai komponen *sparse* dalam strategi

hybrid retrieval. Hiremath et al. [?] mengonfirmasi superioritas BM25 dalam sistem RAG klinis. Meskipun demikian, SPLADE tetap menjadi alternatif yang menarik karena kemampuannya menangkap kecocokan leksikal yang lebih kaya melalui ekspansi kosakata berbasis *Transformer* [?], namun kompleksitas komputasinya lebih tinggi dan tidak terbukti mengungguli BM25 pada domain regulasi [?]. TF-IDF tidak dipilih karena tidak memiliki normalisasi panjang dokumen dan formulasi probabilistik seperti BM25, sehingga umumnya hanya digunakan sebagai *baseline* yang lebih sederhana [?, ?]. Varian BM25L dan BM25+ memang menawarkan normalisasi frekuensi istilah yang lebih baik untuk dokumen dengan variasi panjang [?], namun keduanya lebih jarang digunakan sebagai konfigurasi standar dibanding BM25 dan membutuhkan penyesuaian tambahan terhadap parameter normalisasi. Keunggulan BM25 pada domain regulasi dapat dijelaskan oleh karakteristik terminologi yang eksplisit dan konsisten pada kontrol ISO/IEC 27001:2022, misalnya *access control*, *incident management*, dan *logging*. Karakteristik tersebut memungkinkan pencocokan leksikal bekerja secara efektif, sehingga ketersediaan implementasi BM25 yang luas dan stabilitasnya pada berbagai *benchmark* menjadikannya pilihan yang paling tepat.

2.3.2 Perbandingan Model *Dense Embedding*

Untuk komponen *dense retrieval*, terdapat beberapa alternatif model *sentence embedding* yang dapat digunakan, antara lain paraphrase-multilingual-MiniLM-L12-v2, paraphrase-multilingual-mpnet-base-v2, all-MiniLM-L6-v2, BGE-M3, Jina Embeddings v2, serta IndoBERT. Perbandingan antara model-model tersebut disajikan pada Tabel ?? dan Tabel ??.

Tabel 2.13. Perbandingan Model *Dense Embedding*

Model	Kelebihan	Kekurangan
paraphrase-multilingual-MiniLM-L12-v2 Dim: 384, Bahasa: 50+	Model multilingual ringan yang cocok untuk <i>query</i> berbahasa Indonesia; arsitektur MiniLM terbukti menghasilkan representasi semantik yang efektif untuk tugas <i>information retrieval</i> [?]; pada arsitektur <i>hybrid retrieval</i> , model MiniLM secara konsisten meningkatkan kualitas <i>dense retrieval</i> [?]	Dimensi representasi lebih kecil dibanding MPNet (384 vs 768), sehingga kapasitas representasi lebih terbatas; pada domain berbahasa Indonesia, performa semantiknya sedikit di bawah mpnet-base-v2 [?]
paraphrase-multilingual-mpnet-base-v2 Dim: 768, Bahasa: 50+	Menghasilkan representasi semantik yang lebih kaya dengan dimensi 768; pada studi <i>retrieval</i> berbahasa Indonesia untuk data medis, MPNet mengungguli MiniLM-L12-v2, IndoBERT, dan multilingual BERT [?]	Dimensi dua kali lebih besar dari MiniLM-L12-v2 sehingga meningkatkan latensi dan kebutuhan memori secara signifikan; kurang efisien untuk tahap <i>retrieval</i> pada skenario dengan keterbatasan komputasi
all-MiniLM-L6-v2 Dim: 384, Bahasa: Inggris	Arsitektur MiniLM yang lebih ringan dengan 6 lapisan <i>transformer</i> ; menghasilkan performa yang efektif pada tugas pencarian semantik [?]; lebih cepat dibanding MiniLM-L12-v2	Monolingual (Bahasa Inggris) sehingga tidak dapat memproses <i>query</i> berbahasa Indonesia yang merupakan bahasa utama pada dokumen kontrol ISO dalam penelitian ini
BGE-M3 Dim: 1024, Bahasa: 100+	Model <i>state-of-the-art</i> multilingual yang mendukung tiga fungsionalitas <i>retrieval</i> sekaligus, yaitu <i>dense</i> , <i>sparse</i> , dan <i>multi-vector retrieval</i> dalam satu arsitektur [?]; mendukung lebih dari 100 bahasa dan dokumen hingga 8.192 <i>token</i>	Dimensi sangat besar (1024) sehingga biaya komputasi tinggi; kemampuan <i>multi-functionality</i> merupakan kelebihan yang tidak sepenuhnya dibutuhkan pada tahap <i>retrieval</i> pertama; lebih cocok digunakan sebagai <i>reranker</i> [?]

Tabel 2.14. Perbandingan Model *Dense Embedding* (lanjutan)

Model	Kelebihan	Kekurangan
Jina Embeddings v2 Dim: 768, Bahasa: Multi	Digunakan dalam kombinasi dengan MS-MiniLM pada studi <i>ablation</i> pada domain tanya jawab keuangan dan menghasilkan performa yang baik [?]	Model yang relatif lebih baru sehingga bukti empiris pada domain regulasi berbahasa Indonesia masih terbatas; representasi 768-dim menambah beban komputasi dibanding MiniLM-L12-v2
IndoBERT Dim: 768, Bahasa: Indonesia	Dirancang khusus untuk Bahasa Indonesia sehingga secara teori paling sesuai untuk dokumen kontrol ISO dalam Bahasa Indonesia	Pada studi <i>retrieval</i> berbahasa Indonesia, IndoBERT justru menghasilkan performa di bawah MiniLM-L12-v2 dan MPNet [?]; tidak mendukung multilingual untuk potensi penggunaan internasional

Berdasarkan perbandingan pada Tabel ?? dan Tabel ??, paraphrase-multilingual-MiniLM-L12-v2 merupakan pilihan yang paling sesuai sebagai komponen *dense embedding*. Ravishankar dan Varalakshmi [?] mengonfirmasi bahwa model MiniLM dalam arsitektur *hybrid retrieval* secara konsisten meningkatkan kualitas *dense retrieval* pada domain tanya jawab berbasis dokumen keuangan. Model paraphrase-multilingual-mpnet-base-v2 memang menghasilkan representasi semantik yang lebih kaya dan terbukti mengungguli MiniLM-L12-v2 pada studi *retrieval* data medis berbahasa Indonesia [?], namun dimensi yang dua kali lebih besar (768 vs 384) berdampak pada peningkatan latensi secara signifikan sehingga kurang efisien untuk tahap *retrieval* pertama. Model all-MiniLM-L6-v2 tidak dipilih karena bersifat monolingual Bahasa Inggris [?] dan tidak dapat memproses *query* berbahasa Indonesia. BGE-M3 menawarkan kemampuan *multi-functionality* yang canggih [?], namun dimensi yang sangat besar (1024) menjadikannya kurang efisien untuk tahap *retrieval* pertama dan lebih cocok sebagai *reranker* [?]. Jina Embeddings v2 menunjukkan performa yang baik pada studi *ablation* [?], namun bukti empirisnya pada domain regulasi berbahasa Indonesia masih terbatas. IndoBERT yang dirancang khusus untuk Bahasa Indonesia justru menghasilkan performa di bawah MiniLM-L12-v2 dan MPNet [?]. Dengan mempertimbangkan keseimbangan antara kualitas representasi semantik, dukungan multilingual untuk *query* berbahasa Indonesia, dan efisiensi komputasi, paraphrase-multilingual-MiniLM-L12-v2 merupakan pilihan yang paling pragmatis dan sesuai.

2.3.3 Perbandingan Model *Reranker*

Untuk komponen *reranking*, terdapat beberapa alternatif model yang dapat digunakan, antara lain BAAI/bge-reranker-v2-m3, BAAI/bge-reranker-base, cross-encoder/ms-marco-MiniLM-L-6-v2, Jina Reranker v2, serta ColBERT v2. Perbandingan antara model-model tersebut disajikan pada Tabel ??.

Tabel 2.15. Perbandingan Model *Reranker*

Model	Kelebihan	Kekurangan
BAAI/bge-reranker-v2-m3 Tipe: <i>Cross-encoder</i> multilingual	Model <i>cross-encoder</i> multilingual yang mendukung lebih dari 100 bahasa; versi m3 merupakan pengembangan dari bge-reranker-base dengan tambahan kemampuan multibahasa; pada domain regulasi hukum pajak, model BGE reranker terbukti meningkatkan skor NDCG dari 0,39 menjadi 0,44 [?]	Paling berat di antara reranker alternatif; biaya komputasi dan latensi lebih tinggi dibanding model reranker yang lebih ringan
BAAI/bge-reranker-base Tipe: <i>Cross-encoder</i>	Digunakan secara eksplisit pada studi hukum perpajakan dan terbukti meningkatkan NDCG secara signifikan [?]; lebih ringan dibanding v2-m3; bukti empiris kuat pada domain regulasi	Dukungan bahasa terbatas atau monolingual sehingga tidak optimal untuk <i>query</i> berbahasa Indonesia
cross-encoder/ms-marco-MiniLM-L-6-v2 Tipe: <i>Cross-encoder</i>	Sangat ringan dengan latensi rendah; cocok untuk deployment <i>production</i> ; arsitektur MiniLM yang efisien [?]	Monolingual Bahasa Inggris sehingga tidak dapat menangani <i>query</i> berbahasa Indonesia; performa lebih rendah dibanding seri BGE reranker
Jina Reranker v2 Tipe: <i>Cross-encoder</i> multilingual	Multilingual dengan <i>context window</i> lebih panjang; performa kompetitif dengan BGE pada beberapa <i>benchmark</i>	Model yang relatif lebih baru sehingga dokumentasi dan bukti empiris pada domain regulasi berbahasa Indonesia masih terbatas
ColBERT v2 Tipe: <i>Late interaction</i>	Arsitektur <i>late interaction</i> yang lebih efisien untuk skala besar dibanding <i>cross-encoder</i> murni; kecepatan pemrosesan <i>query</i> lebih tinggi [?]	Implementasi lebih kompleks dan membutuhkan setup indeks khusus; bukan pendekatan <i>plug-and-play</i> seperti <i>cross-encoder</i> ; bukti empiris pada domain regulasi berbahasa Indonesia belum tersedia

Berdasarkan perbandingan pada Tabel ??, BAAI/bge-reranker-v2-m3 merupakan pilihan yang paling sesuai sebagai model *reranker*. Rustamov et al. [?] secara eksplisit menerapkan *cross-encoder reranking* menggunakan model BGE reranker-base pada domain hukum perpajakan dan menemukan peningkatan signifikan pada skor NDCG dari 0,39 menjadi 0,44. Elkiran dan Rasheed [?] menjelaskan bahwa model BGE sebagai *cross-encoder* menerima pasangan *query*–dokumen secara langsung sebagai masukan dan menghasilkan skor kemiripan tanpa melalui representasi vektor perantara, sehingga menghasilkan penilaian relevansi yang lebih akurat meskipun dengan biaya komputasi yang lebih tinggi. Model bge-reranker-base memang telah terbukti efektif pada domain regulasi, namun dukungan bahasanya terbatas sehingga tidak optimal untuk *query* berbahasa Indonesia. Model bge-reranker-v2-m3 yang digunakan pada penelitian ini merupakan pengembangan dari bge-reranker-base dengan tambahan kemampuan multibahasa yang esensial untuk menangani *query* berbahasa Indonesia. Model *cross-encoder/ms-marco-MiniLM-L-6-v2* tidak dipilih karena bersifat monolingual Bahasa Inggris sehingga tidak dapat memproses *query* berbahasa Indonesia. Jina Reranker v2 menawarkan dukungan multilingual dengan *context window* yang lebih panjang, namun sebagai model yang relatif baru, bukti empirisnya pada domain regulasi berbahasa Indonesia masih terbatas. ColBERT v2 menggunakan arsitektur *late interaction* yang lebih efisien untuk skala besar [?], namun implementasinya lebih kompleks dan membutuhkan setup indeks khusus yang tidak sesuai dengan kebutuhan *plug-and-play* pada penelitian ini. Dengan mempertimbangkan bukti empiris pada domain regulasi, dukungan multilingual, dan kemudahan implementasi, BAAI/bge-reranker-v2-m3 merupakan pilihan yang paling tepat.

2.3.4 Perbandingan Komponen Metode RAG

Tabel 2.16. Perbandingan Komponen Metode RAG [?, ?, ?, ?, ?]

Metode	Kelebihan	Kekurangan
<i>Hybrid Retrieval</i>	• Menggabungkan pendekatan leksikal dan semantik sehingga meningkatkan cakupan dokumen relevan (Recall@100: 0,49 → 0,60; +11%) [?]. • Meningkatkan <i>coverage</i> dibanding metode <i>dense</i> tunggal [?]. • Lebih <i>robust</i> terhadap variasi <i>query</i> melalui pendekatan <i>multi-path retrieval</i> [?].	• Kompleksitas implementasi lebih tinggi karena melibatkan beberapa komponen <i>retrieval</i> dan mekanisme <i>score fusion</i> [?, ?]. • Memerlukan penyesuaian parameter fusi skor (mis. α) [?]. • Kualitas peringkat awal belum optimal tanpa <i>reranking</i> (NDCG awal 0,39) [?].
<i>Reranking (Cross-Encoder)</i>	• Meningkatkan presisi dan kualitas hasil peringkat teratas (NDCG: 0,39 → 0,44) [?]. • Menghasilkan peringkat yang lebih relevan (R@1 = 0,687; MRR = 0,725) [?]. • Meningkatkan kualitas pada metrik tertentu seperti NDCG dan <i>correctness</i> [?, ?]. • Mengurangi hasil tidak relevan (<i>false positive</i> sebesar 6%) [?].	• Biaya komputasi lebih tinggi dibanding tahap <i>retrieval</i> awal [?, ?]. • Menambah latensi (2,76–3,12 detik pada <i>reranker</i>) [?]. • Kurang efisien untuk jumlah kandidat besar karena keterbatasan skala pada <i>cross-encoder</i> [?].
Kombinasi (+) <i>(Hybrid Retrieval + Reranking)</i>	• Mengoptimalkan <i>recall</i> dan <i>precision</i> secara simultan (Precision@10 = 98,2%) [?]. • Menunjukkan performa tinggi pada konfigurasi terbaik (<i>combined score</i> 0,9441) [?]. • Mengungguli konfigurasi parsial pada studi <i>ablation</i> (~21% peningkatan Hit dan ~30% peningkatan MRR dibanding <i>dense-only</i>) [?]. • Adaptif terhadap variasi <i>query</i> [?].	• Kompleksitas <i>pipeline</i> paling tinggi karena melibatkan beberapa tahap (<i>retrieval</i>, fusi, <i>reranking</i>, dan generasi) [?, ?]. • Latensi lebih tinggi dibanding metode tunggal (sekitar 3,4 detik) [?]. • Membutuhkan proses <i>tuning</i> yang lebih kompleks (top-<i>k</i>, <i>reranker</i>, parameter α) [?]. • Risiko penurunan efisiensi (<i>diminishing return</i>) [?, ?].

Berdasarkan analisis pada Tabel tersebut, pemilihan variasi metode dalam penelitian ini didasarkan pada pertimbangan terkait kontribusi masing-masing komponen dalam meningkatkan kualitas *retrieval* serta dampaknya terhadap efisiensi sistem:

1. *Hybrid retrieval* dipilih sebagai *baseline* karena mampu meningkatkan cakupan dokumen relevan melalui penggabungan pendekatan leksikal dan semantik. Namun, kontribusi relatif antara komponen *dense* dan *sparse* belum diketahui secara optimal untuk domain ISO/IEC 27001:2022. Oleh karena itu, penelitian ini memvariasikan proporsi pembobotan skor antara keduanya, yakni $\alpha_{\text{dense}} \in \{0,00; 0,25; 0,50; 0,75; 1,00\}$, untuk mengidentifikasi konfigurasi yang paling efektif.
2. *Reranking* berbasis *cross-encoder* digunakan untuk menyaring dan mengurutkan ulang kandidat dokumen sehingga dokumen yang paling relevan dapat berada pada posisi peringkat teratas. Karena efektivitas *reranking* sangat bergantung pada jumlah kandidat yang dikirim ke *reranker* (*candidate pool*), penelitian ini mengevaluasi variasi ukuran *candidate pool*, yakni 5, 10, 15, dan 20 dokumen, untuk mengidentifikasi konfigurasi yang memberikan keseimbangan terbaik antara kualitas peringkat dan efisiensi waktu.
3. Kombinasi *hybrid retrieval* dan *reranking* dianalisis untuk mengevaluasi apakah penggabungan kedua komponen dapat menghasilkan peningkatan performa secara sinergis atau justru menimbulkan *trade-off* terhadap kompleksitas dan latensi. Pada tahap ini, proporsi pembobotan skor akhir antara skor *hybrid retrieval* dan skor *reranker* (α_{hybrid} dan α_{reranker}) divariasikan untuk mengidentifikasi kombinasi yang paling optimal.

2.4 Hipotesis Penelitian

Berdasarkan tinjauan pustaka, analisis perbandingan metode, serta rumusan masalah yang telah ditetapkan, penelitian ini merumuskan hipotesis sebagai berikut. Setiap hipotesis mencakup hipotesis nol (H_0) dan hipotesis alternatif (H_1) yang akan diuji menggunakan uji statistik Friedman pada tingkat signifikansi $\alpha = 0,05$.

Hipotesis 1: Proporsi Pembobotan *Hybrid Retrieval*

H_0 : Tidak terdapat perbedaan performa yang signifikan antar konfigurasi proporsi pembobotan skor *dense* dan *sparse* pada metode *hybrid retrieval* dalam pemetaan kontrol SoA ISO/IEC 27001:2022.

H_1 : Terdapat perbedaan performa yang signifikan antar konfigurasi proporsi pembobotan skor *dense* dan *sparse* pada metode *hybrid retrieval*, dengan

konfigurasi seimbang menghasilkan performa terbaik berdasarkan mayoritas metrik evaluasi.

Hipotesis 2: Ukuran *Candidate Pool* pada *Reranking*

H_0 : Tidak terdapat perbedaan performa yang signifikan antar variasi ukuran *candidate pool* pada proses *reranking* untuk pemeringkatan kontrol SoA ISO/IEC 27001:2022.

H_1 : Terdapat perbedaan performa yang signifikan antar variasi ukuran *candidate pool*, dengan ukuran yang lebih kecil menghasilkan kualitas *reranking* yang lebih baik karena *reranker* memproses kandidat yang lebih terkurasi dari hasil *hybrid retrieval*.

Hipotesis 3: Kombinasi Pembobotan *Hybrid Retrieval* dan *Reranker*

H_0 : Tidak terdapat perbedaan performa yang signifikan antar konfigurasi proporsi pembobotan skor antara *hybrid retrieval* dan *reranker* dalam pemetaan kontrol SoA ISO/IEC 27001:2022.

H_1 : Terdapat perbedaan performa yang signifikan antar konfigurasi proporsi pembobotan, dan terdapat konfigurasi tertentu yang secara konsisten mengungguli konfigurasi lainnya berdasarkan mayoritas metrik evaluasi.

BAB III

METODE PENELITIAN

Bab ini menjelaskan metodologi penelitian yang digunakan dalam pengembangan dan evaluasi sistem *information retrieval* berbasis *hybrid retrieval* dan *cross-encoder reranking*. Pendekatan *hybrid retrieval* menggabungkan metode *dense* dan *sparse retrieval*, kemudian dikombinasikan dengan mekanisme *reranking* menggunakan *cross-encoder* melalui skema pembobotan (*alpha*) untuk mengoptimalkan relevansi hasil pencarian. Pembahasan dalam bab ini mencakup perancangan basis pengetahuan berbasis dokumen ISO/IEC 27001:2022, penyusunan *query* dari dokumen kebijakan Direktorat Teknologi Informasi (DTI) UGM untuk kebutuhan evaluasi, implementasi metode *retrieval* dan *reranking*, serta perancangan skenario pengujian berdasarkan variasi parameter penelitian.

3.1 Alat dan Bahan

3.1.1 Alat Tugas Akhir

Alat-alat yang digunakan pada penelitian ini berupa perangkat keras maupun perangkat lunak sebagai sarana pendukung. Perangkat keras dan lunak yang digunakan berfungsi untuk menulis kode, pengembangan sistem, melakukan pengujian, dan pengumpulan data.

1. Laptop Lenovo Ideapad Flex 5i dengan spesifikasi
 - CPU: 12th Gen Intel(R) Core(TM) i7-1255U (10 cores)
 - RAM: 16 GB (2x8GB DDR4 4267 MHz)
 - GPU: Intel(R) Iris(R) Xe Graphics (128 MB VRAM)
 - Penyimpanan: SSD 512 GB (INTEL SSDPEKNW512GZL)
 - OS: Windows 11 Home Single Language (Build 22631)
2. Model AI
 - *Embedding model*: paraphrase-multilingual-MiniLM-L12-v2 (384 *dimensions*, *multilingual* termasuk Bahasa Indonesia)
 - *Reranking model*: BAAI/bge-reranker-v2-m3 (*cross-encoder multilingual*)
3. Perangkat Lunak
 - Visual Studio Code sebagai *Integrated Development Environment* (IDE) yang digunakan untuk menulis kode program, melakukan *debugging*, serta mengelola proses pengembangan sistem.

- Python 3.11.5 sebagai bahasa pemrograman utama yang digunakan untuk mengimplementasikan seluruh komponen sistem.
- Git sebagai sistem kontrol versi yang digunakan untuk mengelola *source code* serta melakukan pelacakan perubahan selama pengembangan.

3.1.2 Bahan Tugas Akhir

Dalam proses pengembangan dan evaluasi sistem *Retrieval-Augmented Generation* (RAG), diperlukan beberapa bahan sebagai berikut:

1. Dokumen standar ISO/IEC 27001:2022 “INTERNATIONAL STANDARD ISO/IEC 27001 Third Edition 2022-10” sebagai sumber utama pengetahuan yang digunakan dalam proses *retrieval* dan pembentukan basis dokumen.
2. Dokumen kebijakan dari Direktorat Teknologi Informasi (DTI) UGM berbentuk surat edaran dan surat keputusan Rektor Universitas Gadjah Mada yang digunakan sebagai sumber penyusunan *query* dan *ground truth* untuk evaluasi sistem.

3.2 Metode yang Digunakan

3.2.1 Desain Penelitian

Desain penelitian disusun dengan menentukan variabel independen, dependen, dan kontrol agar proses pengujian dapat dilakukan secara sistematis dan terukur. Variabel independen mencakup tiga parameter utama yang dievaluasi secara berurutan: proporsi bobot *scoring* antara *dense* dan *sparse*, jumlah kandidat pada tahap *reranker*, serta proporsi bobot *scoring* antara *hybrid* dan *reranker*. Setiap parameter pada tahap berikutnya menggunakan konfigurasi optimal dari tahap sebelumnya sehingga pencarian parameter bersifat sekuensial, bukan kombinatorik. Variabel dependen digunakan untuk mengukur performa sistem berdasarkan akurasi *retrieval* dan waktu latensi. Sementara itu, variabel kontrol dijaga tetap konstan selama eksperimen untuk memastikan hasil pengujian lebih konsisten dan dapat dibandingkan secara objektif.

Tabel 3.1. Variabel Penelitian (Independen)

Jenis	Nama Variabel	Deskripsi	Indikator / Parameter
Independen	Proporsi bobot <i>scoring dense:sparse</i>	Rasio pembobotan skor <i>dense retrieval</i> dan <i>sparse retrieval</i> pada <i>hybrid retrieval</i>	$\alpha_{dense} \in \{0,0; 0,25; 0,5; 0,75; 1,0\}$
Independen	Jumlah kandidat	Banyaknya dokumen kandidat yang diproses oleh <i>cross-encoder reranker</i>	$k \in \{5; 10; 15; 20\}$
Independen	Proporsi bobot <i>scoring hybrid:reranker</i>	Rasio pembobotan skor <i>hybrid retrieval</i> dan skor <i>reranker</i> pada skor akhir	$\alpha_{reranker} \in \{0,0; 0,25; 0,5; 0,75; 1,0\}$

Tabel 3.2. Variabel Penelitian (Dependen dan Kontrol)

Jenis	Nama Variabel	Deskripsi	Indikator / Parameter
Dependen	Akurasi <i>Retrieval</i>	Tingkat relevansi hasil <i>retrieval</i> terhadap <i>ground truth</i>	Hit@3, Recall@3, MAP@3, NDCG@3
Dependen	Latensi Sistem	Waktu yang dibutuhkan sistem dalam memproses hingga menghasilkan <i>output</i>	Waktu eksekusi
Kontrol	Model <i>Embedding</i> dan <i>Reranker</i>	Model yang digunakan dijaga tetap sama untuk semua skenario	paraphrase-multilingual-MiniLM-L12-v2 dan BGE <i>reranker</i>
Kontrol	<i>Dataset</i> Penelitian	Kumpulan <i>query</i> dan dokumen sumber yang digunakan pada seluruh skenario pengujian tetap sama; <i>query</i> dibentuk dari dokumen DTI UGM	<i>Query</i> DTI UGM beserta <i>ground truth</i> , Dokumen ISO 27001:2022
Kontrol	Lingkungan Sistem	Spesifikasi perangkat dan <i>environment</i> eksekusi dijaga konstan	Laptop, OS, <i>dependency</i>

3.2.2 Pembangunan Basis Pengetahuan ISO/IEC 27001:2022 A.5–A.8

Pembangunan basis pengetahuan pada penelitian ini dilakukan dengan mengumpulkan dan menyusun informasi terkait kontrol keamanan dari standar ISO/IEC 27001:2022, khususnya pada Annex A domain A.5 (*Organizational Controls*), A.6 (*People Controls*), A.7 (*Physical Controls*), dan A.8 (*Technological Controls*). Sumber utama yang digunakan adalah dokumen resmi “INTERNATIONAL STANDARD ISO/IEC 27001 Third Edition 2022-10”, yang kemudian diperkaya dengan referensi pendukung untuk memperjelas konteks implementasi dan kebutuhan audit. Proses ini bertujuan untuk menghasilkan representasi pengetahuan yang terstruktur sehingga dapat digunakan secara optimal dalam sistem *Retrieval-Augmented Generation* (RAG).

Seluruh dokumen yang digunakan sebagai sumber pengetahuan (korpus) disimpan dalam format JSON (*JavaScript Object Notation*). Setiap kontrol direpresentasikan sebagai satu entitas data yang terdiri dari atribut deskriptif, indikator audit, serta kata kunci dalam dua bahasa (Bahasa Inggris dan Bahasa Indonesia). Struktur ini dirancang untuk meningkatkan kualitas pencarian semantik serta mendukung variasi *query* pengguna. Struktur data JSON yang digunakan ditunjukkan pada Tabel berikut.

Tabel 3.3. Struktur Data JSON Basis Pengetahuan

Nama Atribut	Penjelasan	Contoh Isian
control_id	Kode unik kontrol pada ISO 27001 Annex A	A.8.32
title	Judul dari kontrol keamanan	Manajemen perubahan
objective	Tujuan utama dari kontrol	Memastikan perubahan fasilitas pemrosesan informasi dikelola dengan aman
description	Deskripsi lengkap mengenai kontrol dan implementasinya	Perubahan sistem informasi harus tunduk pada prosedur manajemen perubahan
implementation_guidance	Panduan implementasi kontrol secara ringkas	Proses manajemen perubahan formal dengan penilaian dampak keamanan
keywords_en	Kata kunci dalam Bahasa Inggris untuk mendukung <i>retrieval</i>	“change management”, “change control”
keywords_id	Kata kunci dalam Bahasa Indonesia	“manajemen perubahan”, “kontrol perubahan”
audit_indicators_en	Indikator audit dalam Bahasa Inggris	“unapproved changes”, “no change records”
audit_indicators_id	Indikator audit dalam Bahasa Indonesia	“perubahan tidak disetujui”, “tidak ada catatan perubahan”
related_assets_en	Aset terkait dalam Bahasa Inggris	“production systems”, “test environment”
related_assets_id	Aset terkait dalam Bahasa Indonesia	“sistem produksi”, “lingkungan pengujian”
security_principles_en	Prinsip keamanan terkait dalam Bahasa Inggris	“integrity”, “availability”
security_principles_id	Prinsip keamanan dalam Bahasa Indonesia	“integritas”, “ketersediaan”

3.2.3 Pembuatan *Query* dan *Ground Truth*

Query dan *ground truth* disusun sebagai komponen utama dalam proses evaluasi *retrieval* sistem *Information Retrieval*. *Query* berperan sebagai *input* yang merepresentasikan kebutuhan informasi pengguna, sedangkan *ground truth* digunakan sebagai acuan kebenaran untuk menilai relevansi hasil *retrieval* yang dihasilkan sistem. Dengan demikian, kombinasi keduanya memungkinkan pengukuran performa sistem secara objektif melalui perbandingan antara hasil yang dihasilkan model dan referensi yang telah ditentukan.

Query yang digunakan dalam penelitian ini disusun berdasarkan dokumen

kebijakan dan prosedur milik Direktorat Teknologi Informasi (DTI) UGM yang berkaitan dengan implementasi tata kelola dan teknologi informasi terkini. Dokumen-dokumen tersebut merepresentasikan kondisi dan kebijakan terbaru organisasi sehingga dapat menjadi acuan dalam menggambarkan status implementasi keamanan informasi UGM saat ini. Proses pembentukan *query* dilakukan melalui pembacaan manual terhadap isi dokumen untuk mengidentifikasi pernyataan, kebijakan, atau deskripsi kondisi organisasi yang berkaitan dengan kontrol pada Annex A.5 hingga A.8. Pernyataan-pernyataan tersebut kemudian dicatat menjadi *query* yang merepresentasikan kebutuhan pencarian informasi dalam konteks audit dan evaluasi kepatuhan keamanan informasi, beserta *ground truth* yang menunjukkan kontrol ISO/IEC 27001:2022 yang relevan. Pendekatan ini dilakukan agar *query* yang dihasilkan dapat merefleksikan penggunaan sistem pada kondisi dokumen organisasi yang nyata. Berikut merupakan dokumen-dokumen yang digunakan dalam penyusunan *query* pada penelitian ini.

Tabel 3.4. Dokumen DTI UGM yang Digunakan sebagai Sumber *Query* Asli

Nama Dokumen	Tentang
Keputusan Rektor Universitas Gadjah Mada Nomor 357/UN1.P5/KPT/HUKOR/2026	Pedoman Pengelolaan Domain Universitas Gadjah Mada
Peraturan Rektor Universitas Gadjah Mada Nomor 13 Tahun 2025	Tata Kelola Teknologi Informasi di Universitas Gadjah Mada
Keputusan Rektor Universitas Gadjah Mada Nomor 1198/UN1.P5/KPT/HUKOR/2025	Standar Parameter <i>Password</i> dan Keamanan Sistem Finance SIMASTER Universitas Gadjah Mada
Surat Edaran Rektor Universitas Gadjah Mada Nomor 3779/UN1.P/DTI/TI.02.03/2025	Penggunaan Perangkat Lunak di Lingkungan Universitas Gadjah Mada

3.2.4 Perancangan Komponen *Retrieval* dan *Rerank* pada Sistem

Perancangan komponen *retrieval* pada sistem *Retrieval-Augmented Generation* dilakukan untuk memastikan proses penelusuran dokumen mampu menghasilkan kandidat yang relevan secara optimal. Pendekatan utama yang digunakan adalah metode *hybrid retrieval*, yaitu integrasi antara teknik *sparse* dan *dense* untuk memperoleh keseimbangan antara pencocokan berbasis kata kunci dan pemahaman semantik. Hasil dari tahap *retrieval* awal kemudian diseleksi menjadi sejumlah kandidat teratas ($\text{top}@k$) sehingga hanya dokumen yang paling relevan yang dipertimbangkan dalam evaluasi lebih lanjut.

Untuk meningkatkan akurasi dan kualitas peringkat hasil *retrieval*, digunakan pendekatan *reranking* yang melakukan evaluasi ulang terhadap kandidat dokumen yang telah diperoleh. Mekanisme ini memanfaatkan model yang lebih sensitif terhadap hubungan kontekstual antara *query* dan dokumen, sehingga mampu menghasilkan urutan yang lebih representatif terhadap relevansi sebenarnya. Proses *reranking* juga melibatkan pengaturan konfigurasi tertentu, termasuk strategi penggabungan bobot skor (*score fusion*), guna memperoleh hasil akhir yang lebih akurat, konsisten, dan sesuai dengan kebutuhan evaluasi sistem.

3.2.4.1 Perancangan Komponen *Retrieval* pada Sistem

Komponen *hybrid retrieval* pada penelitian ini menggunakan dua metode yang dipilih berdasarkan analisis perbandingan pada Subbab 2.3.2 dan Subbab 2.3.3.


Pemilihan Metode *Sparse Retrieval*

Berdasarkan analisis perbandingan metode *sparse retrieval* pada Subbab 2.3.2, BM25 dipilih sebagai komponen *sparse retrieval*. BM25 mengungguli alternatif lainnya karena memiliki model probabilistik yang kuat untuk pencocokan istilah eksplisit, normalisasi panjang dokumen bawaan, serta bukti empiris yang menunjukkan keunggulannya pada penelitian terdahulu dalam domain regulasi. Karakteristik terminologi yang eksplisit dan konsisten pada kontrol ISO/IEC 27001:2022, misalnya *access control*, *incident management*, dan *logging*, memungkinkan pencocokan leksikal bekerja secara efektif.

Pemilihan Model *Dense Embedding*

Berdasarkan analisis perbandingan model *dense embedding* pada Subbab 2.3.3, paraphrase-multilingual-MiniLM-L12-v2 dipilih sebagai komponen *dense embedding*. Model ini dipilih karena menawarkan keseimbangan optimal antara kualitas representasi semantik, dukungan multilingual untuk *query* berbahasa Indonesia (50+ bahasa), efisiensi komputasi dengan dimensi 384, serta bukti empiris yang menunjukkan konsistensi peningkatan kualitas *dense retrieval* pada arsitektur *hybrid retrieval*.

Komponen *hybrid retrieval* dibangun untuk menggabungkan pencarian semantik berbasis *embedding* dan pencarian leksikal berbasis BM25. Dalam rancangan Bab 3, proses ini dapat dijelaskan melalui tiga tahap utama yang sesuai dengan diagram, yaitu Basis Pengetahuan, Pemrosesan *Query*, dan Pemrosesan *Scoring*. Ketiga tahap tersebut menunjukkan alur dari pembentukan representasi dokumen, pemrosesan masukan pengguna, hingga penggabungan skor untuk memilih dokumen paling relevan.



Gambar 3.6. Komponen hybrid retrieval pada sistem

Berdasarkan alur yang ditunjukkan pada Gambar ??, proses *retrieval* dapat diuraikan ke dalam tiga tahap utama sebagai berikut.

1. Basis Pengetahuan

Tahap Basis Pengetahuan merupakan fase inisialisasi yang dijalankan saat sistem dimulai untuk menyiapkan seluruh representasi dokumen kontrol ISO. Pada tahap ini, data kontrol ISO dimuat dari berkas JSON, dikonversi menjadi representasi teks, kemudian diproses melalui jalur *dense* untuk membentuk *embedding* dokumen dan jalur *sparse* untuk membangun indeks BM25. Hasil dari fase ini disimpan dalam memori agar dapat digunakan kembali ketika *query* pengguna diproses.

- a. **`_load_controls(controls_path)`**: Proses ini memuat data basis pengetahuan dari berkas JSON yang berisi 93 kontrol ISO. Hasil pemuatan data menjadi daftar kontrol yang akan digunakan sebagai korpus dokumen pada proses *retrieval*.
- b. **`control_to_text(control=control)`**: Proses ini mengubah satu data kontrol ISO berbentuk JSON menjadi representasi teks datar (*flat text*). Representasi teks ini menggabungkan atribut penting seperti judul, objektif, deskripsi, serta atribut pengayaan yang tersedia agar dokumen memiliki konteks yang lebih lengkap.
- c. **`encode_texts(texts=control_texts)`**: Proses ini mengubah seluruh representasi teks kontrol ISO menjadi vektor *embedding*. Vektor ini merepresentasikan makna semantik dokumen sehingga dapat dibandingkan dengan *query* pada ruang vektor yang sama.
- d. **`normalize(vectors=doc_embeddings)`**: Proses ini melakukan normalisasi L2 pada vektor *embedding* dokumen. Normalisasi dilakukan agar perhitungan *dot product* antara *query* dan dokumen setara dengan *cosine similarity*.
- e. **`HybridRetriever.doc_embeddings`**: Proses ini menyimpan vektor *embedding* dokumen pada atribut `doc_embeddings`. Penyimpanan dilakukan secara *in-memory* sehingga indeks vektor dapat digunakan langsung saat sistem menghitung *dense score*.
- f. **`tokenize(text=control_text)`**: Proses ini mengubah representasi teks dokumen menjadi daftar token leksikal. Tokenisasi dilakukan dengan mengubah teks menjadi huruf kecil dan mengambil karakter alfanumerik agar dokumen siap diproses oleh BM25.
- g. **`BM25Retriever(documents=control_texts)`**: Proses ini menginisialisasi indeks BM25 berdasarkan seluruh teks kontrol ISO. Inisialisasi ini membentuk struktur data yang diperlukan untuk menghitung kecocokan kata kunci antara *query* dan dokumen.
- h. **`_compute_doc_freq(tokenized_docs)`**: Proses ini menghitung jumlah dokumen yang mengandung setiap *term*. Nilai *document frequency* digunakan sebagai dasar untuk menentukan seberapa umum atau spesifik suatu *term* dalam korpus.
- i. **`_compute_idf(doc_freq)`**: Proses ini menghitung nilai *inverse document frequency* untuk setiap *term*. Nilai IDF memberi bobot lebih tinggi pada *term* yang lebih jarang muncul sehingga dokumen dengan kata kunci spesifik dapat diberi skor lebih relevan.

- j. **BM25 index**: Proses ini menyimpan informasi *term frequency*, panjang dokumen, rata-rata panjang dokumen, dan IDF. Informasi tersebut digunakan kembali pada tahap Pemrosesan *Query* untuk menghitung *sparse score*.

2. Pemrosesan *Query*

Tahap Pemrosesan *Query* dijalankan setiap kali pengguna memasukkan pertanyaan atau kebutuhan informasi. Pada tahap ini, *query* diproses melalui dua jalur yang sama dengan dokumen, yaitu jalur *dense* untuk menghasilkan skor kemiripan semantik dan jalur *sparse* untuk menghasilkan skor kecocokan kata kunci. Hasil dari tahap ini berupa *dense score* dan *sparse score* untuk seluruh kontrol ISO.

- a. **encode_texts(texts=[query])**: Proses ini mengubah *query* pengguna menjadi vektor *embedding*. Karena fungsi yang sama digunakan pada dokumen dan *query*, keduanya berada pada ruang representasi semantik yang sama.
- b. **normalize(vectors=query_embedding)**: Proses ini menormalkan vektor *query* menggunakan normalisasi L2. Normalisasi membuat perhitungan kemiripan antara *query* dan dokumen dapat dilakukan secara konsisten menggunakan *dot product*.
- c. **np.dot(doc_embeddings, q_emb)**: Proses ini menghitung hasil *dot product* antara vektor *query* dan seluruh *embedding* dokumen. Hasilnya adalah *dense score* yang merepresentasikan tingkat kemiripan semantik *query* terhadap 93 kontrol ISO.
- d. **tokenize(text=query)**: Proses ini mengubah *query* menjadi daftar token leksikal. Tokenisasi *query* menggunakan aturan yang sama dengan dokumen agar pencocokan kata kunci pada BM25 berjalan konsisten.
- e. **score_query(query=query)**: Proses ini menghitung skor BM25 antara *query* dan seluruh dokumen. Skor dihitung berdasarkan kombinasi *term frequency*, IDF, dan normalisasi panjang dokumen sehingga menghasilkan *sparse score* untuk 93 kontrol ISO.

3. Pemrosesan *Scoring*

Tahap Pemrosesan *Scoring* berfungsi untuk menggabungkan *dense score* dan *sparse score* menjadi satu skor akhir. Kedua jenis skor terlebih dahulu dinormalisasi karena memiliki skala yang berbeda. Setelah itu, skor digabungkan menggunakan *weighted sum*, diurutkan, dan digunakan untuk memilih dokumen teratas sebagai hasil *retrieval*.

- a. `_minmax(scores=dense_scores)`: Proses ini menormalisasi *dense score* ke rentang 0 sampai 1. Normalisasi ini diperlukan agar skor semantik memiliki skala yang sebanding dengan skor BM25.
- b. `_minmax(scores=sparse_scores)`: Proses ini menormalisasi *sparse score* ke rentang 0 sampai 1. Normalisasi dilakukan secara terpisah dari *dense score* karena kedua skor berasal dari metode yang berbeda.
- c. `weighted_sum(dense_norm, sparse_norm)`: Proses ini menggabungkan skor *dense* dan *sparse* yang telah dinormalisasi. Formula yang digunakan adalah sebagai berikut.

$$hybrid_score = w_{dense} \times dense_norm + w_{sparse} \times sparse_norm \quad (3-1)$$

- d. `np.argsort(a=-hybrid_scores)[:3]`: Proses ini mengurutkan dokumen berdasarkan *hybrid score* secara menurun. Tiga dokumen dengan skor tertinggi dipilih sebagai kandidat paling relevan.
- e. `_build_result(idx=top_indices)`: Proses ini mengambil metadata dokumen terpilih seperti `control_id`, `title`, `objective`, dan `description`. Metadata beserta skor *dense*, *sparse*, dan *hybrid* digunakan sebagai hasil akhir tahap *retrieval*.

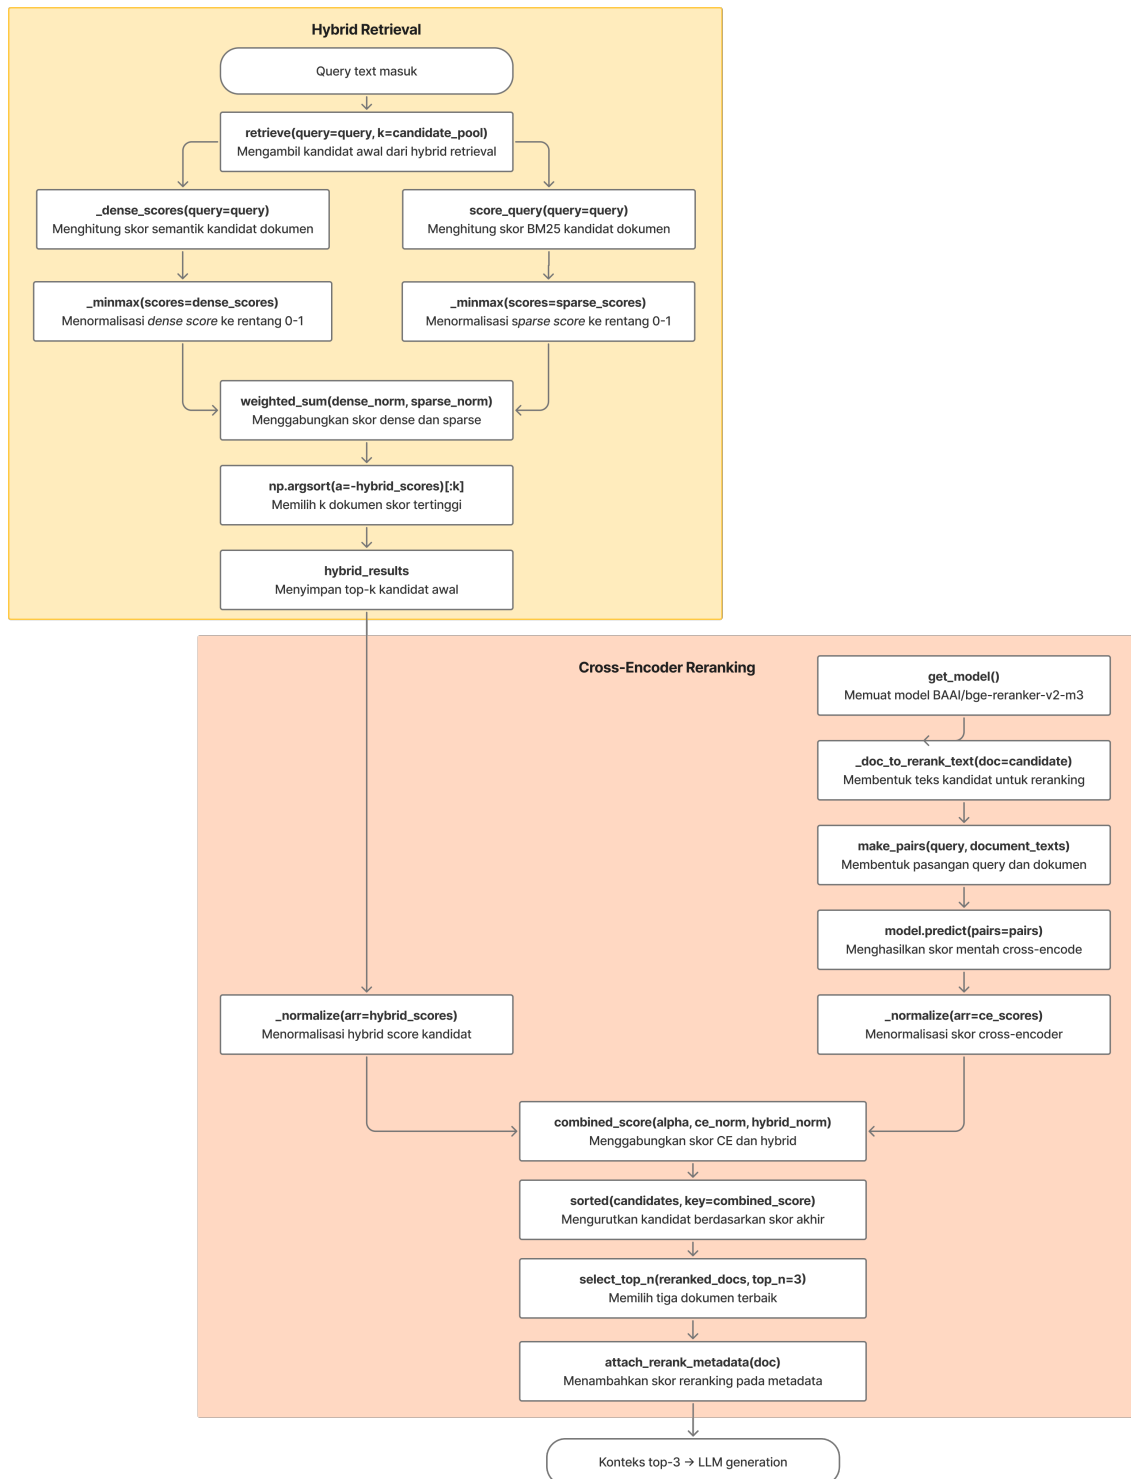
3.2.4.2 Perancangan Komponen *Rerank* pada Sistem

Komponen *reranking* pada penelitian ini menggunakan model *cross-encoder* yang dipilih berdasarkan analisis perbandingan pada Subbab 2.3.4.

Pemilihan Model *Reranker*

Berdasarkan analisis perbandingan model *reranker* pada Subbab 2.3.4, BAAI/bge-reranker-v2-m3 dipilih sebagai model *reranker*. Model ini dipilih karena menggabungkan bukti empiris pada domain regulasi yang menunjukkan peningkatan signifikan pada kualitas peringkat, dukungan multilingual untuk lebih dari 100 bahasa yang esensial untuk *query* berbahasa Indonesia, serta kemudahan implementasi sebagai model *cross-encoder* yang bersifat *plug-and-play*.

Perancangan komponen *rerank* pada sistem dilakukan untuk meningkatkan kualitas urutan dokumen yang telah diperoleh dari tahap *hybrid retrieval*. Pada rancangan ini, sistem tidak langsung menggunakan hasil *hybrid retrieval* sebagai keluaran akhir, tetapi terlebih dahulu membentuk *candidate pool* dan mengevaluasi ulang kandidat tersebut menggunakan model *cross-encoder*. Dengan demikian, hasil akhir tidak hanya mempertimbangkan skor gabungan *dense* dan *sparse*, tetapi juga mempertimbangkan interaksi langsung antara *query* dan dokumen kandidat.



Gambar 3.7. Komponen cross-encoder reranking pada sistem

Berdasarkan alur yang ditunjukkan pada Gambar ??, proses *rerank* dapat diuraikan ke dalam dua tahap utama, yaitu tahap *hybrid retrieval* dan tahap *cross-encoder reranking*.

1. Tahap *Hybrid Retrieval*

Tahap *hybrid retrieval* berfungsi sebagai tahap awal untuk menghasilkan kandidat dokumen yang akan dievaluasi ulang oleh *reranker*. Pada tahap ini, sistem memproses *query* menggunakan mekanisme *dense retrieval* dan *sparse retrieval*, menormalisasi skor dari kedua jalur, menggabungkannya menjadi *hybrid score*, lalu memilih sejumlah kandidat teratas sebagai *candidate pool*. Dalam rancangan ini, *candidate pool* digunakan sebagai masukan untuk tahap *cross-encoder reranking*.

- a. **retrieve(query=query, k=candidate_pool):** Proses ini mengambil kandidat awal menggunakan komponen *hybrid retrieval*. Parameter *k* menentukan jumlah kandidat yang masuk ke *candidate pool* sebelum dilakukan *reranking*.
- b. **_dense_scores(query=query):** Proses ini menghitung skor semantik antara *query* dan seluruh dokumen menggunakan operasi *dot product*. Skor yang dihasilkan merepresentasikan kemiripan makna antara kebutuhan informasi pengguna dan dokumen kontrol ISO.
- c. **score_query(query=query):** Proses ini menghitung skor BM25 antara *query* dan seluruh dokumen. Skor ini merepresentasikan kecocokan kata kunci berdasarkan *term frequency*, IDF, dan normalisasi panjang dokumen.
- d. **_minmax(scores=dense_scores):** Proses ini menormalisasi *dense score* ke rentang 0 sampai 1. Normalisasi diperlukan agar skor semantik memiliki skala yang sebanding dengan skor dari jalur *sparse*.
- e. **_minmax(scores=sparse_scores):** Proses ini menormalisasi *sparse score* ke rentang 0 sampai 1. Normalisasi dilakukan secara terpisah karena skor BM25 memiliki skala berbeda dari skor *dense*.
- f. **weighted_sum(dense_norm, sparse_norm):** Proses ini menggabungkan skor *dense* dan *sparse* yang telah dinormalisasi. Hasil penggabungan membentuk *hybrid score* yang digunakan untuk menentukan kandidat awal.
- g. **np.argsort(a=-hybrid_scores)[:k]:** Proses ini mengurutkan dokumen berdasarkan *hybrid score* secara menurun dan memilih kandidat dengan skor tertinggi. Kandidat terpilih menjadi *candidate pool* untuk tahap *reranking*.
- h. **hybrid_results:** Proses ini menyimpan daftar kandidat awal hasil *hybrid retrieval*. Setiap kandidat mempertahankan metadata dokumen dan skor *dense*, *sparse*, serta *hybrid* untuk digunakan pada tahap berikutnya.

2. *Cross-Encoder Reranking*

Tahap *cross-encoder reranking* berfungsi untuk mengevaluasi ulang kandidat dokumen dari tahap *hybrid retrieval*. Pada tahap ini, setiap kandidat diubah menjadi teks representatif, kemudian dipasangkan dengan *query* dan diproses oleh model *cross-encoder*. Skor *cross-encoder* dinormalisasi dan dikombinasikan dengan skor *hybrid* untuk menghasilkan *combined score*. Skor akhir ini digunakan untuk menentukan urutan dokumen terbaik.

- a. **get_model()**: Proses ini memuat model *BAAI/bge-reranker-v2-m3* dengan mekanisme *lazy loading*. Model digunakan untuk menghitung relevansi pasangan *query* dan dokumen secara langsung.
- b. **_doc_to_rerank_text(doc=candidate)**: Proses ini membentuk teks kandidat yang digunakan pada tahap *reranking*. Teks kandidat memuat atribut dokumen seperti judul, objektif, deskripsi, kata kunci, dan indikator audit agar konteks dokumen lebih lengkap.
- c. **make_pairs(query, document_texts)**: Proses ini membentuk pasangan antara *query* dan teks dokumen kandidat. Pasangan ini menjadi masukan utama bagi model *cross-encoder* untuk melakukan penilaian relevansi.
- d. **model.predict(pairs=pairs)**: Proses ini menghasilkan skor mentah *cross-encoder* untuk setiap pasangan *query* dan dokumen. Skor tersebut menunjukkan tingkat relevansi kandidat berdasarkan interaksi langsung antara dua teks.
- e. **_normalize(arr=ce_scores)**: Proses ini menormalisasi skor *cross-encoder* ke rentang 0 sampai 1. Normalisasi diperlukan agar skor *cross-encoder* dapat digabungkan dengan skor *hybrid*.
- f. **_normalize(arr=hybrid_scores)**: Proses ini menormalisasi *hybrid score* kandidat ke rentang 0 sampai 1. Skor ini digunakan sebagai indikator relevansi awal dari tahap *retrieval*.
- g. **combined_score(alpha, ce_norm, hybrid_norm)**: Proses ini menggabungkan skor *cross-encoder* dan skor *hybrid* yang telah dinormalisasi. Formula yang digunakan adalah sebagai berikut.

$$combined_score = \alpha \times ce_norm + (1 - \alpha) \times hybrid_norm \quad (3-2)$$


- h. **sorted(candidates, key=combined_score)**: Proses ini mengurutkan seluruh kandidat berdasarkan *combined score* secara menurun. Kandidat dengan skor akhir tertinggi ditempatkan pada peringkat teratas.

- i. `select_top_n(reranked_docs, top_n=3)`: Proses ini memilih tiga dokumen terbaik setelah proses *reranking*. Dokumen terpilih menjadi hasil akhir yang digunakan sebagai konteks pada tahap generasi.
- j. `attach_rerank_metadata(doc)`: Proses ini menambahkan informasi hasil *reranking* ke metadata dokumen. Informasi tersebut mencakup `rerank_score`, `rerank_score_norm`, `hybrid_score_norm`, dan `combined_score` untuk mendukung transparansi hasil.

3.3 Alur Tugas Akhir

Penelitian ini dilaksanakan melalui serangkaian tahapan yang dirancang secara sistematis untuk menjawab hipotesis dan tujuan penelitian secara komprehensif. Setiap tahapan memiliki luaran yang saling berkaitan dan digunakan sebagai dasar pada tahapan berikutnya, sehingga keseluruhan proses penelitian dapat berjalan secara terstruktur dan berkesinambungan. Alur penelitian dimulai dari proses studi literatur dan identifikasi permasalahan, dilanjutkan dengan persiapan data dan kebutuhan penelitian, perancangan sistem dan metode yang digunakan, pelaksanaan pengujian dan eksperimen, hingga tahap analisis hasil evaluasi dan penyusunan kesimpulan akhir penelitian.

Gambar ?? menunjukkan diagram alur penelitian secara keseluruhan yang menggambarkan hubungan antar tahapan penelitian mulai dari tahap persiapan hingga proses evaluasi akhir.



Gambar 3.8. Alur penelitian

3.3.1 Tinjauan Pustaka

Langkah pertama pada penelitian ini adalah melakukan tinjauan pustaka untuk memperoleh pemahaman terkait perkembangan penelitian yang relevan dengan topik penelitian. Proses tinjauan pustaka dilakukan dengan menelusuri berbagai publikasi ilmiah, khususnya pada IEEE dan sumber ilmiah bereputasi lainnya. Beberapa kata kunci yang digunakan dalam pencarian literatur antara lain “*RAG for Auditing*”, “*Retrieval Strategy Optimization*”, “*Information Retrieval*”, dan “*Cross-Encoder Reranking*”. Kata kunci tersebut dipilih karena memiliki keterkaitan langsung dengan fokus penelitian, yaitu evaluasi strategi *retrieval* dan *reranking* pada *pipeline* RAG.

Seperti yang telah dijelaskan pada Subbab 2.1, terdapat beberapa tema utama yang ditemukan pada penelitian-penelitian terdahulu. Variasi penelitian yang ditemukan meliputi domain penerapan sistem RAG, jenis pendekatan *hybrid retrieval* yang digunakan, pemanfaatan metode *cross-encoder reranking*, serta strategi pembobotan

score fusion dan penyesuaian parameter untuk memperoleh performa *retrieval* yang optimal. Berdasarkan hasil tinjauan pustaka tersebut, penelitian ini dirancang dengan fokus pada evaluasi performa kombinasi *hybrid retrieval* dan *cross-encoder reranking* dalam meningkatkan kualitas hasil *retrieval* pada dokumen ISO/IEC 27001:2022.

3.3.2 Identifikasi Masalah

Berdasarkan hasil tinjauan pustaka, telah ditemukan berbagai penelitian yang menerapkan pendekatan *Retrieval-Augmented Generation* (RAG) khususnya *Information Retrieval* pada domain tertentu, seperti regulasi perpajakan, dokumen keuangan, maupun kebijakan privasi. Penelitian-penelitian tersebut menunjukkan bahwa kombinasi *hybrid retrieval* dan *reranking* mampu meningkatkan relevansi hasil pencarian pada dokumen yang bersifat regulatif dan berbasis teks.

Namun, hingga saat penelitian ini dilakukan, masih ditemukan keterbatasan penelitian yang secara khusus membahas penerapan strategi *retrieval* pada standar ISO/IEC 27001:2022, terutama pada Annex A domain A.5 hingga A.8. Karakteristik dokumen ISO 27001 memiliki tantangan tersendiri karena beberapa *annex control* memiliki konteks, istilah, dan tujuan kontrol yang saling berdekatan, sehingga suatu kondisi audit dapat berkaitan dengan lebih dari satu kontrol keamanan. Hal tersebut menyebabkan proses klasifikasi dan pemetaan kontrol menjadi lebih rentan kesalahan dibandingkan domain regulasi umum lainnya.

Selain itu, pada *pipeline Retrieval-Augmented Generation* (RAG), kualitas hasil *retrieval* memiliki pengaruh langsung terhadap ketepatan proses *generation*. Apabila dokumen atau kontrol yang dipilih pada tahap *retrieval* tidak relevan, maka hasil *generation* yang digunakan untuk proses pemetaan terhadap *Statement of Applicability* (SoA) berpotensi menjadi kurang akurat. Oleh karena itu, penelitian ini difokuskan pada evaluasi komparatif strategi *retrieval*, khususnya *hybrid retrieval*, *cross-encoder reranking*, serta kombinasi keduanya, untuk mengidentifikasi pendekatan yang mampu memberikan performa *retrieval* paling optimal pada dokumen ISO/IEC 27001:2022. Penelitian ini tidak bertujuan untuk mengembangkan *pipeline* RAG secara *end-to-end*, melainkan menghasilkan rekomendasi strategi *information retrieval* yang efektif untuk mendukung proses pemetaan kontrol keamanan dan implementasi sistem audit keamanan informasi berbasis ISO 27001 di masa mendatang.

3.3.3 Persiapan Basis Pengetahuan Dokumen Kontrol Annex

Tahap persiapan basis pengetahuan dilakukan dengan mengumpulkan informasi terkait *annex control* berdasarkan standar ISO/IEC 27001:2022, khususnya pada domain Annex A.5 hingga A.8. Sumber utama yang digunakan berasal dari dokumen resmi “INTERNATIONAL STANDARD ISO/IEC 27001 Third Edition 2022-10”. Selain itu,

informasi tambahan juga dikumpulkan dari berbagai sumber di internet seperti artikel implementasi keamanan informasi, dokumentasi audit, serta referensi praktik keamanan siber untuk memperkaya konteks tiap kontrol keamanan. Penambahan informasi tersebut dilakukan agar basis pengetahuan tidak hanya memuat definisi kontrol secara formal, tetapi juga mencakup istilah, konteks audit, dan variasi implementasi yang umum digunakan pada lingkungan nyata.

Seluruh informasi yang telah dikumpulkan kemudian direpresentasikan dalam format JSON (*JavaScript Object Notation*), di mana setiap *annex control* disimpan sebagai satu entitas data terstruktur. Struktur JSON mencakup atribut seperti identitas kontrol, deskripsi, panduan implementasi, kata kunci, indikator audit, aset terkait, dan prinsip keamanan dalam Bahasa Indonesia maupun Bahasa Inggris. Proses penyusunan dan pengisian atribut dilakukan secara manual oleh penulis untuk menjaga kesesuaian konteks dengan standar ISO 27001, serta dibantu dengan pemanfaatan *Generative AI* untuk menghasilkan variasi istilah, pengayaan kata kunci, dan penyusunan atribut pendukung yang lebih lengkap.

3.3.4 Persiapan *Dataset Variasi Query*

Tahap persiapan *dataset query* dilakukan dengan menyusun *query* yang dibentuk dari dokumen asli milik Direktorat Teknologi Informasi Universitas Gadjah Mada (DTI UGM). Proses penyusunan *query* dilakukan melalui pembacaan dan penelaahan manual terhadap dokumen kebijakan, prosedur, standar operasional, tata kelola, serta regulasi internal yang berkaitan dengan keamanan informasi dan pengelolaan teknologi informasi. Dari hasil pembacaan tersebut, kemudian diidentifikasi potongan informasi, kebutuhan audit, maupun pernyataan kebijakan yang berpotensi merepresentasikan kebutuhan pencarian informasi pada proses audit ISO/IEC 27001:2022. Berdasarkan konteks tersebut, *query* kemudian dirumuskan secara manual dengan mempertahankan istilah, struktur bahasa, dan gaya penyampaian yang mendekati kondisi nyata pada lingkungan organisasi DTI UGM.

Setelah *query* berhasil dibentuk, dilakukan proses penelaahan untuk menentukan *ground truth annex control* yang sesuai terhadap masing-masing *query*. Penentuan *ground truth* dilakukan dengan mencocokkan konteks *query* terhadap kontrol ISO/IEC 27001:2022 Annex A.5 hingga A.8 berdasarkan relevansi isi, tujuan pengendalian, serta cakupan keamanan informasi yang dibahas dalam dokumen sumber. Setiap *query* dapat memiliki keterkaitan dengan satu atau lebih kontrol *annex* sesuai kompleksitas konteks yang ditemukan.

3.3.5 Perancangan *Hybrid Retrieval* dan Pemilihan Parameter Optimal

Perancangan metode *hybrid retrieval* pada penelitian ini dilakukan dengan mengacu pada beberapa penelitian terdahulu, khususnya penelitian oleh Rustamov et al. dan Liu et al. yang menerapkan kombinasi *sparse retrieval* menggunakan BM25 dan *dense retrieval* berbasis model MiniLM. Pada penelitian ini, BM25 digunakan untuk menangkap kesesuaian istilah secara eksplisit, sedangkan *dense retrieval* menggunakan model paraphrase-multilingual-MiniLM-L12-v2 untuk memahami keterkaitan makna semantik antara *query* dan dokumen *annex control*. Penggunaan model ini merupakan pengembangan dari penelitian sebelumnya yang banyak menggunakan model all-MiniLM-L6-v2 sebagai *baseline dense retrieval*.

Pada penelitian ini dipilih model *multilingual* karena kumpulan *query* dan dokumen berasal dari lingkungan institusi pendidikan di Indonesia yang didominasi penggunaan Bahasa Indonesia serta istilah teknis berbahasa Inggris secara bersamaan. Selain itu, arsitektur L12 dengan 12 *layer* dipilih karena memiliki kapasitas representasi semantik yang lebih baik dibandingkan varian L6, sehingga diharapkan lebih mampu menangkap hubungan makna pada *query* audit yang bersifat implisit, panjang, dan kontekstual. Dengan demikian, model ini dinilai lebih sesuai untuk skenario *retrieval* dokumen keamanan informasi pada domain DTI UGM yang memiliki karakteristik bahasa campuran dan konteks kebijakan yang kompleks.

Setelah metode *hybrid retrieval* dirancang, tahap selanjutnya adalah melakukan pencarian parameter bobot *score fusion* yang optimal melalui penyesuaian nilai α (*alpha scoring*). Parameter α digunakan untuk mengatur proporsi kontribusi skor antara *sparse retrieval* dan *dense retrieval* pada proses penggabungan skor akhir. Pengujian dilakukan terhadap seluruh variasi *query* yang digunakan dalam penelitian untuk menentukan kombinasi bobot yang mampu memberikan performa *retrieval* terbaik sebelum integrasi metode *reranking*. Hasil pencarian parameter ini kemudian digunakan sebagai konfigurasi dasar pada tahap eksperimen berikutnya agar proses *score fusion* antara *hybrid retrieval* dan *cross-encoder reranking* dapat dilakukan secara konsisten dan terukur.

3.3.6 Perancangan *Reranking* dan Pemilihan Parameter Optimal

Tahap perancangan *reranking* dilakukan sebagai pengembangan dari rancangan *hybrid retrieval* yang telah dibangun pada tahap sebelumnya. Pada proses ini, hasil *retrieval* awal dari metode *hybrid retrieval* digunakan sebagai *candidate pool* yang akan diproses kembali untuk meningkatkan kualitas peringkat dokumen. Dengan pendekatan ini, sistem tidak melakukan proses *reranking* terhadap seluruh dokumen pada korpus, melainkan hanya pada sejumlah dokumen dengan skor *retrieval* tertinggi hasil dari proses *hybrid retrieval*. Pendekatan tersebut dipilih untuk menjaga efisiensi komputasi

sekaligus mempertahankan kualitas relevansi hasil pencarian.

Metode *reranking* yang digunakan pada penelitian ini adalah pendekatan *cross-encoder* menggunakan model BAAI/bge-reranker-v2-m3 yang mendukung pemrosesan multibahasa, termasuk Bahasa Indonesia. Pemilihan model BGE *reranker* juga didasarkan pada beberapa penelitian sebelumnya oleh Rustamov et al. menggunakan seri model BGE sebagai pendekatan *retrieval* dan *reranking* karena memiliki performa *semantic matching* yang baik pada tugas *information retrieval* modern. Selain itu, penelitian oleh Elkiran-Rasheed menunjukkan bahwa model BAAI/bge-reranker-base mampu menghasilkan nilai akurasi terbaik dibandingkan beberapa model *reranker* lainnya pada proses evaluasi *retrieval*.

Berdasarkan pertimbangan tersebut, penelitian ini menggunakan varian BAAI/bge-reranker-v2-m3 karena memiliki kemampuan *multilingual* dan kapasitas pemahaman konteks yang lebih sesuai dengan karakteristik dokumen kebijakan serta *query* audit pada lingkungan institusi pendidikan di Indonesia. Setelah rancangan *reranking* dibangun, dilakukan pengujian terhadap beberapa variasi jumlah *candidate pool* yang diambil dari hasil *hybrid retrieval* untuk menentukan nilai top- n yang paling optimal untuk proses *reranking* dilakukan. Pengujian ini bertujuan memperoleh keseimbangan antara kualitas relevansi dan efisiensi komputasi, sehingga proses *score fusion* antara *hybrid retrieval* dan *cross-encoder reranking* dapat menghasilkan performa *retrieval* yang optimal.

3.3.7 Pengujian Kombinasi dan Pemilihan *Scoring* Optimal

Setelah perancangan metode *hybrid retrieval* dan *cross-encoder reranking* selesai dilakukan, tahap selanjutnya adalah melakukan pengujian kombinasi kedua metode melalui mekanisme pembobotan *score fusion*. Pada tahap ini, pengujian dilakukan secara komprehensif dengan memvariasikan parameter α (*alpha scoring*) untuk menentukan proporsi skor yang paling optimal antara hasil *hybrid retrieval* dan skor dari *reranking*, dengan urutan pembobotan *hybrid:cross-encoder*. Dalam kerangka ini, pengujian *hybrid retrieval* secara independen direpresentasikan oleh parameter pembobotan 1:0, pengujian *reranker* secara independen direpresentasikan oleh parameter pembobotan 0:1, sedangkan konfigurasi dengan pembobotan lainnya merepresentasikan kombinasi kedua metode.

Pada tahap ini, *hybrid retrieval* menggunakan parameter bobot α paling optimal antara komponen *dense retrieval* dan *sparse retrieval* yang diperoleh dari tahap sebelumnya, sedangkan *reranking* menggunakan jumlah *candidate pool* terbaik. Proses eksperimen dilakukan pada seluruh *query* yang dibentuk dari dokumen kebijakan Direktorat Teknologi Informasi (DTI) UGM. Setiap kombinasi parameter dievaluasi menggunakan metrik *Information Retrieval* seperti Hit@3, Recall@3, MAP@3, dan

NDCG@3 untuk mengidentifikasi konfigurasi bobot *score fusion* yang memberikan performa paling optimal. Pengujian ini bertujuan untuk mengevaluasi kualitas performa masing-masing pendekatan baik secara independen maupun dalam bentuk kombinasi, sehingga dapat diketahui kontribusi dan karakteristik tiap metode terhadap hasil *retrieval* sekaligus ditentukan pendekatan kombinasi yang paling efektif dalam meningkatkan relevansi hasil pencarian pada proses pemetaan *annex control* ISO/IEC 27001:2022.

3.3.8 Analisis Evaluasi Hasil

Tahap analisis evaluasi hasil dilakukan setelah seluruh proses pengujian terhadap metode *hybrid retrieval*, *cross-encoder reranking*, dan kombinasi bobot *score fusion* selesai dilaksanakan. Pada tahap ini, hasil evaluasi dibandingkan untuk menganalisis performa masing-masing pendekatan, baik secara independen maupun dalam bentuk kombinasi. Analisis dilakukan menggunakan beberapa metrik *Information Retrieval* seperti Hit@3, Recall@3, MAP@3, dan NDCG@3 untuk melihat tingkat relevansi dan kualitas peringkat dokumen yang dihasilkan oleh setiap metode. Selain itu, tahap ini juga digunakan untuk mengamati pengaruh perubahan parameter terhadap performa *retrieval*, seperti nilai α pada *hybrid retrieval*, ukuran *candidate pool*, serta proporsi *score fusion* antara *retrieval* dan *reranking*.

Melalui analisis tersebut, diharapkan dapat terlihat pola performa akurasi dari tiap metode terhadap *query* yang dibentuk dari dokumen kebijakan DTI UGM. Hasil analisis ini diharapkan dapat memberikan rekomendasi konfigurasi *retrieval* yang paling sesuai untuk implementasi sistem *Information Retrieval* pada domain audit keamanan informasi berbasis ISO/IEC 27001:2022.

3.3.9 Penulisan Laporan

Setelah seluruh tahapan penelitian selesai dilaksanakan, dilakukan proses penyusunan laporan sebagai bentuk dokumentasi akhir penelitian. Laporan ini memuat uraian lengkap mengenai tahapan penelitian yang telah dilakukan, implementasi metode yang digunakan, hasil eksperimen dan pengujian yang diperoleh, proses evaluasi dan interpretasi hasil, serta rangkuman temuan penelitian.

BAB IV

HASIL DAN PEMBAHASAN

Bab ini menjelaskan hasil dan pembahasan penelitian yang dilakukan untuk mengevaluasi kinerja sistem *information retrieval* berbasis *hybrid retrieval* dan *cross-encoder reranking* pada domain dokumen ISO/IEC 27001:2022. Evaluasi dilakukan menggunakan 77 *query* yang diekstraksi dari dokumen kebijakan DTI UGM sebagai representasi kebutuhan informasi organisasi nyata. Metrik evaluasi yang digunakan mengacu pada Subbab 2.3.10, yang mencakup Hit@3 dan Recall@3 sebagai metrik *coverage*, serta MAP@3 dan NDCG@3 sebagai metrik *rank-sensitive*.

Penelitian ini menguji tiga skenario utama secara bertahap. Skenario pertama menganalisis pengaruh komposisi pembobotan *dense* dan *sparse* pada *hybrid retrieval* untuk menentukan konfigurasi paling optimal. Skenario kedua menganalisis pengaruh ukuran *candidate pool* terhadap kualitas hasil *reranking*. Skenario ketiga menganalisis komposisi pembobotan antara skor *hybrid retrieval* dan skor *cross-encoder* dalam proses *score fusion*. Pada setiap skenario, validitas statistik perbedaan performa antar konfigurasi diuji menggunakan uji Friedman [?] dengan tingkat signifikansi $\alpha = 0,05$, sebagaimana telah dijelaskan pada Subbab 2.2.15. Uji ini dipilih karena data evaluasi memiliki sifat *repeated measures* di mana setiap *query* dievaluasi pada seluruh konfigurasi yang dibandingkan.

4.1 Analisis Dokumen DTI UGM terhadap Kerangka ISO/IEC 27001:2022

Sebelum membahas hasil evaluasi sistem *retrieval*, perlu dipahami karakteristik distribusi *ground truth* yang menjadi acuan pengujian. *Ground truth* diturunkan dari empat dokumen kebijakan Direktorat Teknologi Informasi (DTI) UGM yang masing-masing merepresentasikan topik dan cakupan kontrol keamanan yang berbeda. Total 77 *query* menghasilkan 231 referensi kontrol ISO/IEC 27001:2022 Annex A (tiga *ground truth* tiap *query*) yang tersebar pada domain A.5 (*Organizational Controls*), A.6 (*People Controls*), A.7 (*Physical Controls*), dan A.8 (*Technological Controls*).

4.1.1 Distribusi *Ground Truth* per Dokumen dan Domain Kontrol

Tabel ?? merangkum jumlah referensi kontrol ISO/IEC 27001:2022 yang terkandung dalam setiap dokumen DTI UGM berdasarkan domain Annex A. Nilai pada setiap sel merupakan jumlah kemunculan referensi kontrol pada domain tersebut dalam keseluruhan *ground truth* dokumen yang bersangkutan.

Tabel 4.1. Distribusi Referensi Kontrol ISO/IEC 27001:2022 per Dokumen DTI UGM

Nama Dokumen	A.5	A.6	A.7	A.8	Total
Keputusan Rektor UGM No. 357/UN1.P5/KPT/HUKOR/2026 tentang Pedoman Pengelolaan Domain UGM	59	0	2	32	93
Peraturan Rektor UGM No. 13 Tahun 2025 tentang Tata Kelola Teknologi Informasi di UGM	47	4	0	30	81
Keputusan Rektor UGM No. 1198/UN1.P5/KPT/HUKOR/2025 tentang Standar Parameter <i>Password</i> dan Keamanan Sistem Finance SIMASTER	15	0	0	24	39
Surat Edaran Rektor UGM No. 3779/UN1.P/DTI/TI.02.03/2025 tentang Penggunaan Perangkat Lunak di Lingkungan UGM	15	1	0	2	18
Total Keseluruhan	136	5	2	88	231

4.1.2 Deskripsi dan Analisis Keterkaitan Tiap Dokumen dengan ISO/IEC 27001:2022

Berikut diuraikan karakteristik dan keterkaitan masing-masing dokumen kebijakan DTI UGM terhadap kontrol-kontrol pada Annex A ISO/IEC 27001:2022.

4.1.2.1 Keputusan Rektor UGM Nomor 357/UN1.P5/KPT/HUKOR/2026 tentang Pedoman Pengelolaan Domain UGM

Dokumen ini berfokus pada tata kelola identitas digital dan pengelolaan nama domain di lingkungan Universitas Gadjah Mada, mencakup ketentuan pendaftaran, perpanjangan, penonaktifan, serta kewajiban teknis pengelola sistem informasi. Berdasarkan pemetaan *ground truth*, dokumen ini menghasilkan 93 referensi kontrol dengan dominasi kuat pada domain A.5 (*Organizational Controls*) sebesar 63,4% dan A.8 (*Technological Controls*) sebesar 34,4%. Tidak terdapat satu pun referensi pada domain A.6 (*People Controls*), sementara domain A.7 (*Physical Controls*) hanya tercatat dua kali melalui kontrol A.7.3 yang berkaitan dengan tanggung jawab personel. Berdasarkan pola distribusi tersebut, dokumen ini secara dominan merujuk pada kontrol-kontrol yang berkaitan dengan tata kelola dan kebijakan keamanan informasi. Kontrol yang paling sering dirujuk disajikan pada Tabel ???. Pola ini mencerminkan bahwa pengelolaan domain pada hakikatnya merupakan bentuk inventarisasi dan klasifikasi aset digital yang disertai dengan penetapan kebijakan akses, prosedur teknis,

dan mekanisme proteksi jaringan.

Tabel 4.2. Kontrol ISO/IEC 27001:2022 Paling Sering Dirujuk pada Keputusan Rektor tentang Pedoman Pengelolaan Domain UGM

No	Kontrol	Jumlah
1	A.5.9 (<i>Inventory of Information and Other Associated Assets</i>)	10
2	A.5.1 (<i>Policies for Information Security</i>)	8
3	A.8.20 (<i>Networks Security</i>)	6
4	A.5.2 (<i>Information Security Roles and Responsibilities</i>)	6
5	A.8.21 (<i>Security of Network Services</i>)	5
6	A.5.37 (<i>Documented Operating Procedures</i>)	5

4.1.2.2 Peraturan Rektor UGM Nomor 13 Tahun 2025 tentang Tata Kelola Teknologi Informasi di UGM

Dokumen ini berfokus pada kerangka tata kelola teknologi informasi secara menyeluruh di tingkat universitas, meliputi struktur organisasi TI, pengelolaan infrastruktur, pusat data, layanan TI, klasifikasi data, serta perlindungan data pribadi. Berdasarkan pemetaan *ground truth*, dokumen ini menghasilkan 81 referensi kontrol dengan distribusi A.5 sebesar 58,0% dan A.8 sebesar 37,0%, serta merupakan satu-satunya dokumen yang secara eksplisit merujuk pada domain A.6 (*People Controls*) sebanyak 4 kali melalui kontrol A.6.1 dan A.6.2 yang berkaitan dengan pengelolaan sumber daya manusia di bidang TI. Berdasarkan pola distribusi tersebut, dokumen ini secara dominan merujuk pada aspek penetapan peran, wewenang, dan tanggung jawab dalam ekosistem TI institusi. Kontrol yang paling sering dirujuk disajikan pada Tabel ???. Distribusi ini mencerminkan cakupan peraturan yang bersifat lintas domain, menjadikannya dokumen dengan spektrum kontrol ISO/IEC 27001:2022 terluas di antara keempat dokumen yang dianalisis.

Tabel 4.3. Kontrol ISO/IEC 27001:2022 Paling Sering Dirujuk pada Peraturan Rektor tentang Tata Kelola TI UGM

No	Kontrol	Jumlah
1	A.5.2 (<i>Information Security Roles and Responsibilities</i>)	12
2	A.8.21 (<i>Security of Network Services</i>)	6
3	A.5.37 (<i>Documented Operating Procedures</i>)	6
4	A.8.20 (<i>Networks Security</i>)	6
5	A.5.9 (<i>Inventory of Information and Other Associated Assets</i>)	5
6	A.8.27 (<i>Secure System Architecture and Engineering Principles</i>)	4

4.1.2.3 Keputusan Rektor UGM Nomor 1198/UN1.P5/KPT/HUKOR/2025 tentang Standar Parameter *Password* dan Keamanan Sistem Finance SIMASTER

Dokumen ini berfokus pada keamanan teknis sistem keuangan SIMASTER, mencakup standar kompleksitas *password*, kebijakan rotasi dan *lockout*, autentikasi multifaktor, *patch management*, pengelolaan hak akses, pencatatan aktivitas (*logging*), enkripsi data, pengelolaan *backup*, serta prosedur manajemen perubahan konfigurasi. Berdasarkan pemetaan *ground truth*, dokumen ini menghasilkan 39 referensi kontrol dengan dominasi A.8 (*Technological Controls*) sebesar 61,5% dan A.5 sebesar 38,5%, tanpa satu pun referensi pada domain A.6 maupun A.7. Berdasarkan pola distribusi tersebut, dokumen ini secara dominan merujuk pada kontrol-kontrol teknis yang bersifat operasional dan preventif. Kontrol yang paling sering dirujuk disajikan pada Tabel ??.

Konsentrasi yang tinggi pada domain A.8 mencerminkan sifat dokumen yang secara spesifik mengatur implementasi langsung kontrol keamanan pada level sistem informasi.

Tabel 4.4. Kontrol ISO/IEC 27001:2022 Paling Sering Dirujuk pada Keputusan Rektor tentang Standar Parameter *Password* dan Keamanan Finance SIMASTER

No	Kontrol	Jumlah
1	A.8.5 (<i>Secure Authentication</i>)	4
2	A.5.18 (<i>Access Rights</i>)	4
3	A.8.16 (<i>Monitoring Activities</i>)	3
4	A.5.17 (<i>Authentication Information</i>)	3
5	A.8.2 (<i>Privileged Access Rights</i>)	3
6	A.5.16 (<i>Identity Management</i>)	3

4.1.2.4 Surat Edaran Rektor UGM Nomor 3779/UN1.P/DTI/TL.02.03/2025 tentang Penggunaan Perangkat Lunak di Lingkungan UGM

Dokumen ini berfokus pada kewajiban penggunaan perangkat lunak legal (*licensed* dan *open source*) di seluruh lingkungan sivitas akademika Universitas Gadjah Mada, beserta konsekuensi hukum dan teknis dari penggunaan perangkat lunak non-legal. Berdasarkan pemetaan *ground truth*, dokumen ini menghasilkan 18 referensi kontrol dengan dominasi sangat kuat pada domain A.5 (*Organizational Controls*) sebesar 83,3%, diikuti A.8 sebesar 11,1%, dan A.6 sebesar 5,6%. Berdasarkan pola distribusi tersebut, dokumen ini secara dominan merujuk pada kontrol-kontrol yang berkaitan dengan kepatuhan hukum dan perlindungan hak kekayaan intelektual. Kontrol yang paling sering dirujuk disajikan pada Tabel ???. Proporsi kontrol A.5.32 yang sangat menonjol mencerminkan sifat dokumen yang secara khusus mengatur aspek kepatuhan terhadap regulasi hak cipta perangkat lunak.

Tabel 4.5. Kontrol ISO/IEC 27001:2022 Paling Sering Dirujuk pada Surat Edaran Rektor tentang Penggunaan Perangkat Lunak di Lingkungan UGM

No	Kontrol	Jumlah
1	A.5.32 (<i>Intellectual Property Rights</i>)	6
2	A.5.36 (<i>Compliance with Policies, Rules, and Standards for Information Security</i>)	2
3	A.5.31 (<i>Legal, Statutory, Regulatory and Contractual Requirements</i>)	2
4	A.8.19 (<i>Installation of Software on Operational Systems</i>)	2
5	A.5.10 (<i>Acceptable Use of Information and Other Associated Assets</i>)	2

4.1.3 Simpulan Analisis Dokumen DTI UGM


Berdasarkan analisis terhadap keempat dokumen kebijakan DTI UGM, dapat disimpulkan bahwa dokumentasi kebijakan DTI UGM telah memiliki cakupan yang memadai pada domain **A.5 (*Organizational Controls*)** dan **A.8 (*Technological Controls*)**, yang bersama-sama mencakup 96,5% dari seluruh 231 referensi kontrol (A.5: 58,9%; A.8: 38,1%). Kondisi ini menunjukkan bahwa kebijakan DTI UGM yang tersedia telah mencerminkan perhatian yang substansial terhadap aspek tata kelola organisasional dan implementasi kontrol teknis, sejalan dengan dua domain utama yang paling banyak dibahas dalam ISO/IEC 27001:2022.

Di sisi lain, cakupan dokumentasi DTI UGM terhadap domain **A.6 (*People Controls*)** masih sangat terbatas, yakni hanya tercatat 5 referensi (2,2%) dari seluruh total, dan domain **A.7 (*Physical Controls*)** yang hanya memiliki 2 referensi (0,9%). Keterbatasan referensi pada A.6 mengindikasikan bahwa aspek-aspek seperti *screening* sumber daya manusia, ketentuan kerja jarak jauh, dan peningkatan kesadaran keamanan informasi belum sepenuhnya diformalisasikan dalam dokumen kebijakan yang tersedia. Demikian pula, belum adanya dokumen yang secara spesifik mengatur keamanan fisik (A.7), seperti perlindungan area aman, pengelolaan peralatan fisik, dan kontrol akses fisik terhadap fasilitas TI, menunjukkan adanya kesenjangan dokumentasi yang perlu mendapat perhatian lebih lanjut. Temuan ini selaras dengan kecenderungan umum pada institusi pendidikan tinggi yang lebih memprioritaskan formalisasi kebijakan TI berbasis teknologi dan tata kelola organisasi dibandingkan prosedur keamanan sumber daya manusia dan keamanan fisik. Distribusi ini memberikan konteks yang penting dalam interpretasi hasil evaluasi sistem *retrieval*, di mana kinerja model pada kontrol A.6 dan A.7 perlu diinterpretasikan dengan mempertimbangkan keterbatasan jumlah *query* pada kedua domain tersebut.

4.2 Analisis Komparatif Komposisi *Dense* dan *Sparse* pada *Hybrid Retrieval*

4.2.1 Hasil Evaluasi Deskriptif

Analisis pada subbab ini dilakukan untuk mengevaluasi pengaruh komposisi pembobotan *dense* dan *sparse* terhadap kualitas hasil *hybrid retrieval*. Lima konfigurasi yang diuji adalah *dense*=0,00 (*sparse* murni), *dense*=0,25 (dominan *sparse*), *dense*=0,50 (seimbang), *dense*=0,75 (dominan *dense*), dan *dense*=1,00 (*dense* murni). Metrik evaluasi yang digunakan mencakup Hit@3, Recall@3, MAP@3, dan NDCG@3. Hasil evaluasi lengkap terhadap *query* dokumen DTI ditunjukkan pada Gambar ?? dan Tabel ??.



Gambar 4.9. Perbandingan metrik evaluasi berdasarkan komposisi *dense* dan *sparse* pada *query* dokumen DTI

Tabel 4.6. Rata-rata metrik evaluasi berdasarkan komposisi *dense* dan *sparse*

Konfigurasi	Hit@3	Recall@3	MAP@3	NDCG@3
Dense 0,00 : Sparse 1,00	0,961	0,485	0,407	0,525
Dense 0,25 : Sparse 0,75	0,948	0,506	0,437	0,549
Dense 0,50 : Sparse 0,50	0,935	0,537	0,467	0,575
Dense 0,75 : Sparse 0,25	0,831	0,468	0,417	0,511
Dense 1,00 : Sparse 0,00	0,649	0,307	0,256	0,336

Hasil evaluasi pada Gambar ?? dan Tabel ?? menunjukkan bahwa konfigurasi tertentu *dense*=0,50 menghasilkan performa terbaik pada tiga dari empat metrik evaluasi, yaitu Recall@3 sebesar 0,537, MAP@3 sebesar 0,467, dan NDCG@3 sebesar 0,575. Sementara itu, konfigurasi *sparse* murni (*dense*=0,00) memperoleh nilai Hit@3 tertinggi sebesar 0,961, namun memiliki kualitas peringkat yang lebih rendah dibanding konfigurasi seimbang pada MAP@3 (0,407 vs 0,467) dan NDCG@3 (0,525 vs 0,575). Konfigurasi *sparse* murni lebih sering berhasil menemukan minimal satu dokumen relevan dalam tiga hasil teratas, tetapi konfigurasi seimbang lebih konsisten dalam menempatkan dokumen relevan pada posisi peringkat yang lebih tinggi.

Pola performa menunjukkan bahwa terdapat peningkatan signifikan ketika komponen *sparse* ditambahkan ke dalam *dense retrieval* murni. Konfigurasi *dense*=0,75 yang masih mendominasi *sparse* menghasilkan performa yang lebih baik dibanding *dense* murni pada seluruh metrik, namun masih lebih rendah dibanding konfigurasi yang memberikan bobot lebih besar pada *sparse*. Di sisi lain, konfigurasi *sparse* murni menghasilkan Hit@3 tertinggi tetapi lebih rendah pada Recall@3 dan metrik

rank-sensitive dibanding konfigurasi seimbang. Temuan ini mengindikasikan bahwa dokumen ISO 27001 membutuhkan kombinasi antara pencocokan semantik untuk menangkap makna kontekstual dan pencocokan leksikal untuk mengenali terminologi spesifik domain keamanan informasi.

4.2.2 Validitas Statistik Perbedaan Performa antar Konfigurasi

Untuk membuktikan bahwa perbedaan performa antar kelima konfigurasi bersifat signifikan secara statistik, dilakukan uji Friedman terhadap empat metrik evaluasi (Hit@3, Recall@3, MAP@3, dan NDCG@3), dengan 77 *query* sebagai *blocking factor*. Hasil uji Friedman ditunjukkan pada Tabel ??.

Tabel 4.7. Hasil uji Friedman pada komposisi *dense* dan *sparse*

Metrik	χ^2	<i>p-value</i>
Hit@3	52,205	< 0,000001
Recall@3	53,542	< 0,000001
NDCG@3	46,395	< 0,000001
MAP@3	46,395	< 0,000001

Seluruh metrik evaluasi menghasilkan *p-value* yang jauh di bawah ambang batas signifikansi $\alpha = 0,05$, sehingga hipotesis nol yang menyatakan tidak ada perbedaan performa antar konfigurasi ditolak. Dengan demikian, terdapat bukti statistik yang kuat bahwa komposisi pembobotan *dense* dan *sparse* secara signifikan memengaruhi kinerja *hybrid retrieval* untuk pencarian dokumen ISO 27001.


4.2.3 Kesimpulan Komposisi *Dense* dan *Sparse*

Berdasarkan hasil evaluasi deskriptif dan uji Friedman, disimpulkan bahwa konfigurasi *dense*=0,50 dan *sparse*=0,50 merupakan komposisi paling optimal untuk *hybrid retrieval* pada domain dokumen ISO 27001. Komposisi seimbang ini menghasilkan performa terbaik pada tiga dari empat metrik evaluasi (Recall@3, NDCG@3, dan MAP@3). Uji Friedman membuktikan bahwa perbedaan performa antar konfigurasi bersifat signifikan secara statistik ($p < 0,001$) pada seluruh metrik. Komposisi seimbang menunjukkan bahwa pencarian dokumen ISO 27001 membutuhkan kombinasi antara kemampuan *dense retrieval* dalam menangkap kesamaan semantik dan kemampuan *sparse retrieval* dalam mencocokkan istilah eksplisit serta terminologi spesifik standar keamanan informasi. Konfigurasi ini kemudian digunakan sebagai parameter tetap pada eksperimen selanjutnya.

4.3 Analisis Komparatif Ukuran *Candidate Pool* pada *Reranking Retrieval*

4.3.1 Hasil Evaluasi Deskriptif

Analisis pada subbab ini dilakukan untuk mengevaluasi pengaruh ukuran *candidate pool* terhadap kualitas hasil *reranking*. Empat ukuran *pool* yang diuji adalah 5, 10, 15, dan 20 dokumen. Seluruh parameter *hybrid retrieval* dijaga konstan pada konfigurasi optimal yang telah ditentukan sebelumnya, yaitu *dense*=0,50 dan *sparse*=0,50. Metrik evaluasi yang digunakan mencakup Hit@3, Recall@3, MAP@3, dan NDCG@3. Hasil evaluasi ditunjukkan pada Gambar ?? dan Tabel ??.



Gambar 4.10. Perbandingan metrik evaluasi berdasarkan ukuran *candidate pool* pada *query* dokumen DTI

Tabel 4.8. Rata-rata metrik evaluasi berdasarkan ukuran *candidate pool*

<i>Pool</i>	Hit@3	Recall@3	MAP@3	NDCG@3	<i>Retrieval</i> (ms)	Total (s)
5	0,857	0,468	0,387	0,485	181,47	5,91
10	0,753	0,424	0,372	0,451	164,07	11,80
15	0,701	0,394	0,343	0,418	160,89	19,79
20	0,688	0,377	0,328	0,405	136,26	24,37

Hasil evaluasi pada Gambar ?? dan Tabel ?? menunjukkan bahwa *candidate pool* berukuran 5 menghasilkan performa terbaik pada seluruh metrik. Konfigurasi ini memperoleh Hit@3 sebesar 0,857, Recall@3 sebesar 0,468, MAP@3 sebesar 0,387, dan NDCG@3 sebesar 0,485. Terdapat tren penurunan performa yang konsisten seiring bertambahnya ukuran *pool*. Ketika ukuran *pool* ditingkatkan dari 5 ke 20, Hit@3 mengalami penurunan sebesar 0,169, Recall@3 turun 0,091, MAP@3 turun 0,059, dan NDCG@3 turun 0,080.

Selain penurunan akurasi, penambahan ukuran *pool* juga meningkatkan waktu proses secara signifikan. Waktu total meningkat dari 9,01 detik pada *pool* 5 menjadi 25,61 detik pada *pool* 20, yang menunjukkan peningkatan hampir tiga kali lipat. Pola penurunan monoton ini mengindikasikan bahwa penambahan kandidat tidak selalu meningkatkan kualitas hasil *reranking*. Pada domain dokumen ISO 27001, semakin besar *candidate pool*, semakin besar pula kemungkinan kandidat yang kurang relevan masuk ke tahap *reranking*, sehingga meningkatkan *noise* dan melemahkan kualitas pemeringkatan akhir.

4.3.2 Validitas Statistik Perbedaan Performa antar Konfigurasi

Untuk membuktikan bahwa perbedaan performa antar empat ukuran *candidate pool* bersifat signifikan secara statistik, dilakukan uji Friedman terhadap empat metrik evaluasi (Hit@3, Recall@3, MAP@3, dan NDCG@3), dengan 77 *query* sebagai *blocking factor*. Hasil uji Friedman ditunjukkan pada Tabel ??.

Tabel 4.9. Hasil uji Friedman pada ukuran *candidate pool*

Metrik	χ^2	<i>p-value</i>
Hit@3	16,760	0,000792
Recall@3	14,095	0,002779
NDCG@3	25,776	0,000011
MAP@3	25,776	0,000011

Seluruh metrik evaluasi menghasilkan *p-value* di bawah ambang batas signifikansi $\alpha = 0,05$, sehingga hipotesis nol ditolak. Dengan demikian, terdapat bukti statistik bahwa ukuran *candidate pool* secara signifikan memengaruhi kinerja *reranking* pada domain dokumen ISO 27001.


4.3.3 Kesimpulan Ukuran *Candidate Pool*

Berdasarkan hasil evaluasi deskriptif dan uji Friedman, disimpulkan bahwa *candidate pool* berukuran 5 merupakan konfigurasi paling optimal untuk *reranking* pada domain dokumen ISO 27001. Konfigurasi ini unggul di seluruh empat metrik evaluasi (Hit@3, Recall@3, NDCG@3, dan MAP@3) dan menghasilkan latensi terendah. Uji Friedman membuktikan bahwa perbedaan performa antar ukuran *pool* bersifat signifikan secara statistik ($p < 0,003$) pada seluruh metrik. Konfigurasi *pool*=5 ini kemudian digunakan sebagai parameter *reranking* pada eksperimen *score fusion* selanjutnya.

4.4 Analisis Komparatif Komposisi *Score Fusion* antara *Hybrid Retrieval* dan *Cross-Encoder*

4.4.1 Hasil Evaluasi Deskriptif

Analisis pada subbab ini dilakukan untuk mengevaluasi pengaruh komposisi pembobotan antara skor *hybrid retrieval* dan skor *cross-encoder* (CE) dalam proses *score fusion*. Lima komposisi yang diuji mencakup seluruh spektrum pembobotan dengan urutan Hybrid:CE, yaitu konfigurasi *hybrid* independen (1,00:0,00), dominan *hybrid* (0,75:0,25), seimbang (0,50:0,50), dominan *cross-encoder* (0,25:0,75), dan *cross-encoder* independen (0,00:1,00). Dengan kerangka ini, konfigurasi *hybrid* independen (1,00:0,00) merepresentasikan hasil *hybrid retrieval* tanpa *reranking*, sedangkan konfigurasi CE independen (0,00:1,00) merepresentasikan *reranking* independen tanpa kontribusi skor *hybrid*. Parameter *hybrid retrieval* menggunakan konfigurasi optimal (*dense*=0,50, *sparse*=0,50) dan *candidate pool* menggunakan konfigurasi optimal (*pool*=5). Hasil evaluasi ditunjukkan pada Gambar ?? dan Tabel ??.



Gambar 4.11. Perbandingan metrik evaluasi berdasarkan komposisi *score fusion* (Hybrid:CE) pada *query* dokumen DTI

Tabel 4.10. Rata-rata metrik evaluasi berdasarkan komposisi *score fusion* (Hybrid:CE)

Konfigurasi (Hybrid:CE)	Hit@3	Recall@3	MAP@3	NDCG@3	Latensi
1,00 : 0,00 (<i>hybrid</i> independen)	0,935	0,537	0,467	0,575	60 ms
0,75 : 0,25 (dominan <i>hybrid</i>)	0,935	0,541	0,470	0,579	6,02 s
0,50 : 0,50 (seimbang)	0,896	0,528	0,452	0,553	5,23 s
0,25 : 0,75 (dominan CE)	0,883	0,502	0,418	0,519	6,08 s
0,00 : 1,00 (CE independen)	0,857	0,469	0,387	0,485	5,91 s

Hasil evaluasi pada Gambar ?? dan Tabel ?? menunjukkan pola yang konsisten: semakin besar bobot *hybrid retrieval*, semakin tinggi performa sistem pada seluruh metrik. Analisis berdasarkan kelompok komposisi mengungkap tiga pola utama sebagai berikut.

Konfigurasi Independen (1,00:0,00 dan 0,00:1,00). Konfigurasi *hybrid* independen (tanpa *reranking*) mencapai Hit@3=0,935, Recall@3=0,537, MAP@3=0,467, dan NDCG@3=0,575 dengan latensi hanya 60 ms. Sebaliknya, konfigurasi *cross-encoder* independen menghasilkan performa terendah pada seluruh metrik (Hit@3=0,857, Recall@3=0,469, MAP@3=0,387, NDCG@3=0,485) dengan latensi 5,91 detik. Hal ini menunjukkan bahwa skor *hybrid retrieval* lebih mampu menangkap relevansi pada domain ISO 27001 dibandingkan skor *cross-encoder* yang berdiri sendiri.

Konfigurasi Dominan Satu Sisi (0,75:0,25 dan 0,25:0,75). Konfigurasi dominan *hybrid* (0,75:0,25) menjadi konfigurasi terbaik secara keseluruhan dengan Recall@3=0,541, MAP@3=0,470, dan NDCG@3=0,579. Pemberian bobot kecil (25%) pada *cross-encoder* terbukti mampu menyempurnakan peringkat pada sejumlah *query* tanpa menurunkan kualitas *hybrid retrieval*. Sebaliknya, konfigurasi dominan *CE* (0,25:0,75) justru menurunkan performa secara signifikan (NDCG turun dari 0,579 ke 0,519), yang menegaskan bahwa bobot besar pada *cross-encoder* melemahkan kualitas peringkat akhir.

Konfigurasi Seimbang (0,50:0,50). Konfigurasi ini menghasilkan performa yang berada di antara konfigurasi independen dan dominan, dengan Hit@3=0,896, Recall@3=0,528, MAP@3=0,452, dan NDCG@3=0,553. Latensinya tercatat 5,23 detik, yang merupakan terendah di antara konfigurasi yang melibatkan *reranking*. Meskipun demikian, akurasi masih di bawah konfigurasi dominan *hybrid*.

4.4.2 Validitas Statistik Perbedaan Performa antar Konfigurasi

Untuk membuktikan bahwa perbedaan performa antar lima komposisi *score fusion* bersifat signifikan secara statistik, dilakukan uji Friedman terhadap empat metrik evaluasi (Hit@3, Recall@3, MAP@3, dan NDCG@3), dengan 77 *query* sebagai *blocking factor*. Hasil uji Friedman ditunjukkan pada Tabel ??.

Tabel 4.11. Hasil uji Friedman pada komposisi *score fusion*

Metrik	χ^2	<i>p-value</i>
Hit@3	10,462	0,033
Recall@3	21,245	0,000283
NDCG@3	29,639	0,000006
MAP@3	28,952	0,000008

Seluruh metrik evaluasi menghasilkan *p-value* di bawah ambang batas signifikansi $\alpha = 0,05$, yang membuktikan bahwa komposisi pembobotan antara skor *hybrid retrieval* dan skor *cross-encoder* secara signifikan memengaruhi kinerja sistem pada seluruh aspek evaluasi. Pada metrik *rank-sensitive*, yaitu NDCG@3 ($p < 0,001$) dan MAP@3 ($p < 0,001$), perbedaan performa sangat signifikan, yang mengonfirmasi bahwa komposisi pembobotan memberikan dampak nyata terhadap kualitas peringkat dokumen, bukan sekadar kemampuan menemukan dokumen relevan.

4.4.3 Analisis Karakteristik *Query* pada Perbedaan Performa *Hybrid Retrieval* dan *Cross-Encoder*

Temuan pada Subbab 4.4.1 memperlihatkan bahwa secara agregat, peningkatan bobot *cross-encoder* justru memperburuk performa *hybrid retrieval*. Meskipun demikian, konfigurasi dominan *hybrid* (0,75:0,25) tetap sedikit mengungguli *hybrid* independen, yang mengindikasikan bahwa *cross-encoder* memberikan nilai tambah pada sejumlah *query* tertentu. Untuk memahami kondisi spesifik yang menentukan kapan masing-masing komponen unggul, dilakukan analisis perbandingan langsung antara *hybrid* independen (1,00:0,00) dan *cross-encoder* independen (0,00:1,00) pada tingkat individual per *query* menggunakan seluruh empat metrik evaluasi. Tabel ?? merangkum distribusi *query* berdasarkan komponen pemenang untuk setiap metrik.

Tabel 4.12. Distribusi *query* berdasarkan komponen pemenang (*hybrid* independen vs. *CE* independen)

Metrik	<i>Hybrid</i> Unggul	<i>CE</i> Unggul	Seri
Hit@3	8 (10,4%)	2 (2,6%)	67 (87,0%)
Recall@3	24 (31,2%)	8 (10,4%)	45 (58,4%)
NDCG@3	36 (46,8%)	15 (19,5%)	26 (33,8%)
MAP@3	36 (46,8%)	15 (19,5%)	26 (33,8%)

Dari 77 *query* yang diuji, Tabel ?? memperlihatkan bahwa *hybrid retrieval* independen secara konsisten mengungguli *CE* independen pada seluruh metrik. Pada Hit@3, yang bersifat biner, terdapat 67 *query* (87,0%) dengan performa sama, menunjukkan bahwa mayoritas *query* berhasil atau gagal menemukan minimal satu dokumen relevan oleh kedua komponen. Recall@3 lebih diskriminatif dengan 45 *query* seri (58,4%), karena metrik ini mengukur proporsi *ground truth* yang ditemukan. NDCG@3 dan MAP@3 menunjukkan distribusi identik, *hybrid* unggul pada 36 *query* (46,8%), *CE* unggul pada 15 *query* (19,5%), dan 26 *query* seri (33,8%), karena kedua metrik sama-sama mengukur kualitas peringkat pada top-3, meskipun dengan formulasi yang berbeda. Dominasi *hybrid retrieval* ini konsisten dengan temuan agregat pada Subbab 4.4.1, namun keberadaan 15 *query* di mana *CE* unggul pada NDCG@3 dan MAP@3 menjadi justifikasi penting bagi pemberian bobot kecil pada *cross-encoder* dalam konfigurasi *score fusion* optimal. Berikut dianalisis karakteristik *query* pada masing-masing kelompok, dikelompokkan berdasarkan komponen yang unggul menurut NDCG@3.

4.4.3.1 Analisis Keunggulan *Reranker Cross-Encoder*

Dari 15 *query* di mana *CE* independen unggul, teridentifikasi tiga pola yang menunjukkan kondisi spesifik di mana pemahaman kontekstual *cross-encoder* memberikan nilai tambah dibandingkan *hybrid retrieval*.

1. Frasa kunci tidak memiliki kecocokan langsung dengan terminologi kontrol ISO.

Terdapat 2 *query* di mana *hybrid retrieval* sama sekali tidak menemukan dokumen relevan (NDCG@3=0), sementara *cross-encoder* berhasil. Pola ini terjadi ketika frasa kunci pada *query* tidak memiliki kecocokan yang cukup, baik secara leksikal maupun semantik, dengan terminologi dalam dokumen kontrol ISO, sehingga BM25 dan *dense embedding* sama-sama gagal menghasilkan peringkat yang tepat. *Cross-encoder* mampu mengatasi kegagalan ini melalui mekanisme *pair-scoring* yang mengevaluasi relasi *query*–dokumen secara holistik. Berikut contoh *query* pada pola ini.

- Q75: “setiap perangkat komputer dengan akun UGM yang teridentifikasi terdapat **perangkat lunak non-legal**, Universitas akan menghentikan sementara layanan koneksi internet sampai dengan keberadaan **perangkat lunak non-legal** tersebut dihapuskan.” Frasa **perangkat lunak non-legal** merupakan terminologi organisasional yang secara leksikal hanya memiliki kecocokan parsial dengan istilah “perangkat lunak” pada kontrol A.8.19 dan A.5.32, namun kualifier “non-legal” membalikkan makna dibanding istilah “berlisensi” yang digunakan dalam A.5.32, sehingga BM25 gagal menangkap perbedaan semantik ini. *Cross-encoder* berhasil memetakan relasi bahwa penggunaan **perangkat lunak non-legal** berkaitan dengan

instalasi perangkat lunak (A.8.19), hak kekayaan intelektual (A.5.32), dan kepatuhan terhadap kebijakan (A.5.36).

- Q56: “(4) Dalam hal suatu layanan TI yang sudah tidak sesuai **tidak dapat ditemui penanggung jawab teknisnya**, Direktorat yang membidangi TI akan menghentikan layanan dengan tetap mengusahakan preservasi Data dan Informasi.” Frasa **tidak dapat ditemui penanggung jawab teknisnya** mengacu pada skenario penghentian layanan TI tanpa penanggung jawab teknis, suatu kondisi prosedural yang tidak tercakup secara leksikal dalam deskripsi manapun kontrol ISO. Meskipun A.5.2 menyebut “tanggung jawab keamanan informasi”, frasa spesifik “penanggung jawab teknis” tidak memiliki padanan langsung. *Cross-encoder* mengenali bahwa skenario ini mengimplikasikan perlunya penghapusan informasi secara aman (A.8.10), pencadangan data (A.8.13), dan perlindungan catatan (A.5.33).

2. *Cross-encoder* menemukan lebih banyak *ground truth* (*recall* naik).

Terdapat 6 *query* di mana *hybrid retrieval* berhasil menemukan sebagian dokumen relevan, tetapi *cross-encoder* mampu menjangkau dokumen relevan tambahan yang terlewat. Pola ini terjadi karena *ground truth* yang terlewat memiliki keterkaitan semantik berdekatan dengan *ground truth* yang sudah ditemukan, namun keterkaitan tersebut melampaui kemampuan pencocokan leksikal BM25 dan *dense embedding*, sehingga evaluasi *pair-scoring* oleh *cross-encoder* lebih unggul dalam membedakan relevansi relatif. Berikut contoh *query* pada pola ini.

- Q31: “Sistem informasi wajib menggunakan **UGM ID** atau **Open Authentication** seperti **Office 365** atau **Google ID**.” *Hybrid retrieval* hanya menemukan 2 dari 3 dokumen relevan (Recall@3=0,667), sementara *cross-encoder* berhasil menemukan seluruhnya (Recall@3=1,000), termasuk kontrol A.5.17 (*Authentication Information*) yang terlewat. Meskipun A.5.17 membahas pengelolaan informasi autentikasi yang secara semantik berkaitan erat dengan mekanisme **UGM ID** dan **Open Authentication**, terminologi dalam *query* menggunakan bahasa Inggris (“Authentication”) sementara kontrol ISO menggunakan bahasa Indonesia (“autentikasi”), sehingga BM25 tidak dapat mencocokkannya secara leksikal.
- Q38: “Unit Kerja berkewajiban untuk menyediakan dan memelihara **jaringan akses** dan **perangkat pendukungnya** sesuai dengan standar dan spesifikasi yang ditentukan oleh Direktorat yang membidangi TI.” *Cross-encoder* berhasil menemukan kontrol A.8.9 (*Configuration Management*) yang tidak terjangkau oleh *hybrid retrieval*. Frasa **jaringan akses** dan **perangkat pendukungnya** merujuk pada konfigurasi infrastruktur jaringan yang harus dikelola sesuai standar, yang secara semantik tercakup oleh A.8.9 yang membahas manajemen konfigurasi perangkat keras, perangkat lunak, layanan, dan jaringan.

- Q28: “Pengelola sistem informasi wajib mematuhi **kebijakan privasi** dan **perlindungan data** sesuai **regulasi nasional atau internasional** yang relevan.” *Cross-encoder* berhasil menemukan kontrol A.5.1 (*Policies for Information Security*) yang terlewat oleh *hybrid retrieval*. Keterkaitan antara frasa **kebijakan privasi** dan **perlindungan data** dengan kebijakan keamanan informasi secara umum (A.5.1) bersifat semantik: A.5.1 membahas arahan dan dukungan manajemen untuk keamanan informasi, yang merupakan lingkup lebih luas yang mencakup privasi dan perlindungan data.

3. *Cross-encoder* memperbaiki peringkat pada *query* kontekstual/prosedural.

Terdapat 7 *query* di mana *recall* tidak berubah namun *cross-encoder* memperbaiki urutan peringkat sehingga dokumen relevan menempati posisi lebih tinggi. Pola ini muncul pada *query* yang mendeskripsikan proses, prosedur, atau kerangka kerja kelembagaan tanpa menyebut terminologi kontrol ISO secara eksplisit. Pada kondisi ini, *hybrid retrieval* berhasil menemukan dokumen relevan namun menempatkannya pada posisi peringkat yang lebih rendah karena kecocokan leksikal dan semantik parsial tidak cukup kuat untuk mengungguli dokumen non-relevan yang memiliki kecocokan permukaan lebih tinggi. Berikut contoh *query* pada pola ini.

- Q58: “**IT Management** merupakan mekanisme dan manajemen TI dan keamanan yang terarah dan fokus mewujudkan Intelligent University dengan kerangka kerja sistematis, terdiri atas **IT Decision Making**, **IT Risk Management**, IT Resource Management, IT Relationship Management, IT Performance Management, dan **IT Value Delivery**.” Istilah **IT Management**, **IT Decision Making**, **IT Risk Management**, dan **IT Value Delivery** merupakan terminologi kerangka kerja kelembagaan yang tidak memiliki padanan langsung dalam penamaan kontrol ISO. *Cross-encoder* mampu memperbaiki peringkat dengan mengenali bahwa kerangka kerja tata kelola TI tersebut berkaitan erat dengan penetapan kebijakan keamanan informasi (A.5.1), tanggung jawab manajemen dalam menerapkan keamanan (A.5.4), dan pengumpulan informasi ancaman sebagai bagian dari manajemen risiko (A.5.7), menghasilkan NDCG@3=0,765 dibanding 0,531 pada *hybrid retrieval*.
- Q55: “(3) Seluruh **layanan TI yang tidak lagi sesuai** sebagai akibat dari berlakunya Peraturan Rektor ini akan disosialisasikan secara luas dan kepada penanggung jawab teknisnya diberi batas waktu maksimal 24 bulan untuk melakukan **mitigasi** dengan **pendampingan** dari Direktorat yang membidangi TI.” Frasa **layanan TI yang tidak lagi sesuai** beserta mekanisme **mitigasi** dan **pendampingan** mengacu pada prosedur transisi layanan yang secara leksikal tidak mirip dengan penamaan kontrol ISO. Namun secara semantik, prosedur tersebut berkaitan dengan prosedur operasional

yang didokumentasikan (A.5.37), kepatuhan terhadap kebijakan dan standar (A.5.36), serta peran dan tanggung jawab keamanan informasi (A.5.2).

4.4.3.2 Analisis Keunggulan *Hybrid Retrieval*

Dari 36 *query* di mana *hybrid retrieval* independen unggul, teridentifikasi tiga pola yang menunjukkan kondisi spesifik di mana kombinasi pencocokan leksikal dan semantik pada *hybrid retrieval* lebih andal dibandingkan evaluasi *cross-encoder*.

1. *Cross-encoder* gagal total, *hybrid retrieval* berhasil menemukan dokumen relevan.

Terdapat 8 *query* di mana *cross-encoder* sama sekali tidak menemukan dokumen relevan ($NDCG@3=0$), sementara *hybrid retrieval* berhasil. Pola ini terjadi karena *cross-encoder* memberi skor tinggi pada dokumen yang secara permukaan mirip dengan *query* namun tidak relevan secara domain ISO 27001, sehingga dokumen yang benar tergeser keluar dari posisi teratas. *Hybrid retrieval* berhasil melalui kombinasi pencocokan leksikal parsial oleh BM25 dan pemahaman semantik oleh *dense embedding* yang sama-sama memberikan indikasi kecocokan pada kontrol yang benar. Berikut contoh *query* pada pola ini.

- Q50: “**Pemondokan web** adalah layanan berupa fasilitas yang terdiri dari **ruang penyimpanan** pada suatu **server** di **pusat Data** dan sambungan Internet, sehingga Data dan Informasi di dalam ruang penyimpanan dapat diakses melalui Internet.” *Hybrid retrieval* berhasil menemukan kontrol A.8.21 (*Security of Network Services*) dan A.8.20 (*Networks Security*) dengan $NDCG@3=0,531$, sementara *cross-encoder* gagal menemukan satupun kontrol relevan ($NDCG@3=0$). Meskipun terminologi spesifik “pemondokan web”, “server”, dan “pusat Data” tidak muncul secara harfiah dalam deskripsi kontrol ISO, kontrol A.8.21 dan A.8.20 membahas keamanan layanan jaringan dan internet yang secara semantik berkaitan dengan layanan *web hosting*, sementara A.5.9 membahas inventarisasi aset termasuk fasilitas pemrosesan informasi. *Hybrid retrieval* berhasil melalui kombinasi pencocokan leksikal parsial pada istilah umum (“internet”, “layanan”, “jaringan”) dan pencocokan semantik oleh *dense embedding* yang menghubungkan konsep *web hosting* dengan keamanan layanan jaringan.
- Q41: “Direktorat yang membidangi TI adalah **satu-satunya** Unit Kerja di UGM yang diberi wewenang dalam mengelola, memelihara, meningkatkan, dan mengembangkan **pusat Data**.” *Hybrid retrieval* berhasil menemukan kontrol A.5.2 (*Information Security Roles and Responsibilities*) dan A.8.14 (*Redundancy of Information Processing Facilities*) dengan $NDCG@3=0,469$, sementara *cross-encoder* gagal total ($NDCG@3=0$). Konsep “satu-satunya” yang diberi wewenang mengelola pusat data

secara semantik berkaitan dengan alokasi peran dan tanggung jawab keamanan informasi (A.5.2) serta redundansi fasilitas pemrosesan informasi (A.8.14). *Cross-encoder* tergeser oleh dokumen yang secara permukaan membahas pengelolaan data namun tidak relevan secara domain ISO 27001.

2. Query yang singkat dan kata kunci spesifik.

Terdapat 6 *query* pendek (≤ 15 kata) yang langsung mengidentifikasi topik melalui satu atau dua kata kunci spesifik. Pada pola ini, BM25 sangat efektif karena *exact match* pada kata kunci tersebut langsung bekerja dengan presisi tinggi, sementara *cross-encoder* tidak mendapat cukup konteks kalimat untuk melakukan evaluasi yang lebih baik dan cenderung mengubah urutan yang sudah benar. Berikut contoh *query* pada pola ini.

- Q24: “Pengelola sistem informasi wajib menggunakan **SSL/TLS** yang aman.” Istilah teknis **SSL/TLS** merupakan protokol kriptografi yang secara semantik berkaitan langsung dengan kontrol A.8.24 (*Use of Cryptography*) yang membahas penggunaan kriptografi dan enkripsi. *Hybrid retrieval* menghasilkan $NDCG@3=0,469$, sementara *cross-encoder* hanya 0,296. Pada *query* singkat ini, *cross-encoder* kekurangan konteks kalimat untuk mengevaluasi relevansi secara memadai.
- Q2: “menetapkan **Keputusan Rektor** Universitas Gadjah Mada tentang **Pedoman Pengelolaan Domain** Universitas Gadjah Mada.” Frasa **Keputusan Rektor** dan **Pedoman Pengelolaan Domain** mengidentifikasi secara tepat dokumen kebijakan yang berkaitan dengan penetapan kebijakan keamanan informasi (A.5.1) dan prosedur operasional (A.5.37). *Hybrid retrieval* menghasilkan $NDCG@3=0,704$ sementara *cross-encoder* hanya 0,235, penurunan yang sangat besar.
- Q6: “Dokumen ini bertujuan untuk menjamin **tata kelola domain** di lingkungan Universitas Gadjah Mada.” Frasa **tata kelola domain** secara semantik berkaitan dengan kebijakan keamanan informasi (A.5.1), prosedur operasional (A.5.37), dan inventarisasi aset (A.5.9). *Hybrid retrieval* menghasilkan $NDCG@3=0,765$ dibanding 0,531 pada *cross-encoder*.

3. Query dengan terminologi teknis atau aset spesifik.

Merupakan pola terbesar dengan 22 *query*, di mana *query* menyebutkan nama sistem, infrastruktur, layanan, atau objek teknis spesifik (domain, server, *wired/wireless*, *Simaster*, basis data, *password*, *firewall*, *backup*, dsb.). Pada pola ini, *hybrid retrieval* berhasil melalui kombinasi pencocokan leksikal parsial oleh BM25 pada istilah umum yang muncul dalam deskripsi kontrol (“jaringan”, “akses”, “hak”, “keamanan”) dan pencocokan semantik oleh *dense embedding* yang menghubungkan terminologi teknis spesifik dalam *query* dengan konsep yang lebih abstrak dalam kontrol ISO. Sementara

itu, *cross-encoder* cenderung meremehkan pentingnya terminologi teknis spesifik karena memfokuskan evaluasi pada pola semantik umum. Berikut contoh *query* pada pola ini.

- Q3: “**Nama domain** dan **subdomain** merupakan **identitas digital UGM** yang harus dikelola **terpusat** untuk menjamin keamanan, konsistensi, dan kepatuhan terhadap kebijakan institusi.” Konsep domain sebagai **identitas digital** yang harus dikelola secara **terpusat** berkaitan semantik dengan inventarisasi aset informasi (A.5.9), kepatuhan terhadap kebijakan (A.5.36), dan penggunaan aset yang dapat diterima (A.5.10). *Hybrid retrieval* menghasilkan $NDCG@3=0,765$ sementara *cross-encoder* hanya 0,235.
- Q52: “(1) **Koneksi wired** dan **wireless** adalah fasilitas siap pakai yang digunakan untuk menunjang produktivitas **sivitas akademika** dalam melaksanakan Tridharma Perguruan Tinggi.” Terminologi **Koneksi wired** dan **wireless** berkaitan semantik dengan keamanan jaringan (A.8.20) dan keamanan layanan jaringan (A.8.21), yang membahas pengamanan jaringan dan koneksinya. *Hybrid retrieval* menghasilkan $NDCG@3=0,765$ berbanding 0,296 pada *cross-encoder*.
- Q67: “Standar Keamanan **Database Server**: akses dan Hak Istimewa: a) akun **DBA** hanya diberikan kepada personel resmi; b) dilarang adanya penggunaan akun **shared account**; dan c) aplikasi terhubung ke database menggunakan akun dengan **hak minimal**, bukan akun administrator.” Terminologi teknis **Database Server**, akun **DBA**, **shared account**, dan **hak minimal** berkaitan semantik dengan hak akses istimewa (A.8.2), yang secara eksplisit membahas pengendalian akses administrator dan hak akses istimewa, serta hak akses pengguna (A.5.18) yang membahas pemberian dan peninjauan hak akses.

Secara keseluruhan, performa *cross-encoder* independen lebih rendah dibandingkan *hybrid retrieval* independen pada seluruh metrik. Sebagai pembanding langsung, dari 77 *query* yang diuji, *cross-encoder* independen hanya unggul pada 15 *query* ($NDCG@3$ dan $MAP@3$), sementara 36 *query* justru mengalami penurunan. Pada $Hit@3$, diskriminasi paling rendah dengan hanya 2 *query* di mana *CE* unggul dan 67 *query* seri, sedangkan $Recall@3$ menunjukkan *CE* unggul pada 8 *query*. Meskipun demikian, pada 15 *query* tersebut ($NDCG@3/MAP@3$), *cross-encoder* berhasil menempatkan dokumen relevan pada posisi yang lebih tinggi, terutama pada *query* yang membutuhkan pemahaman kontekstual yang lebih dalam (Subbab 4.4.3.1 Pola 1, 2, dan 3). Hal ini menjadi justifikasi bahwa komponen *cross-encoder* tetap relevan sebagai pelengkap, meskipun kontribusinya harus dibatasi melalui bobot yang kecil (0,25) agar tidak mengganggu kualitas *hybrid retrieval* yang sudah baik.

4.4.4 Kesimpulan Komposisi *Score Fusion*

Berdasarkan hasil evaluasi deskriptif dan uji Friedman, disimpulkan bahwa konfigurasi dominan *hybrid* (Hybrid:CE = 0,75:0,25) merupakan komposisi *score fusion* yang paling optimal untuk domain dokumen ISO 27001. Konfigurasi ini menghasilkan performa terbaik pada seluruh metrik evaluasi dan membuktikan bahwa skor *hybrid retrieval* memiliki peran dominan dalam menentukan kualitas hasil akhir. Secara agregat, *hybrid retrieval* independen sudah memberikan performa yang sangat baik, dan penambahan komponen *cross-encoder* dengan bobot kecil (25%) memberikan penyempurnaan marginal yang konsisten. Pola ini menunjukkan bahwa *hybrid retrieval* dan *cross-encoder* bersifat komplementer: *hybrid retrieval* unggul dalam cakupan dan ketepatan secara agregat, sementara *cross-encoder* memberikan nilai tambah pada *query* tertentu yang membutuhkan pemahaman kontekstual lebih dalam. Pendekatan *score fusion* dengan dominasi *hybrid* menjadi strategi terbaik karena memanfaatkan kelebihan keduanya sekaligus meminimalkan risiko penurunan performa akibat dominasi *cross-encoder* yang berlebihan.

BAB V

KESIMPULAN DAN SARAN

5.1 Kesimpulan

Berdasarkan hasil penelitian dan pembahasan pada Bab 4 mengenai evaluasi strategi *retrieval* dalam sistem *Retrieval-Augmented Generation* (RAG) untuk pemetaan kontrol *Statement of Applicability* (SoA) ISO/IEC 27001:2022, dapat ditarik kesimpulan sebagai berikut.

1. *Hybrid retrieval* dengan proporsi $dense=0,50:sparse=0,50$ menghasilkan performa terbaik pada $Recall@3=0,537$, $MAP@3=0,467$, dan $NDCG@3=0,575$. Perbedaan performa antar konfigurasi terbukti signifikan secara statistik ($p < 0,001$), yang mengonfirmasi bahwa pemetaan kontrol ISO 27001 membutuhkan kombinasi pencocokan semantik dan leksikal.
2. *Candidate pool* berukuran 5 menghasilkan performa terbaik pada seluruh metrik ($Hit@3=0,857$, $Recall@3=0,468$, $MAP@3=0,387$, $NDCG@3=0,485$) dengan latensi terendah (5,91 detik). Penambahan ukuran *pool* justru menurunkan performa secara monoton karena memperbanyak kandidat yang kurang relevan pada tahap *reranking* ($p < 0,003$).
3. *Score fusion* dengan proporsi Hybrid:CE=0,75:0,25 menghasilkan performa terbaik secara keseluruhan ($Recall@3=0,541$, $MAP@3=0,470$, $NDCG@3=0,579$). *Hybrid retrieval* dan *cross-encoder* bersifat komplementer: *hybrid* unggul pada *query* dengan terminologi teknis spesifik (36 dari 77 *query*), sementara *cross-encoder* memberikan nilai tambah pada *query* yang membutuhkan pemahaman kontekstual (15 dari 77 *query*).

Secara keseluruhan, konfigurasi optimal yang teridentifikasi adalah *hybrid retrieval* dengan proporsi $dense=0,50:sparse=0,50$, *candidate pool* berukuran 5, dan *score fusion* dengan proporsi Hybrid:CE=0,75:0,25, yang mencapai keseimbangan terbaik antara kualitas *retrieval* dan efisiensi komputasi.

5.2 Saran

Berdasarkan hasil penelitian yang telah dilakukan, beberapa saran untuk penelitian selanjutnya adalah sebagai berikut.

1. **Evaluasi pada domain dan organisasi yang berbeda.** Konfigurasi optimal yang ditemukan perlu diuji pada dokumen kebijakan organisasi lain dengan karakteristik terminologi dan ruang lingkup kontrol yang berbeda untuk memvalidasi generalisasi

temuan.

2. **Eksplorasi granularitas parameter yang lebih spesifik.** Penelitian ini menguji pembobotan dengan kelipatan 0,25 pada tiga sumbu desain. Penelitian selanjutnya dapat menerapkan *grid search* dengan resolusi lebih halus (kelipatan 0,05 atau 0,10), serta mengevaluasi metode *reranking* alternatif seperti *listwise reranker* atau model berbasis LLM.
3. **Analisis granular pada domain kontrol yang kurang terwakili.** Dataset penelitian ini didominasi domain A.5 dan A.8 (96,5%), sementara A.6 dan A.7 sangat terbatas. Penelitian selanjutnya perlu mengonstruksi dataset dengan cakupan lebih merata pada keempat domain untuk memvalidasi konsistensi konfigurasi optimal.
4. **Evaluasi *pipeline* RAG secara menyeluruh.** Penelitian selanjutnya perlu mengevaluasi *pipeline* RAG secara *end-to-end*, meliputi tahap *pre-retrieval* (*document chunking*), *retrieval* dengan konfigurasi optimal, serta tahap *generation* dengan LLM untuk mengevaluasi *faithfulness* dan utilitas rekomendasi kontrol.
5. **Validasi hasil oleh praktisi profesional bersertifikat.** Pemetaan manual kontrol Annex pada penelitian ini dilakukan oleh peneliti. Penelitian selanjutnya perlu melibatkan auditor bersertifikat ISO 27001 untuk memvalidasi akurasi *ground truth* dan relevansi hasil pemetaan.
6. **Penerapan uji *post-hoc* untuk perbandingan berpasangan.** Penelitian ini menggunakan uji Friedman secara keseluruhan namun belum dilanjutkan uji *post-hoc* seperti Wilcoxon dengan koreksi Bonferroni untuk mengidentifikasi pasangan konfigurasi mana yang benar-benar berbeda secara signifikan.
7. **Klasifikasi otomatis jenis *query* berdasarkan karakteristik *retrieval*.** *Hybrid retrieval* dan *cross-encoder* bersifat komplementer bergantung pada karakteristik *query*. Penelitian selanjutnya perlu mengembangkan skema klasifikasi *query* dan mekanisme *adaptive retrieval* yang menyesuaikan pembobotan secara dinamis per *query*.
8. **Eksplorasi desain basis pengetahuan dan pemilihan komponen model.** Penelitian selanjutnya perlu menguji variasi desain basis pengetahuan (struktur atribut, cakupan informasi, representasi teks) serta mengeksplorasi kombinasi komponen model (*sparse retrieval*, *dense embedding*, *reranker*) yang lebih efektif pada domain pemetaan kontrol ISO/IEC 27001.